Syrian Arab Republic

الجمهورية العربية السورية

Ministry of Higher Education

وزارة التعليم العالـــــي

Syrian Private University

الجامعة السورية الخاصة

Artificial Intelligence Engineering

كلية هندسة الذكاء الاصطناعي

Computer systems and networks security

اختصاص امن النظم والشبكات الحاسوبية

مشروع فصلي أعد لنيل شهادة الهندسة المعلوماتية في اختصاص امن النظم والشبكات الحاسوبية

تحسين إمكانية كشف التطفل ضمن المنازل الذكية

Improving Intrusion Detection in Smart Homes

إعداد :

محمد هاشم دلول

ماسة الرفاعي

ناريمان سحلول

إشراف

د. وسيم جنيدي

2025

الملخّص :

تستهدف هجمات التشويش (**Jamming**) وهجمات **Probe Flooding** الشبكات اللاسلكية من خلال استهلاك القناة أو إغراق نقطة الوصول، مما يؤدي إلى تدهور أداء الشبكة أو تعطيل الخدمة. يقدّم هذا العمل آلية كشف آنية تعتمد على مراقبة سلوك الشبكة ومؤشرات الأداء دون استخدام تقنيات تعلم آلي.

تم تنفيذ سيناريو عملي يتضمن عقداً وأخرى مهاجمة، مع بناء نموذج مرجعي يمثل السلوك الطبيعي للشبكة. تم كشف هجمة التشويش باستخدام مؤشرات الأداء العامة مثل **PDR**، **Throughput**، **Delay** و**RSSI**، بينما تم كشف هجمة **Probe Flooding** من خلال تحليل معدل الإرسال والفواصل الزمنية للحزم من أسوأ مصدر. أظهرت النتائج فعالية الآلية المقترحة في كشف الهجمتين بدقة جيدة مع تقليل الإنذارات الخاطئة.

Abstract

Wireless networks are vulnerable to attacks that exploit the open nature of the wireless medium, particularly jamming and probe flooding attacks, which can degrade network performance or disrupt services. This work presents a real-time detection approach based on monitoring network behavior and performance metrics, without relying on machine learning techniques.

A practical wireless network scenario with legitimate and attacker nodes is implemented, and a baseline model is built to represent normal network behavior. Jamming attacks are detected using global performance metrics such as packet delivery ratio (PDR), throughput, delay, and received signal strength (RSSI), while probe flooding attacks are detected by analyzing the transmission rate and

inter–arrival time of packets from the worst sender. Experimental results show that the proposed approach effectively detects both attacks with reduced false alarms.

Contents

المصطلحات والتعاريف : 6

المقدمة : 10

المشكلة العلمية: 15

الدراسة النظرية : 16

الفصل الأول :الدراس المراجعية 24

القسم الاول: انترنت الأشياء 24

ما هو إنترنت الأشياء؟ 25

تحديد المعايير اللاسلكية التي تمكّن إنترنت الأشياء : 27

الهدف: قابلية التشغيل البيني (Interoperability) 28

فحص بنية إنترنت الأشياء (IoT Architecture) : 29

بروتوكولات إنترنت الأشياء (IoT Protocols) 31

القسم الثاني: المنازل الذكية 33

وضع المنازل الذكية اليوم : 34

الشبكة الشبكية / كبسولة واحدة لكل غرفة : 36

التغلب على التحديات : 40

القسم الثالث: - أنظمة كشف التطفل :(IDS) 51

مقدمة عن أنظمة كشف التطفل (IDS) : 51

أنظمة كشف التطفل القائمة على التوقيع(SIDS) : 55

نظام كشف التطفل القائم على الشذوذ (AIDS) : 57

التقنيات القائمة على المعرفة : 60

التعلم الخاضع للإشراف في أنظمة كشف التطفل (IDS) : 62

التعلم غير الخاضع للإشراف في نظام كشف التطفل (IDS) : 68

التعلم شبه الخاضع للإشراف في نظام كشف التطفل (IDS) : 70

تقنيات قائمة على الهجين : 71

مقاييس الأداء لأنظمة كشف التطفل (IDS) : 72

الفصل الثاني :الدراسة النظرية المتقدمة : 73

الحساسات المستخدمة في انظمة المنازل الذكية : 73

أمن أجهزة إنترنت الأشياء (IoT) _ (نقاط الضعف الكامنة في أجهزة إنترنت الأشياء) : 78

فئات الهجمات السيبرانية : 79

الفصل الثالث:الخلفية النظرية لهجمات التشويش (jamming attacks) وهجمات الاغراق في الشبكات اللاسلكية (probe flooding) 81

3.1- jamming attacks 81

probe flooding-3.2 84
الفصل الثالث : تجهيز بيئة العمل :..... 86
الفصل الرابع:التجربة العملية 88
الفصل الخامس : النتائج و الافاق المستقبلية 97
نتائج هجمة التشويش (Jamming) : 97
نتائج هجمة Probe Flooding : 97
الافاق المستقبلية : 98
فهرس المراجع :..... 99

فهرس الاشكال :

رقم الشكل	عنوان الشكل	رقم الصفحة
الشكل 1-1	التحديات التي تواجه أنظمة كشف التطفل	25
الشكل 1-2	طبقة إنترنت الأشياء	27
الشكل 1-3	المراحل المبكرة لإنترنت الأشياء	29
الشكل 1-4	معايير المنزل الذكي	36
الشكل 1-5	منزل ذكي مع ZigBee Hub وBluetooth Hub	37
الشكل 1-6	أجهزة المنزل الذكي في البنية التحتية للشبكة	39
الشكل 1-7	شبكة اتصال إنترنت الأشياء الموزعة على كبسولة واحدة لكل غرفة	40
الشكل 1-8	دعم متعدد البروتوكولات الديناميكي وتقنية CurrentConnect	45
الشكل 1-9	العمل المفاهيمي لمناهج أنظمة كشف التطفل القائمة على التوقيع	59
الشكل 1-10	تصنيف أساليب أنظمة كشف التطفل القائمة على الشذوذ	62
الشكل 1-11	التصنيف كمهمة	70
الشكل 1-12	مثال على التصنيف حسب أقرب جار	70

فهرس الجداول:

رقم الجدول	عنوان الجدول	رقم الصفحة
الجدول 1-1	ملخص الأوراق البحثية السابقة	19
الجدول 1-2	التطبيقات على أنظمة كشف التطفل في سياقات إنترنت الأشياء	22
الجدول 1-2	مقارنة بين المحاكيات	77

المصطلحات والتعاريف :

الاسم بالإنكليزي	الاختصار	الاسم العربي
Internet of Things	**IoT**	إنترنت الأشياء
International Telecommunication Union	**ITU**	الاتحاد الدولي للاتصالات
Internet Protocol	**IP**	بروتوكول الإنترنت
Low-Rate Wireless Personal Area Network	**LR-WPAN**	شبكة شخصية لاسلكية منخفضة المعدل
Institute of Electrical and Electronics Engineers	**IEEE**	معهد مهندسي الكهرباء والإلكترونيات
Physical Layer	**PHY**	الطبقة الفيزيائية
Medium Access Control	**MAC**	التحكم بالولوج إلى الوسط
Wireless Local Area Network	**WLAN**	شبكة محلية لاسلكية
Wireless Fidelity	**Wi-Fi (IEEE 802.11)**	تقنية واي فاي
Special Interest Group	**SIG**	مجموعة الاهتمام الخاصة
Bluetooth Low Energy	**BLE**	بلوتوث منخفض الطاقة

Internet Protocol Version 6	**IPv6**	بروتوكول الإنترنت الإصدار السادس
Low Power Wide Area Network	**LPWAN**	شبكة واسعة النطاق منخفضة الطاقة
Long Range	**LoRa**	تقنية المسافات الطويلة
Long Range Wide Area Network	**LoRaWAN**	شبكة واسعة النطاق للمسافات الطويلة
Narrowband Internet of Things	**NB-IoT**	إنترنت الأشياء ضيق النطاق
Fifth Generation	**5G**	الجيل الخامس
Network Node	**Node**	عقدة شبكية
Network Gateway	**Gateway**	بوابة شبكة
Mesh Network	**Mesh Network**	شبكة متشابكة
Virtual Machine Ware	**VMware**	آلة افتراضية
Network Simulator 3	**NS-3**	محاكي الشبكات
Extreme Learning Machine	**ELM**	آلة التعلم القصوى
Manufacturer Usage Description	**MUD**	وصف استخدام المصنع
Deep Reinforcement Learning	**DRL**	التعلم المعزز العميق
Transmission Control Protocol	**TCP**	بروتوكول التحكم بالنقل

User Datagram Protocol	**UDP**	بروتوكول بيانات المستخدم
Internet Protocol Version 4	**IPv4**	بروتوكول الإنترنت الإصدار الرابع
Access Point	**AP**	نقطة الوصول
Station	**STA**	محطة لاسلكية
Carrier Sense Multiple Access	**CSMA**	النفاذ المتعدد مع تحسس الحامل
Tap Interface	**Tap**	واجهة **Tap**
Intrusion Detection System	**IDS**	نظام كشف التطفل
Australian Cyber Security Centre	**ACSC**	المركز الأسترالي للأمن السيبراني
Network Intrusion Detection System	**NIDS**	نظام كشف التطفل في الشبكة
Signature-based Intrusion Detection System	**SIDS**	نظام كشف التطفل القائم على التوقيعات
Anomaly-based Intrusion Detection System	**AIDS**	نظام كشف التطفل القائم على الشذوذ
Machine Learning	**ML**	التعلم الآلي
Deep Learning	**DL**	التعلم العميق
Artificial Neural Network	**ANN**	الشبكة العصبية الاصطناعية
Backpropagation	**BP**	الانتشار الخلفي

Support Vector Machine	**SVM**	آلة المتجهات الداعمة
Hidden Markov Model	**HMM**	نموذج ماركوف المخفي
K–Nearest Neighbors	**KNN**	أقرب جار
Genetic Algorithms	**GA**	الخوارزميات الجينية
Unified Modeling Language	**UML**	لغة النمذجة الموحدة
Cyber–Physical Control System	**CPCS**	الأنظمة السيبرانية–الفيزيائية
Single Hidden Layer Feed–Forward Neural Network	**SLFN**	شبكة أمامية ذات طبقة خفية واحدة
True Positive Rate	**TPR**	معدل الإيجابية الحقيقية
False Positive Rate	**FPR**	معدل الإيجابية الكاذبة
False Negative Rate	**FNR**	معدل السلبية الكاذبة
Classification Rate	**CR**	معدل التصنيف
Detection Rate	**DR**	معدل الكشف
Receiver Operating Characteristic	**ROC**	منحنى خاصية تشغيل المستقبل
False Alarm Rate	**FAR**	معدل الإنذار الكاذب

المقدمة :

يعود الاهتمام بإنترنت الأشياء، بشكل عام، إلى عدة أسباب، منها:

يعمل إنترنت الأشياء على ربط الأشياء معًا عبر هوية خاصة. ولا تختلف تطبيقات إنترنت الأشياء كثيرًا بالنسبة للعاملين في مؤسسات المعلومات الذين تعاملوا سابقًا مع تقنية تتبع الأشياء بتقنية تحديد الهوية بموجات الراديو (RFID) إذ تتشابه في تتبع الأشياء عبر أجهزة استشعار متصلة عن بعُد . إلا أن الفرق هنا يكمن في أن التواصل بين الأشياء والأجهزة يتم عبر إنترنت الأشياء من خلال الإنترنت.

يعُد إنترنت الأشياء وسيلة فعّالة للتغلب على بعض المشكلات التي تواجه المتعلم، ويساعده على تجاوز حواجز الزمان والمكان، ويمُكّنه من إدارة التعلم عن بعُد بنجاح.

كما يمُكن لإنترنت الأشياء أن يسُاعد في تعزيز العلاقة بين الطالب والمعلم، بحيث يتمكن كل منهما من التواصل مع الآخر عبر تطبيقات إنترنت الأشياء دون الحاجة إلى مقابلة فعلية.

يمكن للشركات استخدام هذه التقنية لخفض تكاليف الإنتاج من خلال زيادة التعاون والأتمتة بين الآلات بدلاً من العمال. يمكن للمؤسسات تقديم عروض أكثر كفاءة وتنوعًا وفورية، استنادًا إلى جمع البيانات من المستخدمين في الوقت الفعلي. يجب على المؤسسات تغيير سياستها في الإعلان عن سلعها للعملاء المحتملين، وتوصيل تلك العروض إلى المستخدم عند باب منزله عبر هاتفه الذكي في وقت قياسي ومناسب. يوفر إنترنت الأشياء:

- وسيلة فعّالة لتسويق خدماتها من خلال التواصل بين الجهات المعنية.
- استجابة سريعة وحساسة وآمنة لتلبية احتياجات المستفيدين من المعلومات ضمن شبكة إنترنت الأشياء.

- رفع إنتاجية الأجهزة والأنظمة من خلال زيادة دقة معالجة البيانات، وتنفيذ العمليات عن بعُد، وتقليل الاعتماد على العامل البشري.
- زيادة مستوى التوافر داخل أنظمة المعلومات من خلال تحسين قدرتها على أداء عملها وسرعة الوصول والحصول على المعلومات من خلالها.
- تمكين توصيل الأشياء في أي وقت وفي أي مكان لمن يستخدم خدمات شبكة إنترنت الأشياء بإتقان.
- تطوير خدمات مرجعية وتمكين المستخدمين من طرح أسئلة مرجعية والحصول على إجابات من داخل إنترنت الأشياء.
- ضمان وصول المستخدمين داخل شبكة إنترنت الأشياء إلى الموارد ومصادر المعلومات من خلال هوياتهم الموثّقة والمعرّفة، وأحيانًا من خلال رموز إضافية مُعرّفة.
- تسهيل عملية حفظ الموارد وتخزينها من خلال أنظمة الحوسبة السحابية والحوسبة الضبابية، والتي يتم من خلالها التحكم في موارد المعلومات ومصادرها ومراقبتها والتحكم بها، واستلام بياناتها بدقة وبشكل دائم.
- القدرة على استشعار الأشياء وإصدار التنبيهات والتحذيرات والتقارير المناسبة عنها من خلال قدرتها على معالجة البيانات وتحليلها، ومراقبتها وتتبعها واتخاذ قرارات ذكية باستمرار[20,24].

مزايا إنترنت الأشياء :

1. البيانات: يوفر إنترنت الأشياء كمًا هائلًا من المعلومات التي تساعدنا على اتخاذ القرارات الصائبة في الوقت المناسب.
2. الوقت: توفر تقنية إنترنت الأشياء الكثير من الوقت من خلال توفير معلومات دقيقة في الوقت المناسب وبأسرع وقت.
3. اقتصادية: تعُد تقنية إنترنت الأشياء اقتصادية للغاية، وذلك حسب سيناريوهات التطبيق.
4. التتبع: يساعد إنترنت الأشياء في تتبع أو مراقبة مختلف الأشياء المادية، مما يوفر الوقت والمال.
5. يسُهم بشكل كبير في توفير الوقت والجهد والمال، من خلال تمكين الفرد والمؤسسة من التحكم عن بعُد في الأشياء لتنفيذ ما هو مطلوب منها بدقة ، بالإضافة إلى إمكانية فهم الأشياء فيما بينها من خلال أجهزة استشعار تتواصل مع بعضها البعض عبر الإنترنت و ، قد حقق ذلك نتائج عديدة ساهمت في توفير الوقت والجهد والمال.
6. يتحرر الإنسان من قيود الزمان والمكان، حيث يستطيع إدارة الأمور والتحكم فيها عبر بروتوكول الإنترنت دون الحاجة إلى التواجد في نفس المكان؛ ودون تدخله المباشر في كثير من الأحيان، إذا أعطى تعليمات مسبقة.[1]

تعد الهجمات على البنى التحتية للشبكات من أكبر المشكلات التي تواجه الشبكات في العالم اليوم.

فمع النمو السريع للأنشطة غير القانونية في الشبكات أصبحت أمنية الشبكات تحديًا كبيرًا لا يمكن اعتباره محلولاً بالكامل بعد.

في البدايات كانت جدران الحماية(Firewalls) هي خط الدفاع الرئيسي والوحيد لحماية الشبكات غير أن أول هجوم واسع الانتشار على الإنترنت وقع في عام 1988 بواسطة (Morris Worm) التي استهدفت برنامج .Sendmail

من ذلك الوقت ظهرت العديد من الأساليب للتغلب على هذه الثغرات وتوفير حماية أفضل للشبكات.

في البداية كانت من أكثر الطرق الشائعة لدى الشركات الموردة للأجهزة أن ترسل اسم المستخدم وكلمة المرور الإفتراضيين مع الأجهزة لتقليل خطر الاختراق.

و للمرة الأولى في منتصف الثمانينيات نشرت أبحاث (Denning) حول كشف التطفل حيث افترضت أن الأنشطة التطفلية تختلف عن الأنشطة العادية وأن الدور الأساسي لنظام كشف التطفل (IDS) هو اكتشاف النماذج المناسبة للسلوك الطبيعي بحيث يمكن التمييز بسهولة بين النشاط المشروع و النشاط التخريبي.

إن كشف التطفل اليوم يعتبر من أحدث وأهم مجالات البحث في شبكات الحاسوب و مازال قيد الدراسة المستمرة وقد تم تطوير العديد من النماذج الأولية التي تعمل على مناهج مختلفة للتطبيقات التجارية والعسكرية.

يستند نظام كشف التطفل إلى الدمج بين تقنيات الكشف عن التطفل وتقنيات الـ Brute Force. في الوقت الحالي يعد نظام كشف التطفل (IDS)جزء أساسي من منظومة أمن الشبكات لأنه يوفر حماية شاملة للشبكة من خلال قدرته على التعرف على كل محاولات التطفل الناجحة وغير الناجحة. وتتمثل وظيفة نظام كشف التطفل IDS في رصد جميع السلوكيات غير الطبيعية في النظام و استبعاد الأنشطة التي لا تعتبر هجمات من خلال دراسة معمقة لأنماط وسلوكيات الهجمات والتواقيع المرتبطة بها لذا يمكن لنظام كشف التطفل IDS أن يقدم استجابة فورية لمثل هذه الحوادث.

كما يمكن لنظام كشف التطفل أداء المهام التالية:

1.مراقبة أنشطة النظام والمستخدمين.

2.التحقق من أخطاء النظام.

3.تقييم سلامة الأنظمة وملفات البيانات.

4.تسجيل أي سلوك غير طبيعي وحفظه كسجلات إحصائية.

5.التعرف على الأنشطة التطفلية ورسم خرائط الهجمات المعروفة وتوليد التنبيهات المناسبة. [2]

لقد أصبحت أنظمة كشف التطفل(IDS) مقبولة كإضافة ضرورية إلى البنية التحتية الأمنية في كل مؤسسة. ورغم المساهمات الموثقة التي تقدمها تقنيات كشف التطفل في تعزيز أمن الأنظمة ما زال يتعين تبرير اقتناء هذه الأنظمة . وهناك عدة أسباب مقنعة تدفع إلى اعتماد واستخدام IDS :

1. منع السلوكيات الضارة من خلال زيادة الشعور بمخاطر الاكتشاف والعقوبة لمن يحاولون مهاجمة النظام أو إساءة استخدامه.
2. كشف الهجمات والانتهاكات الأمنية الأخرى التي لا تتمكن وسائل الحماية الأخرى من منعها.
3. التعرف على البدايات الممهدة للهجمات والتي غالبًا ما تظهر على شكل محاولات فحص الشبكات.
4. توثيق التهديدات التي قد تواجه المؤسسة.
5. العمل كأداة لمراقبة التصميم الأمني والإدارة الأمنية خصوصا في المؤسسات الكبيرة والمعقدة.

6. توفير معلومات مهمة حول الهجمات التي تقع بما يسمح بتحسين التشخيص ودعم الاستجابة والتعافي وتصحيح العوامل المسببة. [3]

المشكلة العلمية:

شهدت المنازل الذكية في السنوات الأخيرة انتشارًا واسعًا بفضل الاعتماد على أجهزة إنترنت الأشياء مثل الكاميرات الذكية، الأقفال الإلكترونية، الحساسات، والمساعدات الصوتية. ورغم ما تقدمه هذه الأجهزة من مزايا تتعلق بالراحة والأتمتة وكفاءة استهلاك الموارد، فإنها تفتح في الوقت نفسه سطح هجوم واسع أمام المخترقين . وقد أثبتت هجمات فعلية مثل برمجية Mirai botnet أو اختراق أجهزة مراقبة الأطفال مدى هشاشة بيئة المنازل الذكية من الناحية الأمنية.[4]

تعود خطورة هذه المشكلة إلى عدة أسباب؛ أبرزها أن أجهزة إنترنت الأشياء تمتلك قدرات محدودة من حيث العتاد والذاكرة، مما يجعل من الصعب تثبيت برامج الحماية التقليدية مثل مضادات الفيروسات أو تلقي التحديثات الأمنية بشكل مستمر . بالإضافة إلى ذلك، فإن تعدد الشركات المصنعة واختلاف بروتوكولات الاتصال يؤدي إلى غياب معايير موحدة للأمن. [4] كما أن معظم المستخدمين النهائيين يفتقرون إلى الخبرة التقنية الكافية للتعامل مع الاختراقات عند حدوثها.

أما أنظمة كشف التطفل التقليدية (IDS)، فهي غير ملائمة بالكامل لهذه البيئات، إذ أن بعضها يحتاج إلى موارد عالية لا تتوفر في أجهزة إنترنت الأشياء، بينما يعجز بعضها الآخر عن التمييز بدقة بين أنماط الهجمات المختلفة مثل هجمات حجب الخدمة (SYN Flooding) أو هجمات انتحال العنوان (ARP Spoofing) أو هجمات إعادة الإرسال (. (HTTP Flooding

بناءً على ذلك، تتمثل مشكلة البحث العلمية في غياب آليات كشف تطفل خفيفة وفعّالة ومصممة خصيصًا لبيئة المنازل الذكية، بحيث تكون قادرة على العمل ضمن القيود المفروضة على أجهزة إنترنت الأشياء، وفي الوقت نفسه تحقق قدرة عالية على التعرّف على مختلف أنواع الهجمات بدقة وكفاءة. [4]

الدراسة النظرية :

في هذا القسم سيتم عرض بعض الأبحاث السابقة التي قام بها باحثون في الموضوع المشترك بين كشف التطفل وإنترنت الأشياء ضمن المنازل الذكية حيث:

فقد قام أشرف وآخرون [5] بمراجعة شاملة لأنظمة كشف التطفل في إنترنت الأشياء باستخدام تقنيات التعلم الآلي والتعلم العميق، حيث ناقشوا التحديات والحلول والاتجاهات المستقبلية. وأكّدوا على الحاجة إلى طرق كشف فعّالة ودقيقة، لكنهم لم يقترحوا بنية أو تطبيق عملي محدد. أما في البحث قام شابوني وآخرون [6] باستعرض تقنيات كشف التطفل في شبكات إنترنت الأشياء اعتمادًا على خوارزميات التعلم، وركّزوا بشكل خاص على أمن المنازل الذكية. وقد حللوا بشكل مفصل الأعمال الحديثة في مجال التعلم الآلي، لكنهم لم يتطرقوا إلى قضايا تصميم البنية مثل القدرة على التكيّف ومتطلبات العمل في الزمن الحقيقي.

في البحث قدم الباحث التان [7] تطبيقًا للتعلم العميق في كشف التطفل ضمن أنظمة الاستشعار الخاصة بإنترنت الأشياء الصناعي. ورغم أهميته للتطبيقات الصناعية، إلا أنه قد لا يناسب البيئات المنزلية الذكية بسبب اختلاف القيود التشغيلية وأساليب الهجوم. بينما في هذا البحث اقترح سالاي [8] إطارًا متكاملًا متعدد الطبقات لكشف التطفل في إنترنت الأشياء، وطُبّق في المجال الصناعي، لكنه لم يوضح تفاصيل تصميم البنية أو كيفية النشر. جميع هذه الدراسات أشارت إلى أن أغلب الطرق الحالية تتجاهل قيود إنترنت الأشياء المهمة مثل: زمن الاستجابة المنخفض، تغيّر سلوك الأجهزة باستمرار، وقلة الموارد، وهي عوامل مؤثرة على قابلية التطبيق على نطاق واسع.

أما في هذا البحث ناقشت لين وآخرون[9] كشف التطفل في الحوسبة الضبابية وحوسبة الحافة المتنقلة، وهو عمل مهم خاصة مع ازدياد استخدام هذه التقنية في المنازل الذكية، لكنهم لم يتطرقوا إلى دور التعلم الآلي في الكشف وهذا لا يمكن الاستفادة منه في بحثنا. قدم الباحث لوكاس [10] نظامًا ذاتي التهيئة لكشف التطفل في المنازل الذكية باستخدام التعلم المعزز، حيث يتميز بقدرته على التكيّف مع الظروف المتغيرة وهو خطوة مهمة نحو أنظمة أمنية أكثر ديناميكية واستجابة. تناول الباحث الالادي [11] نهجًا هجينًا يعتمد على "الجهاز المناعي الاصطناعي" لكشف التطفل في شبكات المنازل الذكية، وأبرزت قوة خوارزمية ELM في سرعة التعلم والتعميم، لكنه لم يركز في هذه الدراسة على جانب العمل في الزمن الحقيقي.

دمج روسلي و آخرون في هذا البحث [12] بين الشبكات المعرفة برمجيًا، والتعلم الآلي، ومعيار أوصاف استخدام المصنّع (MUD) مع نظام كشف ومنع التطفل لدراسة تأثيره على أمن الشبكة. ورغم أن إدخال هذه المعايير خطوة مهمة، إلا أن العمل اقتصر على مجال التصنيع ولم يدرس فعالية البنية أو خصائص حركة مرور الشبكة.

بالنسبة لتحليل حركة البيانات، فقد أوضح الباحث ابراهيم واخرون [13] أهمية فهم طبيعة بيانات إنترنت الأشياء ونماذج الاندفاعات المفاجئة في الاستخدام، واقترح نموذجًا متقدمًا يعتمد على وضعيات ON/OFF لتغطية المدن الذكية. ومع ذلك، لم يتناول البحث تصميم البنية أو آلية النشر. بينما في هذه الدراسة قدم Kumar في [14] رؤى حول خصائص حركة مرور إنترنت الأشياء في المنازل الذكية والحرم الجامعي، وأظهرت أن معظم الأجهزة تعمل بشكل دوري مع فترات خمول طويلة، وتنتج كمية صغيرة من البيانات وتتواصل غالبًا مع عدد محدود من الخوادم البعيدة (غالبًا في نفس بلد الجهاز). كما اكتشف البحث مشكلات في الأمن والخصوصية مثل التواصل عبر قنوات غير مشفّرة أو مع خوادم في دول مشهورة بمخاطر الخصوصية.وبناءً على ذلك، يهدف هذا البحث إلى تصميم وبناء نظام كشف تطفل مرن وقابل للتوسع،

يضمن الحماية بكفاءة في البيئات الحقيقية للمنازل الذكية، دون فقدان القدرة على التكيّف والتعميم وهذا البحث نستطيع الاستفادة منه في موضوعنا من خلال تحليل حركات المرور بين اجهزة IoT .

في ما يلي ملخص لما سبق :

الجدول 1-1: ملخص الأوراق البحثية السابقة.

اسم الورقة البحثية	التاريخ	الموضوع	النتائج	الاستفادة في موضوعنا
A review of intrusion detection systems using machine and deep learning in Internet of things: Challenges, solutions and future directions.	2020	مراجعة شاملة لأنظمة كشف التطفل باستخدام التعلم الآلي والتعلم العميق.	أكدوا أهمية طرق كشف فعّالة لكن لم يقدموا تصميم أو تطبيق عملي	يفيد كبنية نظرية لكن لا يوجد فيه تطبيق عملي يمكن البناء عليه.
Network intrusion detection for IoT security based on learning techniques.	2019	استعراض تقنيات كشف التطفل في شبكات إنترنت الأشياء اعتمادًا على خوارزميات التعلم، مع تركيز على أمن المنازل الذكية. ا	تحليل مفصل للأعمال الحديثة، لكن لم يناقش متطلبات الزمن الحقيقي.	يفيد كمصدر لتحديد التحديات الحالية في المنازل الذكية، لكنه لا يعطي حلول قابلة للتطبيق في هذا المشروع.

محدود الفائدة، لكن يمكن الاستفادة من آلية استخدام التعلم العميق كمقارنة مع نموذجنا.	مفيد للصناعة، غير مناسب للمنازل بسبب اختلاف طبيعة الهجمات والموارد.	تطبيق للتعلم العميق في كشف التطفل في IoT الصناعي.	2021	A deep learning application for invasion detection in industrial Internet of things sensing systems
يفيد كفكرة "تعدد الطبقات"، ممكن تطبّقها في مشروعنا (Snort + AI = طبقتين).	طُبق في الصناعة، بدون تفاصيل تصميم أو نشر.	إطار متعدد الطبقات لكشف التطفل في IoT.	2023	An integrated multilayered framework for IoT security intrusion decisions
يناقش الأمور الصناعية لا يفيد المشروع لأنه خارج الموضوع الاساسي	لم يستخدموا تعلم آلي	كشف التطفل في الحوسبة الضبابية.	2018	Sample selected extreme learning machine-based intrusion detection in fog computing and MEC. Wireless Communications and Mobile Computing
مهم جدًا لأنه قريب من بيئة المشروع (منازل ذكية)، يمكن الاستفادة منه عند شرح أهمية الأنظمة المتكيفة.	يتكيف مع الظروف المتغيرة، خطوة مهمة للأنظمة الديناميكية.	نظام ذاتي التهيئة باستخدام التعلم المعزز للمنازل الذكية.	2020	Self configurable cyber-physical intrusion detection for smart homes using reinforcement learning
			2020	Intrusion detection system in smart home network

using artificial immune system and extreme learning machine hybrid approach		جهاز مناعي اصطناعي + خوارزمية ELM لكشف التطفل.	سريع في التعلم والتعميم، لكن بدون زمن حقيقي.	يفيد من حيث طرح نهج هجين (Snort + AI). لكن عيبه نفس مشكلة الزمن الحقيقي.
SDN based intrusion detection and prevention systems using manufacturer usage description: a survey	2020	دمج SDN + ML + معيار MUD لكشف ومنع التطفل.	ركز على التصنيع، ما درس فعالية البنية في المنازل.	محدود الفائدة، لكن يمكن الاستفادة من دمج المعايير والبنى المختلفة.
Traffic modelling of smart city internet of things architecture.	2020	تحليل طبيعة بيانات IoT ونموذج ON/OFF للمدن الذكية.	مهم لفهم خصائص حركة المرور، لكنه ما يناقش الكشف.	يفيد جدًا في جانب تحليل حركة مرور الشبكة على 3NS، خصوصًا في توليد سيناريوهات حركة IoT واقعية.
Characterizing IoT traffic in smart home and campus environments	2020	خصائص حركة مرور IoT في المنازل الذكية والجامعات.	وجد أن الأجهزة ترسل بيانات قليلة وتتواصل مع خوادم محلية، مع مشاكل أمنية.	يعطي بيانات فعلية لطبيعة حركة المرور في المنازل الذكية، ويمكن الاستفادة منها في بناء سيناريوهات NS3.

الجدول 2-1: التطبيقات على أنظمة كشف التطفل في سياقات إنترنت الأشياء.

قطاع إنترنت الأشياء	شرح مختصر
أمن المنازل الذكية	يركز على تعزيز التدابير الأمنية في المنازل الذكية من خلال الكشف التكيفي عن التهديدات والاستجابة الفورية للتهديدات المتنوعة مثل هجمات حجب الخدمة الموزعة والهجمات الإلكترونية.
إنترنت الأشياء الصناعي	يناقش عملية صنع القرار المعقدة وتحسين العمليات في أنظمة إنترنت الأشياء، ومعالجة التحديات الأمنية عالية المخاطر.
أنظمة إنترنت الأشياء للرعاية الصحية	يطبق (Deep Reinforcement Learning) DRL لضمان الدقة والخصوصية الحرجة، والتكيف مع الطبيعة الحساسة لبيانات وعمليات الرعاية الصحية.
أنظمة النقل	يعزز الأمن في النقل من خلال إدارة البيئات الديناميكية وتأمين شبكات المركبات عالية السرعة ضد الهجمات المتطورة.
المدن الذكية	يستخدم(Deep Reinforcement Learning) DRL لإدارة أنظمة تكنولوجيا المعلومات و الاتصالات المعقدة و تحسين الأمن عبر شبكات المدن الكثيفة، وتعزيز بروتوكولات الاتصال على مستوى المدينة.
أمن إنترنت الأشياء العام	يستكشف التطبيق الأوسع ل (Deep Reinforcement Learning)عبر مختلف مجالات إدارة البيانات مع التركيز على التعلم التكيفي وتحسينات الأمان في سياقات تشغيلية متنوعة.

التحديات التي تواجه أنظمة كشف التطفل:

تجري دراسات مستمرة حول أنظمة جديدة للكشف التلقائي عن الاستخدامات غير الطبيعية للأنظمة. إضافةً إلى ذلك، أشار الباحثون إلى تطوير نموذج للكشف عن التطفل، واقترحوا كإطار عمل لنظام كشف التطفل (IDS)) عام الاستخدام [16]. منذ ذلك الحين، قام الخبراء بتطوير وتطبيق عدة خوارزميات لأتمتة عملية الكشف عن التطفل في الشبكات. كما سعوا باستمرار إلى ابتكار طرق أكثر دقة وأسرع وأكثر قابلية للتوسع لهذا الغرض. ومع قدوم عصر إنترنت الأشياء (IoT) و البيانات الضخمة، كان من المتوقع أن يتجاوز عدد الأجهزة المتصلة 26 مليار جهاز بحلول عام 2020 [17] ومع هذا التوجه، من المتوقع أيضًا أن يزداد نوع وعدد قضايا الأمن السيبراني. حيث يلخص الشكل (1) لتحديات في أنظمة كشف التطفل (IDS). وتشمل هذه التحديات: معدل الإنذارات الكاذبة، انخفاض معدل الكشف، عدم توازن مجموعات البيانات، وزمن الاستجابة .

وقد دعا بعض الباحثين مؤخرًا إلى تقسيمات إضافية لأنظمة كشف التطفل. على سبيل المثال، ذكر وا [18] أن أنظمة كشف التطفل IDS يجب أن تصُنّف إلى خمس فئات فرعية يمكن أن تنتمي لأي من الفئات السابقة. والفئات المقترحة هي: المعتمدة على الأنماط، المعتمدة على القواعد، المعتمدة على الإحصاء، المعتمدة على الحالة، والمعتمدة على الاستدلال (heuristic-based). إلا أن مثل هذا التصنيف قد يؤدي إلى إرباك بسبب أوجه التشابه بين نقاط قوة التقنيات المختلفة ، بالإضافة إلى غياب معايير واضحة لتمييز تقنية عن أخرى. غالبًا ما ترتبط أنظمة الكشف المعتمدة على التوقيعات أو القواعد بنسبة معينة من الإنذارات الكاذبة (FP- false positive)، كما أنها غير قادرة على اكتشاف أشكال جديدة من الهجمات [19] ومن المتوقع أن تظهر أنظمة كشف تطفل ((IDS

بمستوى عال من اكتشاف الإنذارات الكاذبة. أما الأنظمة المعتمدة على تحليل البروتوكولات بالحالة (stateful protocol analysis)، فإن أداء الكشف لديها يختلف باختلاف مستوى تعريف ملفاتها الشخصية [20]. ويتمثل التحدي الأكبر في هذا النهج في الحفاظ على تحديث مستمر لهذه الملفات مع تطور البروتوكولات بمرور الوقت.

وكما نوقش سابقًا، فإن هذه الدراسة تركز على تطوير نظام كشف تطفل معتمد على الشذوذ (anomaly-based IDS) يتميز بدقة جيدة ومعدل إنذارات كاذبة منخفض. وقد أجُريت العديد من الدراسات حول تقليل الإنذارات الكاذبة في نظام كشف التطفل IDS. حيث قدّر الخبراء أن حوالي 99% من تنبيهات الكشف عن التطفل لا تتعلق بمشاكل أمنية حقيقية، وذلك بسبب الفروقات البسيطة المرصودة بين الأنشطة العادية والأنشطة الخبيثة[21]. كما أشاروا إلى تحديات أخرى، مثل تطوير توقيعات دقيقة تستطيع اكتشاف السلوك غير الطبيعي دون أن تطُلق إنذارات أثناء الأنشطة العادية، إذ قد يسُمح ببعض الأنشطة في حالات معينة بينما تعُتبر تطفلًا في حالات أخرى.

واقترحوا نهج المتعلم التكيفي لتصنيف التنبيهات ALAC في[22]، والذي يعتمد على تقنيات التعلم الآلي (ML-machine learning) مقترنة بتدريب يعتمد على الملاحظة البشرية للتعلم التكيفي لقواعد التصنيف الضمنية. وبسبب تدخل العامل البشري أثناء التدريب، يمكن لنظام ALAC أن يتم تحديثه تدريجيًا مع تغير الظروف، فإن التحديات الرئيسية لأنظمة كشف التطفل المعتمدة على الحالات الخاصة تتمثل في أن بناء نظام بخصائص كهذه يصبح أكثر تعقيدًا في حالة كشف سوء الاستخدام [23]. بالإضافة إلى ذلك، يرتفع معدل الإنذارات الكاذبة مع انخفاض معدل الكشف. وهناك أيضًا مشكلة عدم توازن البيانات، والتي تؤثر بشكل مباشر على تقييم النماذج [19].

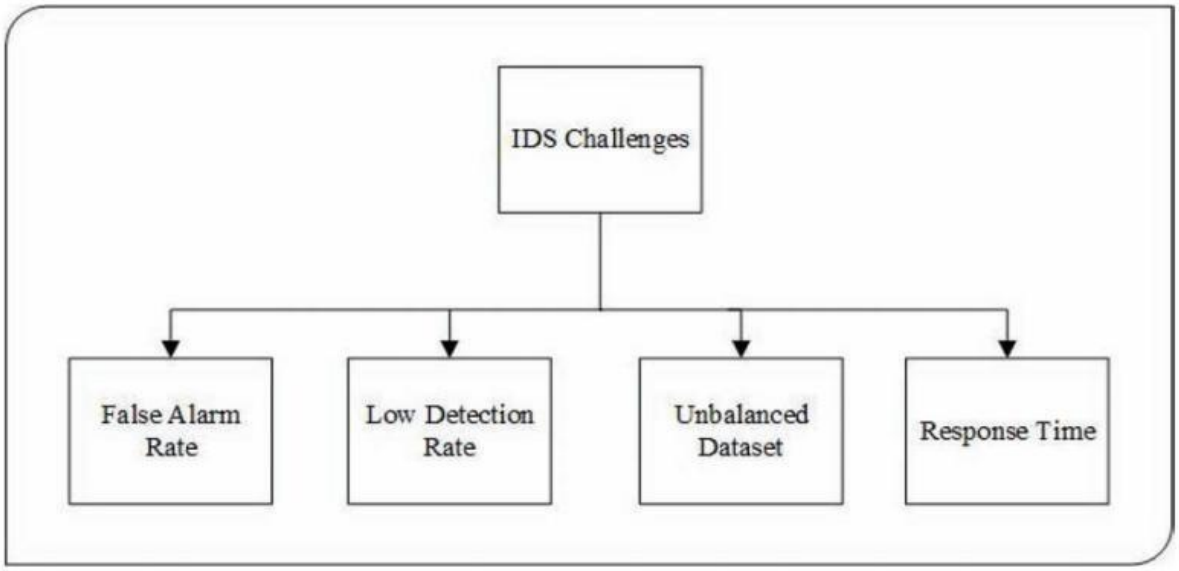

الشكل 1-1: التحديات التي تواجه أنظمة كشف التطفل.

الفصل الأول :الدراس المراجعية

القسم الاول: انترنت الأشياء

إن إنترنت الأشياء (IoT) يخلق عالماً جديداً ـ عالماً قابلاً للقياس والرصد ـ يستطيع فيه الناس إدارة حياتهم بشكل أفضل، وتتمكن المدن من إدارة بنيتها التحتية بكفاءة أكبر، وتتمكن الشركات من إدارة أعمالها بفاعلية أعلى كما ان هذا العالم الذكي المتصل سيقدم تغييرات جوهرية للمستهلكين وللمجتمع، كما سيُحدث تحولاً عميقاً في صناعات كاملة. إن صعود إنترنت الأشياء سيحقق العديد من التحسينات المهمة في عالمنا وحياتنا اليومية من خلال مساعدتنا على اتخاذ قرارات أفضل وبشكل أسرع اعتماداً على معلومات آنية وذات جودة أعلى.

ما هو إنترنت الأشياء؟

لفهم إنترنت الأشياء، من المفيد أن نعيد بسرعة تتبّع كيفية تطور الإنترنت ككل.

بدأ الإنترنت كشبكة صغيرة نسبياً من الحواسيب العسكرية والحكومية الموصولة عبر اتصالات سلكية. ومع مرور الوقت، توسّع الإنترنت وأصبح متاحاً لملايين الأشخاص حول العالم، وجعلت شبكة الويب العالمية من الممكن لأي شخص نشر المعلومات للاطّلاع العام. جاءت القفزة التالية مع الانتشار السريع للاتصالات اللاسلكية. وبمساعدة شبكات Wi-Fi والاتصالات الخلوية، حدث توسّع هائل. فقد حررت الهواتف الذكية والأجهزة المحمولة المتصلة بالإنترنت الوصول إلى الشبكة من أماكن محددة، مما جعلها متاحة تقريباً في كل مكان.

لكن لم تكن الحواسيب وحدها هي التي تستخدم الإنترنت، بل بدأت العديد من أنواع الأجهزة الأخرى تتضمن قدرات بسيطة للحوسبة والشبكات. في أوائل العقد الأول من الألفية الجديدة ظهر مصطلح إنترنت الأشياء (IoT) لوصف النطاق المتزايد باستمرار من الأشياء المتصلة بالإنترنت واستخداماتها. وفي عام 2005، اعترف الاتحاد الدولي للاتصالات (ITU) رسمياً بهذا المصطلح. ويعرّف الاتحاد إنترنت الأشياء بأنه: "يتألف من أشياء ذكية تتصل بالإنترنت وتتواصل مع بعضها البعض بحد أدنى أو دون أي تدخل بشري."

عادةً ما تتصل هذه الأشياء عبر بوابة (Gateway) بمنصة إنترنت الأشياء، التي تتكون من أدوات وخدمات برمجية تجمع البيانات من أجهزة الاستشعار (Sensors) والمتحكمات (Controllers) والأجهزة الأخرى.

اليوم يتمحور إنترنت الأشياء (IoT) حول ربط العديد من أنواع الأجهزة المختلفة بالإنترنت، مثل أجهزة الاستشعار، ووحدات التحكم الصوتية (Hands-free controllers)، وأجهزة المراقبة عن بُعد. ووفقاً لشركة Cisco، فقد

تجاوزنا بالفعل المرحلة التي أصبح فيها عدد "الأشياء" أو الأجهزة المتصلة بالإنترنت أكبر من عدد الأشخاص ـ وفي الواقع، لقد تجاوزنا هذه المرحلة منذ أكثر من عشر سنوات.

يوضح الشكل 2-1 ما يحدث بشكل عام. في طبقة الاستشعار والاتصال (Sense & Connect Layer)، تقوم المنصة بربط عتاد إنترنت الأشياء بالتطبيقات الشبكية التي تنفذ عمليات معالجة البيانات وتخزينها. في المنتصف توجد طبقة المنصة (Platform Layer)، حيث تُخزَّن البيانات وتُؤمَّن وتُعالج وتُحلَّل. أما في طبقة المستخدم النهائي (End-User Layer)، فهي ترتبط بالتطبيقات المخصصة للمستخدم النهائي، والتي تقوم بمراقبة وتفسير البيانات القادمة من أجهزة إنترنت الأشياء، ثم ترسل تعليمات تخبر الأجهزة بتنفيذ إجراءات مثل قفل باب منزلك أو رفع باب المرآب.

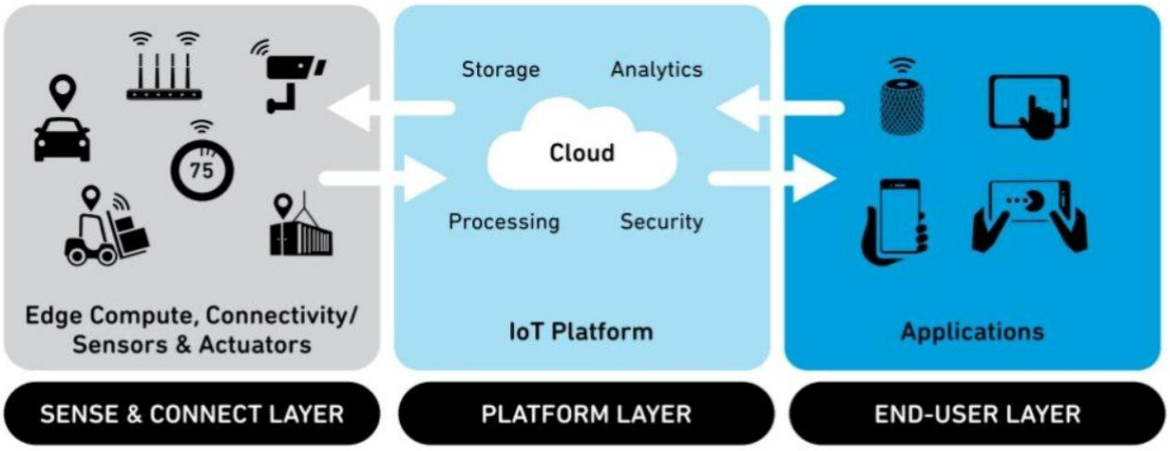

الشكل 2-1: طبقات إنترنت الأشياء.

توفر منصات إنترنت الأشياء (IoT Platforms) عادةً خدمات تتميز بـ:

القدرة على التكيف (Adaptable): يمكن لأنظمة إنترنت الأشياء التكيف ديناميكياً مع تغيّر السياقات، بحيث تتصرف وفقاً لظروف التشغيل أو مدخلات المستخدم أو المعلومات المستشعرة.

هوية فريدة (Uniquely identifiable): يمتلك كل جهاز من أجهزة إنترنت الأشياء هوية فريدة، مثل عنوان بروتوكول الإنترنت (IP address). وتتيح هذه العناوين للمستخدمين الاستعلام عن الجهاز، ومراقبته، والتحكم به عن بُعد.

التكوين الذاتي (Self-configurable): يمكن للأجهزة ضمن شبكة إنترنت الأشياء أن تقوم بتكوين نفسها تلقائياً، مما يسمح للعديد من الأجهزة المتصلة بالتعاون فيما بينها لتوفير وظائف النظام الكاملة.

التكامل الشبكي (Network integrated): يتم دمج أجهزة إنترنت الأشياء في شبكة إنترنت الأشياء لتمكين الاتصال بين العقد (Nodes)، والبوابات (Gateways)، والبنية التحتية.

اتخاذ القرارات الذكية (Intelligent decision making): تستطيع أجهزة إنترنت الأشياء اتخاذ قرارات تمكّنها من التكيف مع الظروف المتغيرة.

تحديد المعايير اللاسلكية التي تمكّن إنترنت الأشياء :

تُستخدم حالياً مجموعة واسعة من معايير تقنيات الاتصال اللاسلكي لربط أجهزة إنترنت الأشياء. بعض هذه المعايير مألوف مثل Bluetooth و Wi-Fi و Zigbee، بينما يعتمد بعضها الآخر على حلول خاصة أقل شيوعاً. يلخّص الشكل 3-1 المشهد الحالي، حيث يقسّمه إلى ثلاثة أقسام بناءً على النطاق (Range). وكما هو موضح في الشكل، أصبحت منظومة إنترنت الأشياء معقداة وصعبة الإدارة من منظور المستخدم بسبب كثرة المعايير المختلفة المستخدمة.

عادةً ما تختار الشركات التي تصنع منتجات إنترنت الأشياء المعيار (أو مجموعة المعايير) المراد استخدامها بناءً على النطاق ونوع البيانات. فعلى سبيل المثال، قد تحتاج هذه الأجهزة إلى نقل محتوى وسائط (Media Content) أو بيانات الاستشعار والتحكم (Sense-and-control data). ومع وجود مجموعة كبيرة من المعايير القياسية للاختيار منها، بالإضافة إلى بعض الحلول الخاصة (Proprietary)، يمكن لمصممي الأنظمة اختيار التقنية الأنسب لتحسين أداء أجهزة المستخدم النهائي. لكن هذا لا يجعل الأمور دائماً سهلة بالنسبة للمستخدم العادي.

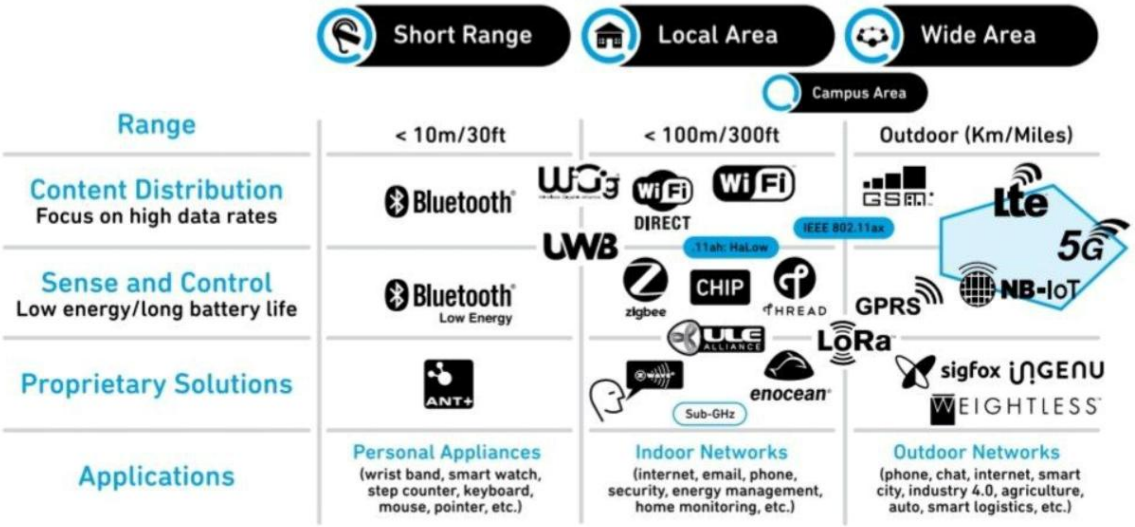

الشكل 3-1: المراحل المبكرة لإنترنت الأشياء.

الهدف: قابلية التشغيل البيني (Interoperability)

تشير قابلية التشغيل البيني إلى قدرة منتج أو نظام ما على العمل مع منتجات أو أنظمة أخرى، سواء في الوقت الحاضر أو في المستقبل، دون أي قيود.

يرغب المستهلكون في أن تتواصل جميع أجهزتهم المنزلية اللاسلكية معاً بطريقة "التوصيل والتشغيل" (Plug-and-Play)، دون الحاجة إلى عناء التأكد من أن جهاز إنترنت الأشياء الجديد الذي يرغبون بشرائه سيعمل مع شبكتهم الحالية. فهم يريدون أن يتمكنوا من شراء أي منتج لاسلكي ويعمل تلقائياً. لكن، اليوم، هذا غير ممكن.

فعلى سبيل المثال، يصبح شراء قفل باب ذكي أو لمبة إضاءة متصلة بالإنترنت أمراً معقداً، لأن المستخدم بحاجة إلى التفكير بكيفية تواصل هذا الجهاز مع الأجهزة المنزلية الأخرى، بما في ذلك تلك التي تستخدم Alexa أو Google Assistant أو Siri.

بعض الشركات المصنعة تعتمد على المعايير اللاسلكية الأساسية لتأمين الاتصال، لكنها تضيف حلولاً خاصة بها (Proprietary Solutions) للتحكم والتفاعل مع أجهزة إنترنت الأشياء. غير أن هذا النهج له ثمن، خصوصاً بالنسبة للمستخدمين الذين يواجهون صعوبة أثناء عملية الشراء أو التثبيت، لأن أجهزتهم الجديدة لا تندمج بسهولة كما كانوا يتوقعون مع شبكتهم الحالية.

فحص بنية إنترنت الأشياء (IoT Architecture) :

بعض تطبيقات إنترنت الأشياء أصبحت واقعاً بالفعل، مثل القدرة على التحكم في منظم حرارة المنزل لاسلكياً أو استخدام الهاتف لفتح أبواب السيارة. لكن التطبيقات المستقبلية المحتملة لإنترنت الأشياء أوسع وأكبر بكثير.

هذه التطبيقات المستقبلية ستتطلب منصات بنية لإنترنت الأشياء قادرة على تنفيذ عمليات ضخمة من نقل البيانات ومعالجتها في الخلفية.

تتألف منصة/معمارية إنترنت الأشياء (IoT Platform/Architecture) من عدة طبقات مترابطة داخلياً (انظر الشكل 1-1). فيما يلي نظرة أقرب على المكوّنات الفردية الموجودة ضمن هذه الطبقات:

المستشعرات والمشغلات (Sensors and Actuators): تقوم مستشعرات ومشغلات إنترنت الأشياء بقياس عناصر مثل درجة الحرارة، الصوت، الرطوبة، والاهتزاز.

في منزل ذكي نموذجي، يحتوي جهاز ذكي مثل منظم الحرارة (Thermostat) على وحدة اتصال مدمجة تتصل بشبكة المنزل. تقوم هذه المستشعرات والمشغلات بتحويل هذه القياسات الفيزيائية إلى قيم كهربائية تُشغّل النظام.

بوابات إنترنت الأشياء (IoT Gateways): تعمل البوابة على نقل البيانات بين الشبكة المحلية والإنترنت. حيث تُستقبل القيم الكهربائية من المستشعرات والمشغلات ثم تُرفع إلى الشبكة المحلية باستخدام بروتوكولات شبكية مثل Bluetooth، أو Bluetooth Low Energy (BLE)، أو Cellular، أو LoRaWAN، أو Thread، أو Wi-Fi، أو Zigbee. تنشئ البوابة عموداً فقرياً شبكياً مترابطاً (Meshed Backbone) لتوزيع البيانات المجمّعة وإرسال الاستجابات إلى الأجهزة.

منصة إنترنت الأشياء السحابية (Cloud-based IoT Platform): يتم تخزين البيانات المرسلة عبر البوابة ومعالجتها ضمن منصة سحابية لإنترنت الأشياء أو في مراكز بيانات الشركة. ثم تُستخدم هذه البيانات لتنفيذ إجراءات ذكية واتخاذ القرارات.

التطبيقات (Applications): في النهاية، تُستخدم البيانات القادمة من أجهزة إنترنت الأشياء ضمن التطبيقات لمساعدة الأفراد أو المؤسسات على اتخاذ قرارات أفضل أو القيام بإجراءات محددة. تقوم هذه التطبيقات بدفع المعلومات من السحابة إلى تطبيقات على الهواتف الذكية أو الأجهزة اللوحية أو الحواسيب. تُعد طبقة التطبيقات الأهم بالنسبة

للمستخدمين لأنها تمثل واجهتهم مع شبكة إنترنت الأشياء، مما يمكّنهم من التحكم ومراقبة العديد من عناصر النظام، أحياناً بشكل لحظي (Real-time).

بروتوكولات إنترنت الأشياء (IoT Protocols)

تشكل بروتوكولات الاتصال العمود الفقري لأنظمة إنترنت الأشياء، حيث تربط أجهزة إنترنت الأشياء بالشبكة وفي النهاية بالتطبيقات والمستخدمين. تتيح هذه البروتوكولات . سواء كانت قائمة على معايير قياسية أو بروتوكولات خاصة (Proprietary) . تمرير البيانات بين الطبقات المختلفة لبنية إنترنت الأشياء، من خلال تحديد صيغ تبادل البيانات، وترميزها، وآليات عنونة الأجهزة، والطريقة التي تُوجَّه بها حزم البيانات من العقدة (Node) إلى الوجهة.

تتضمن منظومة إنترنت الأشياء مجموعة متنوعة من البروتوكولات التي تدعم الشبكات قصيرة المدى، والمحلية، وواسعة النطاق، وجميعها تتعايش معاً. وتتمتع كل تقنية بخصائص محددة من حيث النطاق (Range)، وقدرات الاستشعار والتحكم، والقدرة على نقل أنواع مختلفة من المعلومات (الشكل1-2).

معاً، يمكن لهذه التقنيات أن توفر تغطية سلسة عبر جميع النطاقات والقدرات اللاسلكية. فعلى سبيل المثال: يعمل Bluetooth بكفاءة في التطبيقات قصيرة المدى، بينما يُستخدم Narrowband IoT (NB-IoT) بشكل جيد في التطبيقات بعيدة المدى.

ملخص حول بعض بروتوكولات الشبكات الرئيسية:

معيار IEEE 802.15.4: هو مجموعة من معايير الشبكات الشخصية اللاسلكية منخفضة المعدل (LR-WPAN). توفّر هذه المعايير اتصالات منخفضة التكلفة ومنخفضة السرعة للأجهزة محدودة الطاقة. وهي تُشكل

الأساس للمواصفات الخاصة ببروتوكولات اتصال عالية المستوى مثل Zigbee. يُعد Zigbee شبكة متشابكة (Mesh Network) مصممة للعمل منخفض الاستهلاك للطاقة، وتُستخدم في المنازل الذكية وفي تطبيقات الطاقة الذكية الخاصة بالمرافق. يستند Zigbee إلى طبقة الفيزيائية (PHY) وطبقة التحكم بالولوج للوسط (MAC) من معيار IEEE 802.15.4.

Wi-Fi: هو مجموعة من معايير الاتصال اللاسلكي ضمن الشبكات المحلية (WLAN) التي وضعتها IEEE 802.11. يوفر Wi-Fi معدلات بيانات عالية لكل من البيئات الداخلية والخارجية، ويُعد واسع الاستخدام عالمياً.

Bluetooth: معيار مفتوح تديره مجموعة الاهتمام الخاصة بالبلوتوث (Bluetooth SIG). يُعتبر تقنية اتصال لاسلكي منخفضة التكلفة مناسبة لنقل البيانات بين الأجهزة المحمولة لمسافات قصيرة تتراوح بين 8 و 10 أمتار. يُستخدم في تطبيقات مثل بث الصوت، السيارات، مكبرات الصوت، وسماعات الرأس.

Bluetooth Low Energy (BLE): جزء من معيار البلوتوث صُمم خصيصاً لتقليل استهلاك الطاقة. غالباً ما تستخدم أجهزة BLE بطاريات صغيرة من نوع (Coin Cell). يُستخدم BLE في أجهزة إنترنت الأشياء مثل المصابيح الكهربائية ومفاتيح الإضاءة.

Thread: تقنية شبكات متشابكة (Mesh Networking) آمنة ومنخفضة الاستهلاك للطاقة، قائمة على بروتوكولات الإنترنت، مخصصة لمنتجات إنترنت الأشياء.

في عام 2014،تم إنشاء مجموعة Thread Group لدعم اعتماد هذه التقنية. يدعم Thread معايير الاتصال الحالية القائمة على 6IPv ضمن شبكته المؤمنة والمنخفضة الطاقة.

LoRa: بروتوكول للشبكات واسعة النطاق منخفضة الطاقة (LPWAN) طُوّر من قبل LoRa Alliance. يُعد مثالياً لتمكين أجهزة الاستشعار في تطبيقات الزراعة واسعة النطاق بفضل قدرته على الاتصال لمسافات طويلة مع استهلاك منخفض للطاقة.

المعايير الخلوية (Cellular Standards): مثل الجيل الخامس (G5)، والتي توفّر العمود الفقري لشبكات إنترنت الأشياء، حيث تدعم كلّاً من معدلات البيانات العالية والاتصالات بعيدة المدى. من أكثر المعايير استخداماً في هذا المجال معيار NB-IoT، ويُستخدم في مواقف السيارات الذكية، وإدارة المرافق، وأتمتة عمليات التصنيع.

تُستخدم بروتوكولات المراسلة هذه لمشاركة البيانات عبر الأجهزة ومع السحابة. وتُعد بروتوكولات إنترنت الأشياء جزءًا أساسيًا من حزمة تقنيات إنترنت الأشياء، وبدونها لن تعمل الأجهزة المادية على الإطلاق. تمكّن بروتوكولات إنترنت الأشياء الجهاز من تبادل البيانات بطريقة مضبوطة وذات معنى.

على سبيل المثال، تُسمّى أجهزة إنترنت الأشياء "ذكية" لأنها لا تكتفي بالتحدث مع بعضها البعض، بل إذا واجهت مشكلات فإنها تستطيع تلقائيًا التخفيف من أثر المشكلة أو طلب المساعدة عبر الشبكة. إن هذا التفاعل لا يكون ممكنًا إلا من خلال بروتوكولات الاتصال أو اللغة المشتركة التي تُزوَّد بها أجهزة إنترنت الأشياء.

القسم الثاني: المنازل الذكية

في هذا القسم، سوف نتعمق في كيفية دعم إنترنت الأشياء للمنزل الذكي، وكيف تُمكّن الشبكات الشبكية / الموحدة ان تكون واحدة لكل غرفة من الاتصال بإنترنت الأشياء. كما أتناول بعض تحديات إنترنت الأشياء، وكيف تُساعد التطورات التكنولوجية الجديدة في معالجتها.

وضع المنازل الذكية اليوم :

شهد مفهوم المنزل الذكي رواجًا كبيرًا خلال السنوات القليلة الماضية، حيث طوّر المصنّعون مجموعة متنامية من الأجهزة التي يمكنها الاتصال بشبكات المنازل. تُمكّن شبكات المنازل الذكية أصحاب المنازل من استخدام الموارد بكفاءة، والتحكم في الأجهزة والأدوات باستخدام الأوامر الصوتية، واتخاذ القرارات بناءً على البيانات الواردة منها. وتتمتع المنازل الذكية بإمكانيات هائلة: إذ يُمكن استخدامها لتحسين كفاءة الطاقة، والراحة، والأمان، والترفيه، والرفاهية.

معظم المنازل الذكية اليوم مُجهزة بالعديد من أجهزة إنترنت الأشياء، والمحاور، وأجهزة الاستشعار التي تتواصل عبر شبكة/بوابة المنزل، وفي نهاية المطاف مع السحابة. ويمكن للمالك التحكم في كل ذلك من أي مكان في المنزل، أو حتى عن بُعد عبر الإنترنت.

قد تتضمن أنظمة المنازل الذكية العديد من معايير الاتصال اللاسلكي ذات الصلة بتطبيقات المنزل. يوضح الجدول خصائص بعض هذه المعايير والاختلافات بينها. علاوة على ذلك، قد تتكون هذه الشبكات المنزلية من عدة شبكات مترابطة تعمل تحت البوابة الرئيسية.

Wireless Protocol	Wi-Fi	Zigbee/Thread	Bluetooth
Standard	IEEE 802.11	IEEE 802.15.4	IEEE 802.15.1
Frequency band	2.4, 5, 6 GHz	2.4 GHz	2.4 GHz
Nominal range	150 meters	100 meters	10 meters
Data rate	11 Gbps	250 Kbps	1 Mbps

الشكل 4-1: معايير المنزل الذكي.

تتكون العديد من المنازل الذكية اليوم من مجموعة مخصصة من العقد. العقدة هي قطعة من الأجهزة لها عنوان فريد على الشبكة؛ ويمكن أن تكون العقدة إما جهازًا أو موزعًا:

» الأجهزة: عادةً ما يكون للجهاز (مثل منظم الحرارة أو مصباح كهربائي) اتصال واحد فقط بالشبكة. قد تحتاج الأجهزة إلى تتبع الوقت الفعلي أو لا، حسب وظيفتها.

» المحاور: المحور هو جهاز يدير حركة مرور الشبكة؛ قد يحتوي على العديد من الاتصالات لأنه يتصل بأجهزة متعددة. يجب أن تتبع المحاور الوقت الفعلي لإرسال الأحداث بكفاءة وفعالية.

» تتكون شبكة المحور الواحد من عقدة محور واحدة وعقدة جهاز واحدة أو أكثر. يدير المحور تبادل الأحداث والمعلومات بين الأجهزة في الشبكة. تحتوي شبكة المحاور المتعددة على أكثر من نوع واحد من المحاور، كما هو موضح في الشكل التالي. يحتوي مخطط الشبكة الموضح في الشكل التالي على محورين، يستخدم كل منهما بروتوكول شبكة مختلفًا (بلوتوث مقابل زيجبي). تتصل الأجهزة الفردية بأحد المحورين. ثم يتصل المحوران بالبوابة، التي يمكنها التواصل مع كليهما.

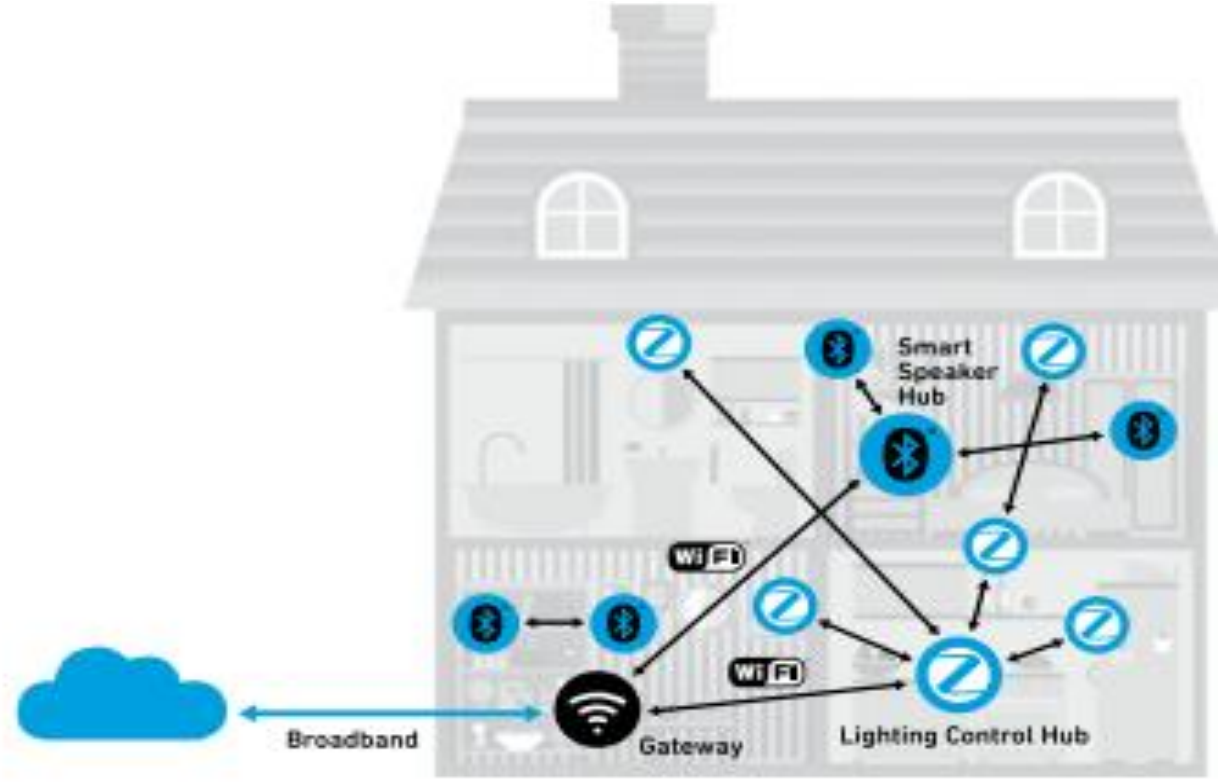

الشكل 5-1: منزل ذكي مع zigbee hub و Bluetooth hub.

الشبكة الشبكية / كبسولة واحدة لكل غرفة :

لإنشاء منزل ذكي أكثر اتصالاً بشبكة اتصالات أكثر موثوقية، يتجه المستهلكون نحو طوبولوجيا أحدث تُعرف بالشبكة الشبكية، والتي يُشار إليها أحيانًا باسم "كبسولة واحدة لكل غرفة". تُوسّع الشبكات الشبكية نطاقات الأجهزة اللاسلكية بسهولة، وتوفر معدلات بيانات عالية ومتسقة في جميع أنحاء المكاتب والمنازل، وحتى في الهواء الطلق. بالإضافة إلى ذلك، يُمكن للشبكات الشبكية التي تستخدم "كبسولة واحدة لكل غرفة" مع إمكانيات متعددة البروتوكولات أن تُقلل من تكلفة وجود أنظمة شبكية متعددة داخل المنزل.

تُعدّ الشبكات الشبكية تطورًا هامًا في تطور تقنية Wi-Fi، وخاصةً في المنازل الذكية. تتضمن أنظمة Wi-Fi الشبكية جهاز توجيه يتصل باتصال الإنترنت الرئيسي، وأجهزة أو عُقدًا شبيهة بجهاز التوجيه عبر الأقمار الصناعية، موزعة حول المنزل لتوفير تغطية كاملة لإنترنت الأشياء المنزلي بتقنية Wi-Fi (انظر الشكل).

توفر هذه الشبكات الشبكية المتطورة تكرارًا كاملاً، وتُحسّن أداء الشبكة إلى أقصى حد.

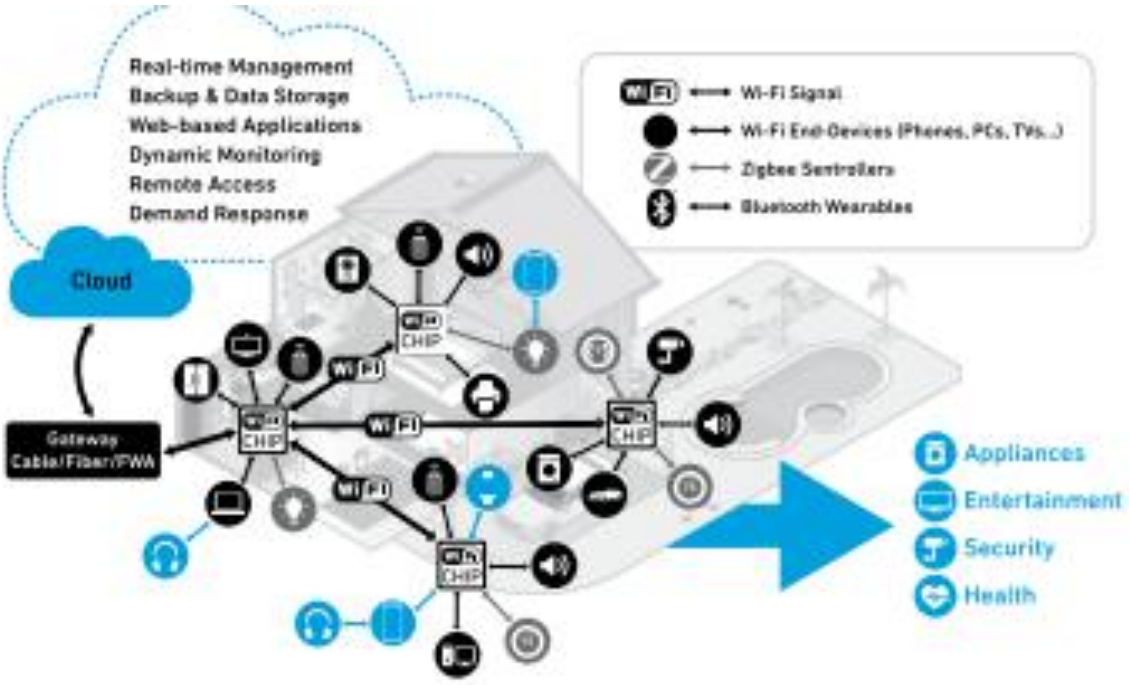

الشكل 6-1: أجهزة المنزل الذكي في البنية التحتية للشبكة.

كلما زاد عدد العقد، اتسع نطاق الاتصال، كما هو موضح في الشكل 7-1. تُوسّع شبكات الشبكية نطاق الإشارة بفعالية ليشمل منزلًا كاملًا، مما يزيد من الموثوقية ويُتيح التواصل الفوري مع جميع الأجهزة. تسمح التطورات في نشر شبكات Wi-Fi بفصل الطيف وضمان مسارات بيانات مخصصة لنقل المعلومات من وإلى السحابة. كما تُوفر تدفقات بيانات مخصصة للأجهزة. علاوة على ذلك، تُخزّن بعض الأجهزة البيانات، مما يُوفّر على المستخدمين المال، ويُعزز موثوقية الشبكة، ويُمكّن من تطبيقات أكثر ذكاءً تعتمد على البيانات.

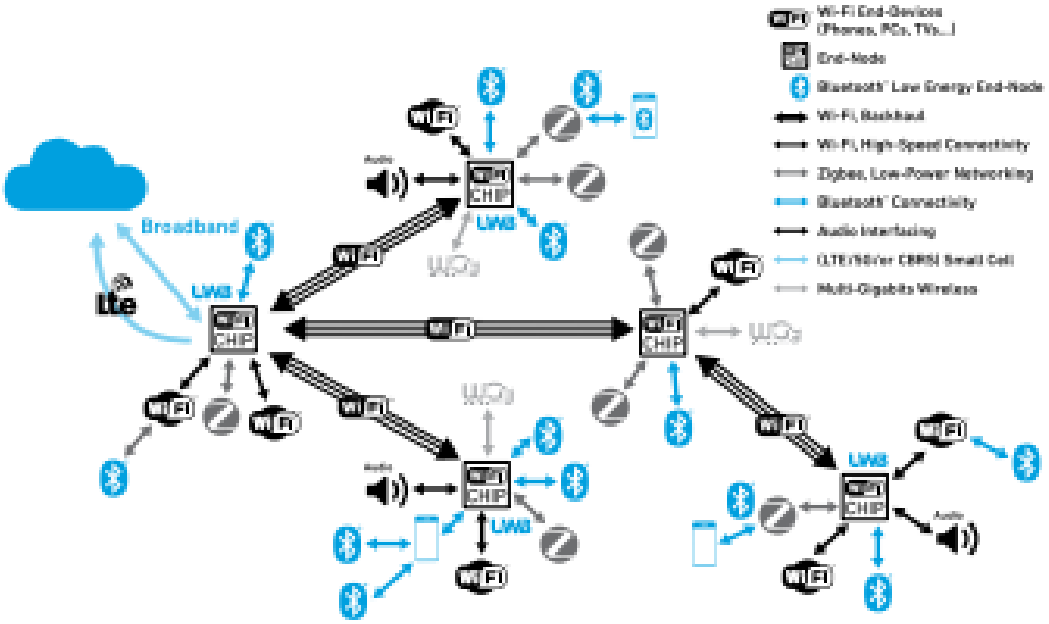

الشكل 7-1: شبكة اتصال إنترنت الأشياء الموزعة على كبسولة واحدة لكل غرفة.

يمكن لشبكة الشبكية أن تُهيئ نفسها تلقائيًا. وبالتالي، يمكنها دمج عقدة جديدة في الشبكة الحالية تلقائيًا دون الحاجة إلى تعديل من مسؤول الشبكة. هذا يجعل الشبكة أكثر قابلية للتكيف والتوسع. كما يمكن لشبكة المِشْب أن تُصلح نفسها تلقائيًا من خلال العثور على أسرع وأكثر إشارات موثوقية لنقل البيانات، حتى في حالة حجب إحدى العقد أو فقدانها.

تستخدم العديد من شبكات المِشْب الحالية ما يُسمى ببوابات واي فاي ثلاثية النطاقات والعقد الطرفية. تُحسّن شبكة واي فاي ثلاثية النطاقات سعة البيانات والتغطية باستخدام نطاقات 2.4 جيجاهرتز و5.2 جيجاهرتز و5.6 جيجاهرتز داخل البوابات والعقد الطرفية. في نظام ثلاثي النطاقات، يعمل النطاق الثاني 5.6 جيجاهرتز كخط اتصال

مخصص بين جهازي توجيه على الشبكة لتسريع النظام بأكمله بنسبة تصل إلى 180% مقارنةً بالأنظمة القديمة ثنائية النطاقات المهيأة.

وهكذا، تتضح مزايا واي فاي ثلاثية النطاقات. في البداية، يُسهّل ربط المزيد من الأجهزة اللاسلكية بالإنترنت باستخدام نطاق 5 جيجاهرتز الأسرع، ومع Wi-Fi 6E، نطاقي 5 و6 جيجاهرتز. وإذا كانت شبكتك عبارة عن نظام شبكي مع عدة أجهزة توجيه موزعة في جميع أنحاء المكان، فإن هذا النطاق الأعلى يعمل كخط اتصال مخصص بين جهازي التوجيه لتسريع النظام بأكمله.

يُستخدم أيضًا الراديو الثالث في نظام ثلاثي النطاق لنقل الاتصالات بين أجهزة توجيه الشبكة الشبكية. لذا، يُنشئ سلكًا مخصصًا فقط لغرض تدفق البيانات بين أجهزة التوجيه. على الرغم من أن أنظمة النطاق المزدوج تستخدم نفس نطاق Wi-Fi للاتصال بأجهزة التوجيه ونقاط الوصول الأخرى، إلا أنه في النطاق الثلاثي، تكون الأجهزة الطرفية متاحة فورًا للاتصال. وهذا يُحسّن الكفاءة بنسبة 50%، خاصةً مع إضافة المزيد من أجهزة الشبكة.

بالإضافة إلى ذلك، نظرًا لأن سرعة الراديو هذه أسرع، فإن سرعات الاتصال العالية الموجودة في مودم DSL/الكابل لا تتوقف عند هذا الحد. بل إنها تنتقل إلى الشبكة بأكملها. هذا مفيد جدًا لبث فيديو Wi-Fi إلى أجهزة التلفزيون الذكية والكاميرات المنتشرة في جميع أنحاء المنازل الذكية اليوم وغدًا.

لضمان مستقبل نظام شبكتك المنزلية الحالي، ستحتاج إلى استخدام نظام ثلاثي النطاقات. ستصبح خدمات الجيجابت قريبًا واقعًا ملموسًا للجميع، وتطبيق نظام ثلاثي النطاقات هو أفضل طريقة لضمان السعة والسرعة في المستقبل.

من التطورات الرئيسية الأخرى في أنظمة الشبكات الشبكية إدخال تقنية المرشحات لزيادة سعة ونطاق طوبولوجيا "كبسولة واحدة لكل غرفة". يساعد استخدام مرشحات bandBoost على تعظيم السعة والنطاق من خلال تعزيز

عزل النطاق في أنظمة الشبكات ثلاثية النطاقات. كما يعزز استخدام مرشحات edgeBoost السعة والنطاق من خلال تعظيم طاقة الخرج في قنوات Wi-Fi القريبة من حافة النطاق.

سنتناول هذه المواضيع بمزيد من التفصيل، بالإضافة إلى كيفية معالجتها لتحديات التعايش في الشبكات الشبكية في القسم التالي.

كما نوقش في الفصل الأول، تعمل كبرى الشركات المصنعة على تطوير معيار جديد يُسمى Connected Home over IP (CHIP) لزيادة قابلية التشغيل البيني للأجهزة وتقليل التعقيد في الشبكات الشبكية.

خلال عملية الانتقال إلى CHIP، ستكون هناك حاجة إلى أجهزة راديو متعددة المعايير. ستُهيئ هذه الأجهزة الشبكة للمستقبل لدعم الانتقال إلى CHIP وتوفير التوافق مع الإصدارات السابقة لتوصيل العقد التي تستخدم المعايير القديمة. على الرغم من أن CHIP لا يزال قيد الإعداد، حيث من المتوقع طرحه في وقت ما في عام 2021، إلا أن التعاون بين هيئات المعايير والشركات المصنعة الرائدة يدفع إلى زيادة اعتماد الصناعة .

التغلب على التحديات :

الان سنقوم بعرض بعض التحديات التي تواجه مصنعي شبكات وأجهزة إنترنت الأشياء المنزلية الذكية.

التوافقية :

التوافقية هو قدرة الأنظمة والتطبيقات والخدمات على العمل معًا بشكل موثوق وبطريقة متوقعة. يساعد هذا على ضمان سهولة استخدام التكنولوجيا وتسريع اعتمادها. يتوقع كل مستخدم أن تتصل أجهزته الإلكترونية، السلكية واللاسلكية، بسهولة وتعمل معًا بأقل جهد، وهو ما يُعرف باسم "التوصيل والتشغيل". والأمر لا يختلف في شبكة المنزل الذكي، التي تتكون من العديد من الأجهزة التي طورتها العديد من الشركات المصنعة المختلفة. تساعد برامج التوافقية

والاعتماد على ضمان التوافق التشغيلي بين الأجهزة التي تستخدم العديد من معايير إنترنت الأشياء الرئيسية. ويعود نجاح واي فاي الكبير إلى برنامج التوافق التشغيلي الذي يديره تحالف واي فاي، الذي يتمتع بأحد أكثر أنظمة الاعتماد موثوقية في العالم. وهناك عشرات الآلاف من أجهزة واي فاي المعتمدة التي تتميز باتصال سلس ومُثبت.

اليوم، يوفر Zigbee 3.0 نفس مستوى التوافق التشغيلي، بفضل الشراكات والشهادات. كما أن الاتصال بين المنتجات التي تستخدم Zigbee وThread معتمد أيضًا بفضل الشراكات بين المجموعتين. كما يوفر Bluetooth برامج اعتماد تغطي حزمة البروتوكولات بأكملها، بالإضافة إلى ملف تعريف التطبيق، مما يساعد Bluetooth وBluetooth Low Energy (BLE) على تحقيق تجربة اتصال مثالية.

كانت هذه التحالفات والشهادات حاسمة في توفير التكامل في بيئة أجهزة إنترنت الأشياء المنزلية الذكية المجزأة ذات المعايير المتعددة. يجب على مصنعي الأجهزة التي تستخدم هذه البروتوكولات المتعددة الالتزام بمعايير الاعتماد والتحالف هذه للحصول على موافقة منتجاتهم قبل طرحها في السوق. وهذا يضمن حصول المستخدمين على التوافق التشغيلي الفوري الذي يتوقعونه.

تداخل الترددات الراديوية :

ازداد تعقيد التداخلات اللاسلكية (RF) في شبكات المنزل الذكي مع كل جيل جديد من التقنيات اللاسلكية. تستخدم العديد من أجهزة الاتصال اللاسلكي المنزلية معايير تعمل على نطاقات تردد متداخلة أو قريبة جداً من بعضها، وأحياناً تكون هذه النطاقات قريبة لدرجة أنها تسبب تداخلًا يؤثر على إشارات الإرسال والاستقبال الخاصة بالنطاق الآخر.

يُضيف كل من IoT و G5 مستوى آخر من التعقيد، مما يزيد من التحديات التي يواجهها مهندسو تصميم الأجهزة المنزلية الذكية. يجب على أجهزة IoT المنزلية الذكية اليوم أن تدعم العديد من المسارات اللاسلكية (RF paths) ،

مع نطاقات تردد أكبر في بعض الأحيان، وأن تحافظ في الوقت نفسه على استهلاك منخفض للطاقة، كل ذلك دون حدوث تداخل بين المعايير والبيانات التي يتم إرسالها أو استقبالها. ومع وجود الكثير من المعايير التي تعمل على شبكة واحدة، أصبح تقليل التداخل أمراً حتمياً.

الحفاظ على اتصال سلس، موفر للطاقة، وموثوق :

تصنع بعض الشركات منتجات تدعم عدة معايير، مما يزيد من إمكانية التشغيل البيني في شبكات إنترنت الأشياء (IoT)، لأن ذلك يمكّن منتجاتها من الاتصال بمجموعة أكبر من الأجهزة الأخرى. فمع خاصية دعم البروتوكولات المتعددة (dynamic multi-protocol support)، يمكن للعقدة (node) التواصل مع أجهزة متعددة تستخدم معايير مختلفة.

على سبيل المثال، قد تتضمن شبكة المنزل الذكي أجهزة Zigbee و أجهزة BLE. في هذه الحالة، يمكن للعقدة الشبكية التي تدعم البروتوكولات المتعددة لكل من Zigbee و BLE، أن تقوم بتحويل الاتصال تلقائياً بين هذه المعايير، لتتواصل مع كل معيار على حدة في لحظة معينة.

وتضيف منتجات الاتصالات لإنترنت الأشياء من Qorvo، والتي تستخدم في الأجهزة المنزلية الذكية، قدرة إضافية عبر دعم تقنية ConcurrentConnect التي تستقبل وتترجم الاتصالات بشكل مستمر، كما هو موضح في الشكل 3-6. هذا الابتكار الإضافي يطبق خاصية تبديل البروتوكولات بطريقة أسرع وأكثر موثوقية لتقليل فقدان حزم البيانات، مع الحفاظ على دعم البروتوكولات المتعددة.

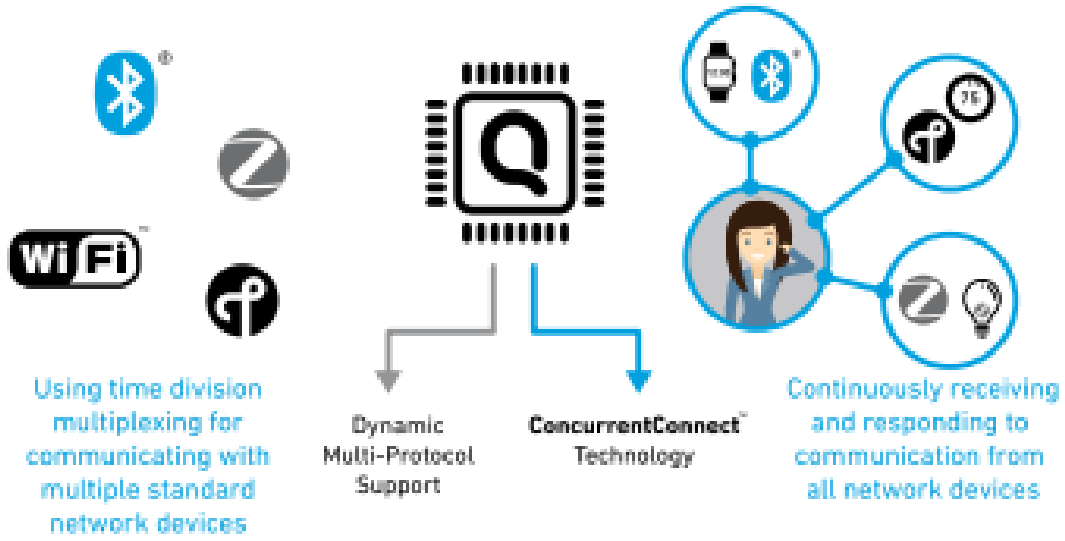

الشكل 8-1: دعم متعدد البروتوكولات الديناميكي و تقنية CurrentConnect.

على سبيل المثال، وبالإشارة إلى الشكل 3-6، نرى في الجهة اليسرى أن منتجات اتصالات إنترنت الأشياء (IoT) تتضمن ميزة دعم البروتوكولات المتعددة(dynamic multiprotocol support). هذا الدعم يسمح بالاتصال بين عدة أجهزة IoT تستخدم معايير مختلفة، مما يتيح التبديل من بروتوكول لآخر عند الحاجة.

لكن شركة Qorvo تضيف مستوى آخر من التعقيد في أجهزتها اللاسلكية (RF) الخاصة بإنترنت الأشياء، وهو ما يُعرف بتقنية ConcurrentConnect. هذه التقنية تجعل اتصالات أجهزة IoT أكثر موثوقية وسلاسة، لأنها تضيف القدرة على استقبال وإرسال اتصالات الأجهزة من كل الشبكة بشكل مستمر ومتزامن. وبالتالي، يصبح التبديل بين كل بروتوكول سلساً، مما يلغي الحاجة إلى إعادة إرسال "ping" ويمنع انقطاع الاتصالات المحتمل.

لنأخذ مثالاً على شبكة فعلية: بدون تقنية ConcurrentConnect، فإن أجهزة Zigbee/CHIP و(Bluetooth Low Energy (BLEستتبادل الاتصال بين المعيارين، وتتواصل مع أحدهما في كل مرة. لكن هذا التبديل بين البروتوكولات يسبب تأخيراً يؤدي إلى انقطاع الاتصالات. في المقابل، تسمح الأجهزة المزودة بتقنية

ConcurrentConnect بالتبديل الفوري من BLE إلى Zigbee/CHIP مع القليل من الانقطاعات أو عدم وجودها على الإطلاق. وهذا لأن تقنية ConcurrentConnect تقضي على التأخير في تبديل البروتوكولات. وبذلك تصبح الاتصالات أسرع، وأكثر كفاءة، وأكثر قابلية للتوسع، وقادرة على استقبال عدد أكبر من حزم البيانات في وقت أقصر.

إنشاء شبكة إنترنت أشياء سهلة الاستخدام ذاتية الإدارة :

يرغب معظم مستخدمي شبكات إنترنت الأشياء (IoT) في تجربة "التوصيل والتشغيل" (plug-and-play) التي تتطلب إعداداً بسيطاً أو معدوماً. كل ما نريده هو أن تعمل الأجهزة بمجرد تشغيلها. وهذا يضع مسؤولية سهولة الاستخدام على عاتق الشركة المصنعة للمنتج. وهذا التحدي ليس سهلاً دائماً، لأن شبكة كل مستخدم تختلف عن الأخرى.

ولتحقيق هذا الهدف، يجب أن تكون شبكة IoT الشبكية (mesh network) في المنزل ذاتية الإدارة وذاتية المعالجة، حتى يطمئن المستخدمون إلى استمرار عملها دون الحاجة إلى التدخل في التفاصيل التقنية لإدارة الشبكات. يجب أن تكون شبكة IoT قادرة على العمل ومراقبة المستخدمين وإخطارهم بالمشكلات المحتملة التي قد تحدث قبل حدوث انقطاع كامل للشبكة.

يجب أن تعمل العقد الفردية (individual nodes) والبوابات (gateways) مع بعضها البعض وتتكيف مع أي أعطال في الشبكة أو تغييرات بيئية. وتقوم الأنظمة الفرعية في شبكة المنزل الذكي بمراقبة قوة الإشارة، وعمر البطارية، والمزيد، حيث تتكيف باستمرار وتخطر المستخدم لضمان أفضل أداء.

تُقدم الشبكات الشبكية (mesh networking) مزايا حقيقية لتطبيقات إنترنت الأشياء، لأنها متاحة وسهلة الوصول دائماً. تستخدم الشبكة الشبكية خوارزمية "الشفاء الذاتي" (self-healing algorithm) التي تختار تلقائياً أفضل مسار لإرسال البيانات حتى لو فقدت بعض العقد اتصالها عن غير قصد. وتضمن هذه الخوارزمية أن يتم توجيه البيانات فقط عبر الاتصالات المتاحة والعاملة. وهكذا، تستمر الشبكة الشبكية في العمل حتى عندما لا تكون بعض العقد فعالة. كما تتيح الشبكات الشبكية للأجهزة أن تتواصل مباشرة مع بعضها البعض دون الحاجة إلى توجيه كل الاتصالات عبر البوابة (gateway).

أمان الشبكة والخصوصية :

يمكن أن يشكل تطبيق إجراءات الأمن والخصوصية الكافية تحديًا كبيرًا عند نشر أنظمة إنترنت الأشياء (IoT). فشبكات IoT اليوم غالبًا ما تكون مجزأة وتستخدم مجموعة متنوعة من البروتوكولات والتقنيات، مما يجعل التحكم في الأمن والخصوصية أمرًا صعبًا.

هذا الواقع يمثل حجة قوية لتوحيد المعايير (standardization)، الأمر الذي سيساعد على تحسين الأمن والخصوصية. كما أنه سيوفر سهولة أكبر في الاستخدام وقابلية للتوسع، مما يمكّن المستخدمين من إضافة أجهزة بسهولة إلى الشبكة. ويسهم التوحيد في مساعدة المستخدمين على إنشاء تصميم شبكة IoT الأمثل الخاص بهم بطريقة آمنة.

إن استخدام الشبكة الشبكية (mesh network)، كما وُصف سابقًا، يضع قوة التحكم والأمان في يد المالك. وعادةً ما يتم إعداد هذه الأنظمة الشبكية والتحكم بها ومراقبتها باستخدام تطبيق خاص. يساعد التطبيق في إعداد الشبكة ويضمن تعيين كلمة مرور آمنة. كما يساعد في إدارة مشكلات الشبكة، والتحقق من سرعات البيانات، ووضع parental controls (أدوات الرقابة الأبوية)، والمزيد. وتساعد بعض الأنظمة المالك على معرفة من هو المتصل بالشبكة في أي وقت.

تحديثات جهاز الكمبيوتر والهاتف الذكي ضرورية للحفاظ على أمان هذه الأجهزة. الأمر نفسه ينطبق على الشبكة الشبكية. لكن الشبكة الشبكية عادةً ما تقوم بتحديث نفسها تلقائيًا، مما يريح المالك من القلق بشأن إجراء تحديثات مزعجة.

تقدم بعض الشبكات الشبكية أيضًا رسوم اشتراك مدفوعة للحصول على ميزات أمان محسّنة، مثل الحماية من المتسللين وتهديدات المواقع الإلكترونية والفحوصات الأمنية. وقد تتضمن هذه الاشتراكات أيضًا الحماية من التهديدات مثل البرامج الضارة (malware) والفيروسات والمتسللين وحتى مجرمي الإنترنت.

إذا كان لديك منزل ذكي مزود بكاميرات أمنية متصلة بالشبكة، وأجهزة ترموستات، وأجهزة IoT ذكية أخرى، فإن نظام الشبكة الشبكية يُعد إضافة مفيدة جدًا. فميزات النظام الشبكي يمكن أن تساعد في حماية الشبكة بأكملها، بما في ذلك هذه الأجهزة، من الهجمات الإلكترونية.

استهلاك الطاقة :

تتضاءل مستويات الوقود الأحفوري في جميع أنحاء العالم بسرعات متزايدة. ويتزايد الضغط لتقليل استهلاك الطاقة وتقديم منتجات أكثر صداقة للبيئة. هذا الضغط نفسه يقع على عاتق الشركات المصنعة والموردين الذين ينتجون أجهزة إنترنت الأشياء (IoT) اليوم، وهذا التوجه سيزداد حدةً مع دفع قادة العالم للمزيد من المبادرات الخضراء.

تستخدم بعض منتجات IoT بطاريات بحجم العملة المعدنية (تدوم بعضها حتى عشر سنوات)، ولكن إنتاج هذه البطاريات يستهلك الوقود الأحفوري. بالإضافة إلى ذلك، لا تستخدم العديد من أجهزة IoT بطاريات بحجم العملة المعدنية؛ بل تستخدم الطاقة من الشبكة الكهربائية (grid). لذا، وللحفاظ على متطلبات استهلاك الطاقة تحت

السيطرة، يتم أحياناً إضافة برامج وأجهزة إلى بعض أجهزة IoT هذه لضمان بقائها في وضع السكون (sleep mode) عندما لا تكون في حالة اتصال.

في بيئات التصنيع، لا تقتصر فوائد أجهزة تقنية IoT على دفع عجلة الكفاءة والأتمتة بشكل غير مسبوق فحسب، بل يجب أيضًا تصميم هذه الأجهزة لتستهلك طاقة أقل أثناء التشغيل. وقد وضعت الشركات المصنعة لأجهزة IoT بالفعل نصب أعينها إنتاج منتجات تستهلك طاقة أقل. وبذلك، تصبح منتجاتهم أكثر كفاءة وأصغر وأكثر أناقة. الجميع يربح من محاولة إنتاج أجهزة تستخدم طاقة أقل أثناء التشغيل، سواء كان المستهلك، أو الشركة، أو المصنّع.

يمكن للعديد من الشركات الاستفادة من وضع إنترنت الأشياء (IoT) في طليعة الطاقة المتجددة. يمكن لتطبيق حساسات IoT على معدات التوليد والنقل والتوزيع أن يمكّن من مراقبة الأصول وإدارتها عن بُعد. بالإضافة إلى ذلك، يمكن أن يساعد تركيب IoT في جميع أنحاء بيئة التصنيع في تقليل التكاليف المرتبطة بالإضاءة والتدفئة والتبريد والسلامة.

يمكن لشبكة المنزل الذكي أن تتضمن العديد من أجهزة الاتصال التي تعمل على مدار الساعة طوال أيام الأسبوع (7/24). ولأن هذه الأجهزة تستهلك الطاقة حتى عندما لا تتصل بشكل فعال، فإن الكفاءة واستهلاك الطاقة سيظلان دائمًا مصدر قلق في التصميم. ويجب تحسين أجهزة IoT لتكون ذات كفاءة في استهلاك الطاقة بغض النظر عن البروتوكول الذي تستخدمه.

سنعرض الان ملخص عالي المستوى لاستهلاك الطاقة في المعايير المختلفة: WiFi و CHIP (Zigbee, Thread) لهما نطاق إشارة متشابه، لكن WiFi يستهلك طاقة أكبر بكثير بسبب دعمه لنطاق البيانات العالي.

تستهلك CHIP (Zigbee, Thread) و BLE طاقة متشابهة، وقد تم تطويرهما للحفاظ على طاقة البطارية.

- تستهلك CHIP (Zigbee, Thread) حوالي 1% إلى 3% من الطاقة التي يستهلكها Wi-Fi، وهذا يعتمد على التطبيق.

مع تطبيق المبادرات الخضراء على مستوى العالم، أصبح تقليل استهلاك الطاقة عبر شبكة إنترنت الأشياء (IoT) أمرًا ضروريًا. ويسعى كل من المستخدمين والشركات المصنعة لتحقيق استهلاك أقل للطاقة دون المساس بالأداء أو بأهداف الاتصال الشاملة لأجهزة IoT. ويمكن للأجهزة أن تضمن استمرار عملها من خلال إشعار المستخدمين تلقائياً عندما تحتاج البطاريات إلى استبدال.

أهمية الاتصال الدائم :

توسعت شبكات إنترنت الأشياء (IoT) في المنزل ومكان العمل بشكل كبير خلال السنوات القليلة الماضية. وفي الوقت نفسه، ازداد اعتمادنا على هذه الشبكات. يعمل المزيد من الأشخاص من مكاتبهم المنزلية، وتستخدم العائلات شبكاتها المنزلية لإجراء مكالمات الفيديو، والألعاب، ومشاهدة التلفزيون، ومراقبة صحتهم، وتأمين منازلهم. هناك حاجة حقيقية لاتصالات موثوقة، مستمرة، وذات زمن انتقال منخفض (low-latency) لضمان دعم هذه الاستخدامات على مدار الساعة.

لحسن الحظ، يستجيب مزودو الخدمات اللاسلكية في جميع المناطق بعمليات طرح جديدة، بما في ذلك الانتقال إلى شبكات G5 . لم نعد بحاجة للقلق بشأن الاتصال أو سرعة نقل البيانات. بدلاً من ذلك، ستتركز اهتماماتنا على خصائص الشبكة ذات المستوى الأعلى مثل الخصوصية والأمان، خاصةً مع تزايد اعتمادنا على شبكات IoT للمنزل الذكي، والمدينة الذكية، والصناعة 4.0، و V2X، وغيرها من جوانب حياتنا. هذه الاهتمامات الجديدة تدفع جميع الشركات المصنعة ومقدمي الخدمات اللاسلكية للاستجابة من خلال وضع الأمان في صدارة تصميمات شبكاتهم وأجهزتهم.

يسمح العالم الرقمي الجديد للشركات والمستهلكين بالبقاء على اتصال دائم. يقضي مستخدمو IoT المتصلون بشكل كبير معظم أيامهم على الإنترنت، سواء في العمل، أو الدراسة، أو اللعب، أو استخدام وسائل التواصل الاجتماعي، وغيرها. لا نقتصر على قضاء 8 ساعات أو أكثر يومياً على الإنترنت، بل أجهزتنا IoT أيضًا تعمل على مدار الساعة. هذه التفاعلات عبر حساساتنا وكاميراتنا متصلة بالإنترنت طوال الوقت، وهذه الحساسات والكاميرات وأجهزة المراقبة تدفعنا أكثر نحو سيناريو الاتصال الدائم، خاصةً في عالم IoT .

هذا العالم الرقمي ديناميكي ويسمح لنا بالعديد من قنوات الاتصال المختلفة، وأهمها الإنترنت و IoT . الاتصال عبر الإنترنت اليوم سريع، وبسيط، وفوري، ويضمن أن تكون المعلومات والبيانات متاحة دائمًا تحت تصرفنا.

في عالم الأعمال، يتيح الاتصال الدائم (7/24) للمديرين والموظفين وأصحاب المصلحة وسلاسل التوريد الحصول على المعلومات المحدثة والاطلاع عليها في الوقت الفعلي. عندما تكون خارج المكتب، لا تحتاج أن تكون منقطعًا عن ما يحدث. ستكون المنتجات الخاصة بالصناعات هي السباقة في استخدام IoT، ولكن بمساعدة الصناعة 4.0، والمدفوعة بالبحث عن كفاءة التصنيع وإدارة التكاليف، أصبح المستهلكون أيضًا جزءًا أساسيًا من عالم IoT.

يشتري المستهلكون مليارات الوحدات لتثبيتها داخل منازلهم لمراقبة وتحديث كل شيء تلقائيًا ويدويًا، وكل ذلك على أمل الحصول على الراحة والأمان والصحة وتقليل التكاليف. يعد IoT للمستهلكين بجعل بيئاتنا ومنازلنا ومركباتنا أكثر ذكاءً، وأكثر قابلية للقياس، وأكثر قدرة على الاتصال. إنه يعمل دائمًا وينتظر منا التواصل، مثل Amazon's Alexa أو Echo، أو يراقب دائمًا ما يحدث لمساعدتنا على اتخاذ قرارات أفضل بشأن بيئاتنا المنزلية والأنشطة المرتبطة بها.

يُولد IoT كميات هائلة من البيانات لأنه يعمل 7/24، باستخدام حساسات مثبتة على أجزاء الآلات أو حساسات بيئية أو مكبر الصوت الذكي داخل غرف المعيشة. وهذا يعني أن IoT هو محرك كبير لإنشاء كم هائل من تحليلات البيانات للسماح للشركات بالتحليل ولأشياءنا الذكية بأن تصبح أكثر ذكاءً.

تأتي هذه البيانات بأشكال مختلفة، من طلبات صوتية وقراءات حساسات ومقاطع فيديو وغيرها. وتنمو بيانات IoT ، ويتم تغذية هذه البيانات الوصفية (metadata) في قواعد بيانات لإضفاء هيكل على المحتوى غير المهيكل، أو تُغذى في أنظمة معرفية (cognitive systems) لإضفاء مستويات جديدة من اتخاذ القرار والفهم والذكاء على بيئتنا.

كمية اتخاذ القرار والفهم والذكاء التي تحدث حولنا بفضل IoT يمكن أن تكون مذهلة. على سبيل المثال، يندهش العديد من الأشخاص من عدد أجهزة IoT الموجودة على شبكاتهم المنزلية. إذا كان لديك منزل جديد بأجهزة جديدة و Amazon Alexa أو اثنين، فقد يكون لديك قريبًا ما يصل إلى 15 أو 20 جهازًا متصلاً بشبكتك. يمكن أن يظهر لك مسح بسيط للتطبيقات على هاتفك مستوى IoT في منزلك: كاميرا عند بابك الأمامي، وداخل غرفة المعيشة، وفي فنائك الخلفي؛ وتطبيق آخر لغسالتك ومجففك الجديدين، ومن المحتمل أن يكون هناك ثلاجة وفرن وميكروويف؛ و Amazon Alexa أو اثنان حول المنزل. بالإضافة إلى ذلك، ربما لديك تطبيق لبعض الإضاءة في المنزل، وهذا يعني ثلاث أو عشر لمبات أخرى. . . . لقد فهمت الفكرة. اجمعها كلها، وقد يكون لديك 10 إلى 20 جهاز IoT منتشرًا، وعلى الأرجح ساعتان ذكيتان أو ثلاثة أو Fitbits متصلة ببضعة هواتف وأجهزة لوحية. هذه الأجهزة تعمل دائمًا وتتصل بشبكتك وببعضها البعض. أجهزة IoT تعمل دائمًا وتستشعر وتراقب وتتخذ القرارات

لنا ومعنا. يمكن أن يكون مسح بسيط كهذا مذهلاً ورائعًا في الوقت نفسه، حيث يظهر لك أن IoT موجود في كل مكان حولك.

القسم الثالث: - أنظمة كشف التطفل :(IDS)

مقدمة عن أنظمة كشف التطفل (IDS) :

يمثل التطور المستمر للبرمجيات الخبيثة تحديًا جوهريًا أمام تصميم أنظمة كشف التطفل (IDS). فالهجمات الخبيثة باتت أكثر تعقيدًا، والتحدي الأكبر يكمن في اكتشاف البرامج الخبيثة المجهولة والمموّهة. يلجأ مصممو هذه البرامج إلى استخدام تقنيات تمويه متقدمة لإخفاء المعلومات، بهدف تجنب الاكتشاف من قبل أنظمة IDS.

علاوة على ذلك، شهدنا ازديادًا ملحوظًا في التهديدات الأمنية، مثل هجمات على ثغرات غير مكتشفة بعد (Zero-day attacks)، التي تستهدف مستخدمي الإنترنت بشكل مباشر. ولهذا أصبح أمن الكمبيوتر أمرًا لا غنى عنه في حياتنا اليومية التي باتت تعتمد بشكل كبير على تقنية المعلومات.

لقد أثرت الهجمات على الثغرات الغير المكتشفة بعد بشكل كبير على دول مثل استراليا والولايات المتحدة. فوفقًا لتقرير Symantec لأمن الإنترنت لعام 2017، تم الإبلاغ عن أكثر من ثلاثة مليارات هجوم من هذا النوع في عام 2016، مما يؤكد أن حجمها وشدتها فاقا التوقعات السابقة. كما كشفت إحصائيات اختراق البيانات لعام 2017 عن فقدان أو سرقة ما يقرب من تسعة مليارات سجل بيانات على يد المخترقين منذ عام 2013.

تُظهر تقارير Symantec أن حوادث الاختراق الأمني في تصاعد. في الماضي، كان مجرمو الإنترنت يركزون بشكل أساسي على عملاء البنوك لسرقة الأموال من حساباتهم أو بطاقاتهم الائتمانية. لكن الجيل الجديد من البرامج الخبيثة

أصبح أكثر جرأة وطموحًا، حيث يستهدف البنوك نفسها، وفي بعض الأحيان يحاول سرقة ملايين الدولارات في هجوم واحد. لهذا السبب، أصبح اكتشاف الهجمات على الثغرات الغير المكتشفة على رأس الأولويات.

أثبتت حوادث الجرائم الإلكترونية البارزة سهولة انتشار التهديدات السيبرانية على المستوى الدولي، حيث يمكن لاختراق بسيط أن يعطل الخدمات أو المرافق الحيوية لشركة ما. يوجد عدد كبير من مجرمي الإنترنت حول العالم، الذين تحفزهم دوافع لسرقة المعلومات، أو الحصول على إيرادات غير شرعية، أو البحث عن أهداف جديدة. يتم تصميم البرامج الخبيثة عمدًا لاختراق أنظمة الكمبيوتر واستغلال أي نقطة ضعف في أنظمة كشف التطفل. في عام 2017، قام المركز الأسترالي للأمن السيبراني (ACSC) بدراسة نقدية لمستويات التعقيد المختلفة التي يستخدمها المهاجمون.

لذلك، هناك حاجة ملحة لتطوير نظام كشف تطفل فعّال يمكنه اكتشاف البرامج الخبيثة المستجدة والمعقدة. يهدف نظام IDS إلى تحديد أنواع مختلفة من البرمجيات الخبيثة في أقرب وقت ممكن، وهو أمر لا يمكن للجدار الناري التقليدي (firewall) تحقيقه. ومع تزايد حجم البرمجيات الخبيثة على أجهزة الكمبيوتر، أصبح تطوير أنظمة IDS محسّنة أمرًا في غاية الأهمية.

في العقود القليلة الماضية، تم استخدام التعلم الآلي لتحسين كشف التطفل، وهناك حاجة حاليًا لتصنيف شامل وحديث، ومسح للأعمال الأخيرة في هذا المجال. هناك عدد كبير من الدراسات ذات الصلة التي تستخدم مجموعة بيانات KDD-Cup 99 أو DARPA 1999 للتحقق من تطوير أنظمة IDS ؛ ومع ذلك ، لا توجد إجابة واضحة على السؤال حول أي تقنيات استخراج البيانات هي الأكثر فعالية. وثانيًا، لا يتم أخذ الوقت اللازم لبناء نظام IDS في الاعتبار عند تقييم بعض تقنيات IDS، على الرغم من كونه عاملاً حاسماً في فعالية أنظمة IDS "اللحظية" (on-line).

تقدم هذه الورقة تصنيفًا محدثًا، بالإضافة إلى مراجعة لأبرز الأبحاث حول أنظمة IDS حتى الوقت الحاضر؛ وتصنيف للأنظمة المقترحة وفقًا للتصنيف. كما تقدم نظرة عامة منظمة وشاملة على أنظمة IDS الحالية حتى يتمكن الباحث من الإلمام بسرعة بالجوانب الرئيسية لكشف الشذوذ. وتقدم هذه الورقة أيضًا مسحًا لتقنيات استخراج البيانات المطبقة لتصميم أنظمة كشف التطفل. وتصف الأساليب القائمة على التوقيعات والقائمة على الشذوذ (SIDS وAIDS)، إلى جانب العديد من التقنيات المستخدمة في كل طريقة. يتم مناقشة تعقيد أساليب AIDS المختلفة وتقنيات تقييمها، يتبعها مجموعة من الاقتراحات لتحديد أفضل الأساليب، اعتمادًا على طبيعة التطفل. كما يتم مناقشة التحديات التي تواجه أنظمة IDS الحالية. مقارنة بالمنشورات الاستقصائية السابقة، تقدم هذه الورقة مناقشة لمشاكل مجموعات بيانات IDS التي تعد مصدر قلق رئيسي للمجتمع البحثي في مجال أنظمة كشف تطفل الشبكة (NIDS). لم تقم الدراسات السابقة بمراجعة شاملة لأنظمة IDS من حيث مجموعات البيانات، والتحديات، والتقنيات. في هذه الورقة، نقدم دراسة منظمة ومعاصرة وواسعة النطاق حول نظام كشف التطفل من حيث التقنيات ومجموعات البيانات؛ ونسلط الضوء أيضًا على تحديات التقنيات ومن ثم نقدم توصيات.

خلال السنوات القليلة الماضية، تم نشر عدد من الأبحاث الاستقصائية حول كشف التطفل. قام المسح حول نظام كشف التطفل وتصنيفه بواسطة (Axelsson) Axelsson , 2000 بتصنيف أنظمة كشف التطفل بناءً على طرق الكشف.

قام المسح الذي تم الاستشهاد به بشكل كبير بواسطة . (Debar et al.، 2000) بمسح طرق الكشف بناءً على سلوك وخصائص الهجمات. وقد قدم تصنيف أنظمة التطفل بواسطة Liao et al

((Liao et al., 2013a) ، تصنيفًا لخمسة فئات فرعية مع منظور متعمق لخصائصها: القائمة على الإحصاء، والقائمة على الأنماط، والقائمة على القواعد، والقائمة على الحالات، والقائمة على الاستدلال. من ناحية أخرى، يركز عملنا على مبدأ كشف التوقيعات، وكشف الشذوذ، والتصنيف، ومجموعات البيانات.

تركز مقالات المراجعة الحالية على تقنيات كشف التطفل، أو مشكلة مجموعة البيانات، أو نوع هجوم الكمبيوتر، أو تجنب IDS. لم تقم أي مقالة بمراجعة شاملة لكشف التطفل، ومشاكل مجموعة البيانات، وتقنيات التجنب، وأنواع مختلفة من الهجمات مجتمعة. بالإضافة إلى ذلك، كان تطوير أنظمة كشف التطفل بحيث تم اقتراح العديد من الأنظمة المختلفة في هذه الأثناء، ولذلك هناك حاجة لتحديث. تقدم هذه الورقة مسحًا محدثًا لتصنيف مجال كشف التطفل، مما يعزز التصنيفات المقدمة في (Liao et al., 2013a; Ahmed et al., 2016).

في ضوء مناقشة الدراسات الاستقصائية السابقة، تركز هذه المقالة على ما يلي:

* تصنيف أنواع مختلفة من أنظمة IDS مع الأنواع الرئيسية للهجمات بناءً على طرق التطفل.

* تقديم تصنيف لمقاييس تقييم أنظمة IDS الشاذة للشبكة ومناقشة أهمية اختيار الميزات.

* تقييم مجموعات بيانات IDS المتاحة ومناقشة تحديات تقنيات التجنب.

يمكن تعريف التطفل بأنه أي نوع من الأنشطة غير المصرح بها التي تسبب ضررًا لنظام المعلومات. هذا يعني أن أي هجوم يمكن أن يشكل تهديدًا محتملاً لسرية المعلومات، أو تكاملها، أو توفرها، سيعتبر تطفلاً. على سبيل المثال، الأنشطة التي تجعل خدمات الكمبيوتر غير مستجيبة للمستخدمين الشرعيين تعتبر تطفلاً. نظام IDS هو نظام برمجي أو مادي يحدد الأنشطة الضارة على أنظمة الكمبيوتر من أجل السماح بالحفاظ على أمن النظام (Liao et al., 2013a). هدف نظام IDS هو تحديد أنواع مختلفة من حركة مرور الشبكة الضارة واستخدام الكمبيوتر، والتي لا

يمكن تحديدها بواسطة جدار حماية تقليدي. وهذا أمر حيوي لتحقيق حماية عالية ضد الإجراءات التي تهدد توفر أنظمة الكمبيوتر أو تكاملها أو سريتها. يمكن تصنيف أنظمة IDS بشكل عام إلى مجموعتين: نظام كشف التطفل القائم على التوقيع (SIDS) ونظام كشف التطفل القائم على الشذوذ (AIDS).

أنظمة كشف التطفل القائمة على التوقيع(SIDS) :

تعتمد أنظمة كشف التطفل القائمة على التوقيعات (SIDS) على تقنيات مطابقة الأنماط للعثور على هجوم معروف مسبقاً؛ وتعرف هذه الأنظمة أيضاً باسم "الكشف القائم على المعرفة" أو "كشف سوء الاستخدام". في هذه الأنظمة، تُستخدم طرق المطابقة للعثور على تطفل سابق. بعبارة أخرى، عندما يتطابق توقيع تطفل حالي مع توقيع هجوم سابق موجود بالفعل في قاعدة بيانات التوقيعات، يتم إطلاق إشارة إنذار.

بالنسبة لـ SIDS، يتم فحص سجلات الجهاز المضيف للعثور على تسلسلات من الأوامر أو الأفعال التي تم تعريفها مسبقاً على أنها برامج خبيثة. وقد أُطلق على أنظمة SIDS في المراجع أيضاً أسماء مثل " الكشف القائم على المعرفة " أو "كشف سوء الاستخدام".

يوضح الشكل 1 المفهوم العملي لأساليب SIDS. تتمثل الفكرة الرئيسية في بناء قاعدة بيانات لتوقيعات التطفل، ومقارنة الأنشطة الحالية بالتوقيعات الموجودة، وإطلاق إنذار في حال العثور على تطابق. على سبيل المثال، قد تؤدي قاعدة على شكل "إذا: شرط – إذن: نتيجة" إلى "إذا (عنوان IP المصدر = عنوان IP الوجهة) إذن صنف على أنه هجوم".

عادةً ما تقدم أنظمة SIDS دقة ممتازة في الكشف عن التطفلات المعروفة مسبقاً. ومع ذلك، تواجه صعوبة في اكتشاف الهجمات على الثغرات الغير المكتشفة (zero-day attacks) لأنه لا يوجد توقيع مطابق في قاعدة البيانات حتى يتم استخراج توقيع الهجوم الجديد وتخزينه. تُستخدم أنظمة SIDS في العديد من الأدوات الشائعة، مثل Snort و NetSTAT.

تدرس الأساليب التقليدية لـ SIDS حزم الشبكة وتحاول مطابقتها بقاعدة بيانات التوقيعات. لكن هذه التقنيات غير قادرة على تحديد الهجمات التي تمتد عبر عدة حزم. وبما أن البرامج الخبيثة الحديثة أصبحت أكثر تعقيداً، فقد يكون من الضروري استخلاص معلومات التوقيع عبر حزم متعددة. وهذا يتطلب من نظام IDS استدعاء محتويات الحزم السابقة. فيما يتعلق بإنشاء توقيع لـ SIDS، عادةً ما تكون هناك عدة طرق حيث يتم إنشاء التوقيعات كـ "آلات حالات" (state machines)، أو أنماط لغوية رسمية، أو شروط دلالية.

إن المعدل المتزايد لهجمات على الثغرات الغير المكتشفة قد جعل تقنيات SIDS أقل فعالية تدريجياً، لأنه لا يوجد توقيع مسبق لمثل هذه الهجمات. كما أن الأشكال المتعددة للبرامج الخبيثة وزيادة الهجمات الموجهة يمكن أن تزيد من تقويض كفاءة هذا النموذج التقليدي. ويمكن أن يكون الحل المحتمل لهذه المشكلة هو استخدام تقنيات AIDS (أنظمة كشف التطفل القائمة على الشذوذ)، التي تعمل من خلال تحديد السلوك المقبول بدلاً من تحديد السلوك الشاذ، كما سيتم وصفه في القسم التالي.

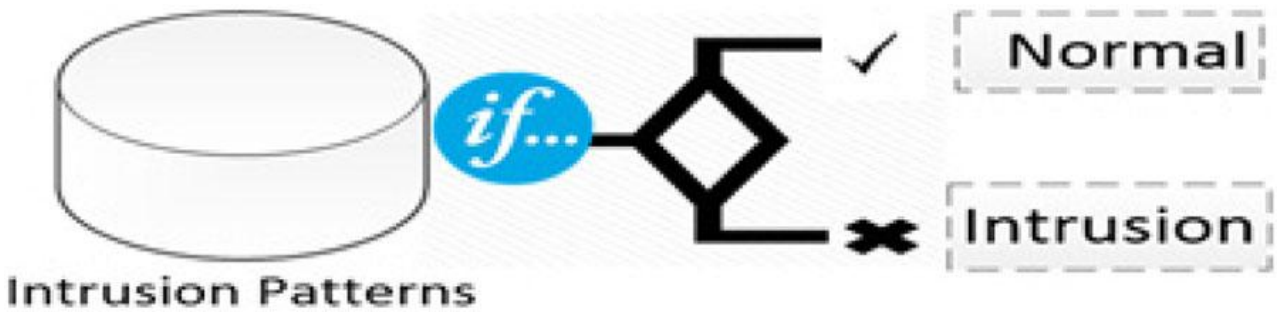

الشكل 9-1: العمل المفاهيمي لمناهج .SIDS

نظام كشف التطفل القائم على الشذوذ (AIDS) :

حظيت أنظمة كشف التطفل القائمة على الشذوذ (AIDS) باهتمام كبير من الباحثين، وذلك لقدرتها على تجاوز القيود التي تعاني منها أنظمة SIDS ، في أنظمة AIDS يتم إنشاء نموذج للسلوك "الطبيعي" لنظام الكمبيوتر باستخدام طرق تعتمد على التعلم الآلي أو الإحصاء أو المعرفة. يُعتبر أي انحراف كبير بين السلوك الملاحظ والنموذج بمثابة "شذوذ" (Anomaly)، والذي يمكن تفسيره على أنه تطفل. تعتمد هذه المجموعة من التقنيات على افتراض أن السلوك الخبيث يختلف عن سلوك المستخدم المعتاد. لذا، يتم تصنيف سلوكيات المستخدمين غير الطبيعية التي لا تتوافق مع السلوكيات القياسية على أنها عمليات تطفل.

يتكون تطوير أنظمة AIDS من مرحلتين:

* مرحلة التدريب: يتم فيها استخدام ملف تعريف حركة المرور الطبيعية لتعلم نموذج السلوك الطبيعي.

* مرحلة الاختبار: يتم فيها استخدام مجموعة بيانات جديدة لتحديد قدرة النظام على التعميم واكتشاف التطفلات التي لم يسبق له رؤيتها.

يمكن تصنيف أنظمة AIDS إلى عدة فئات بناءً على الطريقة المستخدمة في التدريب، مثل الأنظمة القائمة على الإحصاء، أو القائمة على المعرفة، أو القائمة على التعلم الآلي.

المزايا الرئيسية لـ AIDS

تكمن الميزة الأهم لـ AIDS في قدرتها على اكتشاف الهجمات على الثغرات الغير المكتشفة (Zero-day attacks)، لأن عملية التعرف على نشاط المستخدم غير الطبيعي لا تعتمد على قاعدة بيانات التوقيعات. تطلق أنظمة AIDS إشارة خطر عندما يختلف السلوك الذي يتم فحصه عن السلوك المعتاد.

علاوة على ذلك، تتمتع أنظمة AIDS بفوائد أخرى متعددة:

* اكتشاف الأنشطة الخبيثة الداخلية: إذا بدأ متطفل في إجراء معاملات على حساب مسروق لا تتطابق مع نشاط المستخدم المعتاد، فإن النظام يطلق إنذاراً.

* صعوبة التجاوز: من الصعب جداً على المخترقين تحديد ما هو السلوك "الطبيعي" للمستخدم دون إطلاق إنذار، لأن النظام مصمم بناءً على ملفات تعريف مخصصة. يمكن لأنظمة SIDS أن تحدد فقط التطفلات المعروفة جيداً، بينما يمكن لأنظمة AIDS أن تكشف عن الهجمات على الثغرات الغير المكتشفة بعد . ومع ذلك، يمكن أن تؤدي أنظمة AIDS إلى معدل عالٍ من الإنذارات الكاذبة (False Positive)، لأن بعض الشذوذ قد يكون مجرد أنشطة طبيعية جديدة بدلاً من تطفلات حقيقية.

نظرًا لغياب تصنيف شامل لأنظمة كشف التطفل القائمة على الشذوذ، فقد تم تصنيفها هنا إلى خمس فئات فرعية بناءً على ميزاتها: القائمة على الإحصاء، القائمة على الأنماط، القائمة على القواعد، القائمة على الحالة، والقائمة على الاستدلال.

تقنيات لتطبيق أنظمة كشف التطفل القائمة على الشذوذ (AIDS) :

يقدم هذا القسم نظرة عامة على مناهج أنظمة كشف التطفل القائمة على الشذوذ (AIDS) التي تم اقتراحها في السنوات الأخيرة، بهدف تحسين دقة الكشف وتقليل الإنذارات الكاذبة.

يمكن تصنيف أساليب AIDS إلى ثلاث مجموعات رئيسية:

* الأساليب القائمة على الإحصاء (Statistics-based): تتضمن هذه الأساليب جمع وفحص كل سجل بيانات في مجموعة من العناصر، ثم بناء نموذج إحصائي لسلوك المستخدم الطبيعي.

* الأساليب القائمة على المعرفة (Knowledge-based): تحاول هذه الأساليب تحديد الأنشطة المطلوبة من بيانات النظام الموجودة، مثل مواصفات البروتوكول وحالات حركة مرور الشبكة.

* الأساليب القائمة على التعلم الآلي (Machine-learning based): تكتسب هذه الأساليب قدرات معقدة على مطابقة الأنماط من خلال بيانات التدريب.

يوضح الشكل 2 هذه الفئات الثلاث، بالإضافة إلى أمثلة على فئاتها الفرعية.

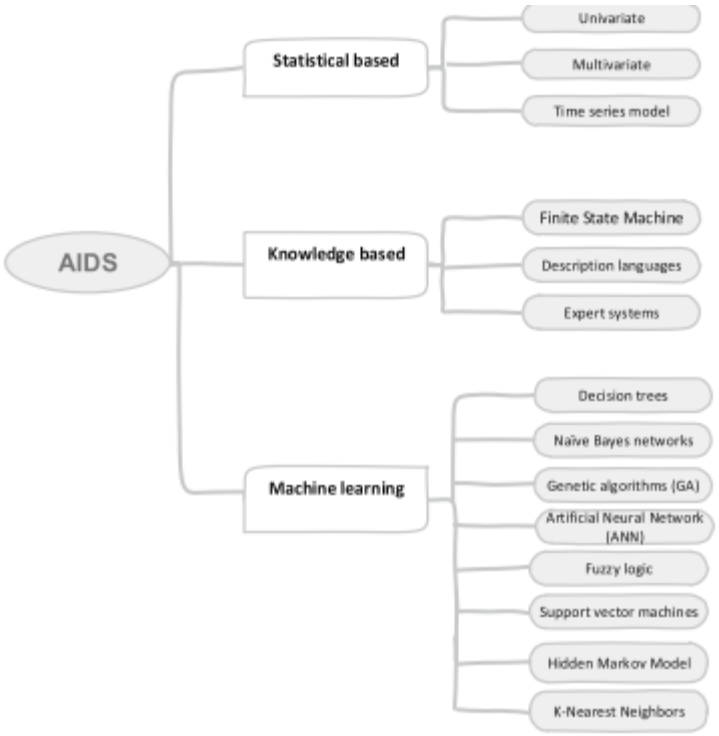

الشكل 10-1: تصنيف أساليب AIDS.

التقنيات القائمة على المعرفة :

تُعرف هذه المجموعة من التقنيات أيضًا بأسلوب "نظام الخبير". يتطلب هذا النهج إنشاء قاعدة معرفية تعكس ملف تعريف حركة المرور الشرعية. الأنشطة التي تختلف عن هذا الملف القياسي تُعامَل على أنها تطفل.

على عكس الفئات الأخرى من أنظمة AIDS، يتم إنشاء نموذج الملف القياسي عادةً بناءً على المعرفة البشرية، في شكل مجموعة من القواعد التي تحاول تعريف نشاط النظام الطبيعي.

الميزة الرئيسية للتقنيات القائمة على المعرفة هي القدرة على تقليل الإنذارات الكاذبة (false-positive alarms)، لأن النظام يمتلك معرفة بكل السلوكيات الطبيعية. ومع ذلك، في بيئة حوسبة تتغير ديناميكيًا، يحتاج هذا النوع من أنظمة IDS إلى تحديث منتظم للمعلومات المتعلقة بالسلوك الطبيعي المتوقع، وهي مهمة تستغرق وقتًا طويلاً، حيث إن جمع المعلومات حول جميع السلوكيات الطبيعية أمر صعب للغاية.

الآلة ذات الحالات المنتهية (Finite state machine – FSM):

FSM هو نموذج حوسبي يُستخدم لتمثيل تدفق التنفيذ والتحكم فيه. يمكن تطبيق هذا النموذج في كشف التطفل لإنتاج نموذج نظام كشف تطفل. عادةً ما يتم تمثيل النموذج في شكل حالات، وانتقالات، وأنشطة. تقوم الحالة بفحص البيانات التاريخية. على سبيل المثال، يتم ملاحظة أي تغييرات في المدخلات، وبناءً على التغيير المكتشف، يحدث الانتقال. يمكن لنموذج FSM أن يمثل سلوك النظام الشرعي، وأي انحراف ملحوظ عن هذا النموذج يعتبر هجومًا.

لغة الوصف (Description Language):

تعرّف لغة الوصف بناء القواعد التي يمكن استخدامها لتحديد خصائص هجوم معين. يمكن بناء القواعد بواسطة لغات وصف مثل N-grammars و UML.

النظام الخبير (Expert System):

يحتوي النظام الخبير على عدد من القواعد التي تحدد الهجمات. في النظام الخبير، عادة ما يتم تعريف القواعد يدوياً من قبل مهندس معرفة يعمل بالتعاون مع خبير في المجال.

تحليل التوقيع (Signature analysis):

هي أقدم تقنية مطبقة في أنظمة IDS. تعتمد على الفكرة البسيطة لمطابقة النصوص. في مطابقة النصوص، يتم فحص الحزمة الواردة، كلمة بكلمة، مع توقيع مميز. إذا تطابق التوقيع، يتم إطلاق إنذار. وإن لم يتطابق، يتم مطابقة المعلومات الموجودة في حركة المرور مع التوقيع التالي في قاعدة بيانات التوقيعات.

التعلم الخاضع للإشراف في أنظمة كشف التطفل (IDS) :

يعرض هذا القسم تقنيات التعلم الخاضع للإشراف المختلفة المستخدمة في أنظمة كشف التطفل. كل تقنية يتم تقديمها بالتفصيل مع إشارات إلى منشورات بحثية مهمة.

تقنيات أنظمة كشف التطفل القائمة على التعلم الخاضع للإشراف (Supervised learning) تكشف عن التطفلات باستخدام بيانات تدريب مصنفة. يتكون هذا النهج عادةً من مرحلتين: التدريب والاختبار. في مرحلة التدريب، يتم تحديد الميزات والفئات ذات الصلة ثم تتعلم الخوارزمية من عينات البيانات هذه. في أنظمة IDS القائمة على التعلم تحت الإشراف، كل سجل هو زوج، يحتوي على مصدر بيانات للشبكة أو الجهاز وله قيمة مخرجة مرتبطة به (أي تصنيف)، إما "تطفل" أو "طبيعي". بعد ذلك، يمكن تطبيق عملية اختيار الميزات لإزالة الميزات غير الضرورية. باستخدام بيانات التدريب للميزات المختارة، تُستخدم تقنية التعلم تحت الإشراف لتدريب مصنف لتعلم العلاقة الجوهرية الموجودة بين بيانات الإدخال وقيمة المخرج المصنفة. تم استكشاف مجموعة واسعة من تقنيات التعلم تحت الإشراف في الأدبيات البحثية، لكل منها مزاياها وعيوبها. في مرحلة الاختبار، يتم استخدام النموذج المدرب لتصنيف البيانات غير المعروفة إلى فئة "تطفل" أو "طبيعي". يصبح المصنف الناتج نموذجًا يتنبأ، عند إعطائه مجموعة من قيم الميزات، بالفئة التي قد تنتمي إليها بيانات الإدخال. يوضح الشكل 3 نهجًا عامًا لتطبيق تقنيات التصنيف.

هناك العديد من طرق التصنيف مثل أشجار القرار (Decision trees)، والأنظمة القائمة على القواعد (Rule-based systems)، والشبكات العصبية (Neural networks)، وآلات المتجهات الداعمة (Support Vector Machines)، وناييف بايز (Naïve Bayes)، وأقرب جار (Nearest-neighbor).

تستخدم كل تقنية طريقة تعلم لبناء نموذج تصنيف. ومع ذلك، يجب أن يكون نهج التصنيف المناسب قادرًا ليس فقط

على التعامل مع بيانات التدريب، بل يجب أن يحدد بدقة فئة السجلات التي لم يرها من قبل. يعد إنشاء نماذج تصنيف ذات قدرة تعميم موثوقة مهمة مهمة لخوارزمية التعلم.

أشجار القرار (Decision trees): تتكون شجرة القرار من ثلاثة مكونات أساسية. المكون الأول هو عقدة القرار (decision node)، والتي تستخدم لتحديد خاصية اختبار. والثاني هو الفرع (branch)، حيث يمثل كل فرع قرارًا ممكنًا بناءً على قيمة خاصية الاختبار. والثالث هو الورقة (leaf) التي تحتوي على الفئة التي ينتمي إليها العنصر. هناك العديد من خوارزميات أشجار القرار المختلفة بما في ذلك 3ID و4.5C و CART.

ناييف بايز (Naïve Bayes): يعتمد هذا النهج على تطبيق مبدأ بايز مع افتراضات استقلالية قوية بين الخصائص. يجيب ناييف بايز على أسئلة مثل "ما هو احتمال حدوث نوع معين من الهجوم، بالنظر إلى أنشطة النظام الملحوظة ؟" من خلال تطبيق صيغ الاحتمال الشرطي. يعتمد ناييف بايز على الميزات التي لها احتمالات مختلفة للحدوث في الهجمات والسلوك الطبيعي. يُعد نموذج تصنيف ناييف بايز أحد أكثر النماذج شيوعًا في أنظمة كشف التطفل نظرًا لسهولة استخدامه وكفاءته الحسابية، وكلاهما مستمد من خاصية افتراض الاستقلالية الشرطية. ومع ذلك، لا يعمل النظام بشكل جيد إذا كان افتراض الاستقلالية هذا غير صالح، كما تم إظهاره على مجموعة بيانات 99'KDD لكشف التطفل التي تحتوي على تبعيات خصائص معقدة. تكشف النتائج أيضًا أن نموذج ناييف بايز لديه دقة منخفضة لمجموعات البيانات الكبيرة. أظهرت دراسة أخرى أنه يمكن تطبيق نموذج Hidden Naïve Bayes (HNB) الأكثر تطورًا على مهام IDS التي تتضمن أبعادًا عالية، وخصائص مترابطة للغاية، وشبكات عالية السرعة.

الخوارزميات الجينية (Genetic algorithms – GA): الخوارزميات الجينية هي نهج استرشادي (heuristic) للتحسين، يعتمد على مبادئ التطور. يتم تمثيل كل حل ممكن كسلسلة من البتات (الجينات) أو كروموسوم، وتتحسن جودة الحلول بمرور الوقت من خلال تطبيق عوامل الاختيار والتكاثر، مع تفضيل الحلول الأكثر ملاءمة. عند تطبيق خوارزمية جينية على مشكلة تصنيف التطفل، يوجد عادةً نوعان من ترميز الكروموسوم: أحدهما يكون وفقًا للتجميع لتوليد طريقة ترميز كروموسوم ثنائي؛ والآخر هو تحديد مركز التجميع (مصفوفة نموذج التجميع) بواسطة كروموسوم ترميز عدد صحيح.

* استخدم Murray et al. GA لتطوير قواعد بسيطة لحركة مرور الشبكة. يتم تمثيل كل قاعدة كجينوم، والعدد الأساسي للجينومات هو عدد من القواعد العشوائية. يتكون كل جينوم من جينات مختلفة تتوافق مع خصائص مثل IP المصدر، وIP الوجهة، ومنفذ المصدر، ومنفذ الوجهة، ونوع بروتوكول واحد.

الشبكة العصبية الاصطناعية (Artificial Neural Network – ANN): تعد ANN واحدة من أكثر طرق التعلم الآلي تطبيقًا على نطاق واسع وقد ثبت نجاحها في اكتشاف البرامج الضارة المختلفة.

تقنية التعلم الأكثر شيوعًا المستخدمة في التعلم تحت الإشراف هي خوارزمية الانتشار الخلفي (backpropagation – BP). تقييم خوارزمية BP تدرج خطأ الشبكة فيما يتعلق بأوزانها القابلة للتعديل. ومع ذلك، بالنسبة لأنظمة IDS القائمة على ANN، لا تزال دقة الكشف، خاصة للهجمات الأقل شيوعًا، ودقة الكشف بحاجة إلى تحسين. مجموعة بيانات التدريب للهجمات الأقل شيوعًا صغيرة مقارنة بتلك الخاصة بالهجمات الأكثر شيوعًا، وهذا يجعل من الصعب على ANN تعلم خصائص هذه الهجمات بشكل صحيح. نتيجة لذلك، تكون دقة الكشف أقل للهجمات الأقل شيوعًا. في مجال أمن المعلومات، يمكن أن يحدث ضرر كبير إذا لم يتم اكتشاف

الهجمات منخفضة التردد. على سبيل المثال، إذا أفلتت هجمات(User to Root (U2R من الكشف، يمكن لمجرم إلكتروني الحصول على امتيازات ترخيص مستخدم الجذر وبالتالي تنفيذ أنشطة ضارة على أنظمة الكمبيوتر الخاصة بالضحية. بالإضافة إلى ذلك، غالبًا ما تكون الهجمات الأقل شيوعًا شاذة. غالبًا ما تعاني ANNs من الحدود الدنيا المحلية، وبالتالي يمكن أن يصبح التعلم مستهلكًا للوقت للغاية. تكمن قوة ANN في أنها، مع وجود طبقة مخفية أو أكثر، قادرة على إنتاج نماذج غير خطية بدرجة عالية تلتقط العلاقات المعقدة بين خصائص الإدخال وتصنيفات التصنيف. مع تطوير العديد من المتغيرات مثل الشبكات العصبية المتكررة و الالتفافية، تعد ANNs أدوات قوية في العديد من مهام التصنيف بما في ذلك IDS.

المنطق الضبابي (Fuzzy logic): تعتمد هذه التقنية على درجات عدم اليقين بدلاً من المنطق البولياني الثنائي الصحيح أو الخاطئ الذي تم بناء أجهزة الكمبيوتر المعاصرة عليه. لذلك، تقدم طريقة مباشرة للوصول إلى استنتاج نهائي بناءً على بيانات إدخال غير واضحة أو غامضة أو مشوشة أو غير دقيقة أو مفقودة. باستخدام مجال ضبابي، يسمح المنطق الضبابي للعنصر بالانتماء، جزئيًا ربما، إلى فئات متعددة في نفس الوقت. لذلك، يعد المنطق الضبابي مصنفًا جيدًا لمشاكل IDS لأن الأمن نفسه يتضمن غموضًا، والحدود الفاصلة بين الحالات الطبيعية وغير الطبيعية ليست محددة جيدًا. بالإضافة إلى ذلك، تحتوي مشكلة كشف التطفل على ميزات رقمية مختلفة في البيانات المجمعة والعديد من المقاييس الإحصائية المستمدة. يؤدي بناء أنظمة IDS بناءً على بيانات رقمية بحدود صارمة إلى إنذارات كاذبة عالية. لا يمكن التعرف على نشاط ينحرف قليلاً فقط عن النموذج أو قد يؤدي تغيير طفيف في النشاط الطبيعي إلى إنذارات كاذبة. باستخدام المنطق الضبابي، من الممكن نمذجة هذا الشذوذ البسيط للحفاظ على المعدلات الكاذبة منخفضة. أظهرت Elhag et al. أنه باستخدام المنطق الضبابي، يمكن تقليل معدل الإنذار الكاذب في تحديد الإجراءات

التطفلية. وقد قاموا بتحديد مجموعة من القواعد الضبابية لوصف الأنشطة الطبيعية وغير الطبيعية في نظام الكمبيوتر، ومحرك استدلال ضبابي لتحديد التطفلات.

آلات المتجهات الداعمة SVM: (Support Vector Machines – SVM)هو مصنف تمييزي يتم تعريفه بواسطة مستوى فاصل. تستخدم SVMs دالة نواة (kernel) لتعيين بيانات التدريب في فضاء ذي أبعاد أعلى بحيث يتم تصنيف التطفل بشكل خطي. تشتهر SVMs بقدرتها على التعميم وهي ذات قيمة أساسية عندما يكون عدد الخصائص كبيرًا وعدد نقاط البيانات صغيرًا. يمكن تحقيق أنواع مختلفة من المستويات الفاصلة عن طريق تطبيق دالة نواة، مثل Linear، Polynomial، Gaussian Radial Basis Function (RBF)، أو Hyperbolic tangent. في مجموعات بيانات IDS، العديد من الميزات زائدة عن الحاجة أو أقل تأثيرًا في فصل نقاط البيانات إلى فئات صحيحة. لذلك، يجب أخذ اختيار الميزات في الاعتبار أثناء تدريب SVM. يمكن أيضًا استخدام SVM للتصنيف في فئات متعددة. في العمل الذي قام به Li et al.، تم تطبيق مصنف SVM مع نواة RBF لتصنيف مجموعة بيانات KDD 1999 إلى فئات محددة مسبقًا. من إجمالي 41 خاصية، تم اختيار مجموعة فرعية من الميزات بعناية باستخدام طريقة اختيار الميزات.

نموذج ماركوف المخفي HMM: (Hidden Markov Model – HMM)هو نموذج ماركوف إحصائي يُفترض فيه أن النظام الذي يتم نمذجته هو عملية ماركوف ذات بيانات غير مرئية. أظهرت الأبحاث السابقة أنه يمكن تطبيق تحليل HMM لتحديد أنواع معينة من البرامج الضارة. في هذه التقنية، يتم تدريب نموذج ماركوف المخفي مقابل ميزات البرامج الضارة المعروفة (مثل تسلسل رمز العملية) وبمجرد اكتمال مرحلة التدريب، يتم تطبيق النموذج

المدرب لتسجيل حركة المرور الواردة. ثم يتم مقارنة النتيجة بحد محدد مسبقًا، وتشير النتيجة الأكبر من الحد إلى وجود برنامج ضار. وبالمثل، إذا كانت النتيجة أقل من الحد، يتم تحديد حركة المرور على أنها طبيعية.

مصنف أقرب جار (K-Nearest Neighbors - KNN): تقنية أقرب جار (k-NN) هي مصنف نموذجي غير معلمي يُطبق في التعلم الآلي.

فكرة هذه التقنيات هي تسمية عينة بيانات غير مصنفة إلى فئة أقرب k من جيرانها (حيث k هو عدد صحيح يحدد عدد الجيران المراد أخذهم في الاعتبار). يوضح الشكل 5 مصنف K-Nearest Neighbors حيث k = 5. تمثل النقطة X مثيلاً لتاريخ غير مصنف يحتاج إلى تصنيف. من بين أقرب خمسة جيران لـ X، هناك ثلاثة أنماط مماثلة من فئة "تطفل" واثنان من فئة "طبيعي". يتيح التصويت بالأغلبية تعيين X إلى فئة "تطفل".

يمكن تطبيق k-NN بشكل مناسب كمعيار لجميع المصنفات الأخرى لأنه يوفر أداء تصنيف جيدًا في معظم أنظمة IDS.

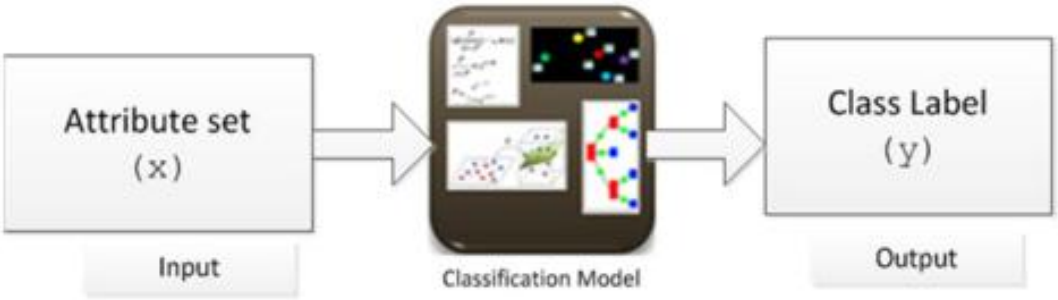

الشكل 11-1: التصنيف كمهمة.

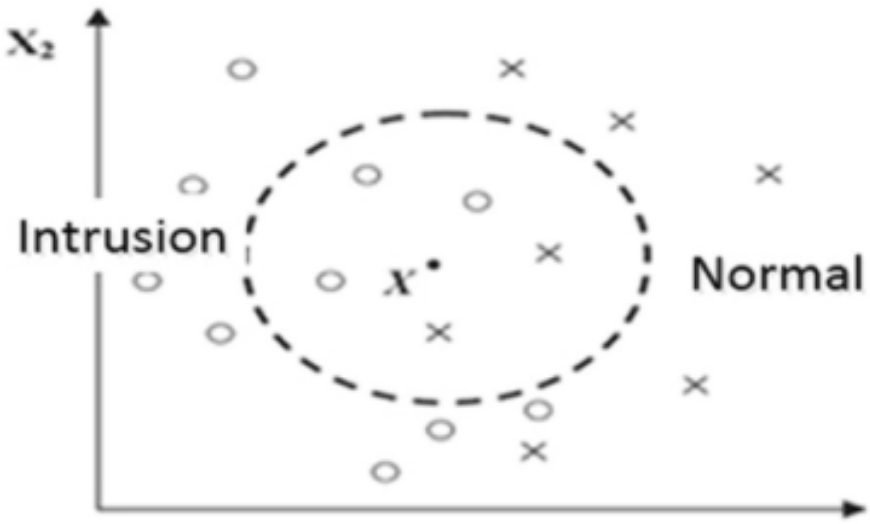

الشكل 12-1: مثال على التصنيف حسب اقرب جار ل k=5.

التعلم غير الخاضع للإشراف في نظام كشف التطفل (IDS) :

يُعدّ التعلم غير الخاضع للإشراف (Unsupervised learning) أحد فروع التعلم الآلي الذي يُستخدم لاستخلاص معلومات هامة من مجموعات بيانات الإدخال التي لا تحتوي على تصنيفات مسبقة. في هذا النهج، تُعامل نقاط بيانات الإدخال عادةً كمجموعة من المتغيرات العشوائية. بعد ذلك، يتم إنشاء نموذج كثافة مشترك لمجموعة البيانات بأكملها.

بينما يعتمد التعلم غير الخاضع للإشراف على تصنيفات محددة لتدريب النموذج، فإن التعلم غير تحت الإشراف يعمل بشكل مختلف؛ حيث لا تُعطى أي تصنيفات، بل يتم تجميع البيانات تلقائيًا في فئات مختلفة من خلال عملية التعلم. في سياق تطوير نظام كشف تطفل، يعني التعلم غير الخاضع للإشراف استخدم آلية لتحديد التطفلات بالاعتماد على بيانات غير مصنفة لتدريب النموذج.

بمجرد تجميع السجلات، يتم تصنيف جميع الحالات التي تظهر في المجموعات الصغيرة على أنها تطفل، وذلك لأن الحالات الطبيعية من المفترض أن تُنتج مجموعات كبيرة مقارنة بالشذوذ. بالإضافة إلى ذلك، بما أن التطفلات الخبيثة والحالات الطبيعية غير متشابهة، فإنها لا تقع في نفس المجموعة.

* خوارزمية K-means (المتوسطات): تُعدّ تقنية K-means من أكثر تقنيات التحليل التجمعي شيوعاً، وتهدف إلى فصل 'n' من كائنات البيانات إلى 'k' من المجموعات، حيث يتم اختيار كل كائن بيانات في المجموعة الأقرب إلى متوسطها. إنها تقنية تجميع تعتمد على المسافة ولا تحتاج إلى حساب المسافات بين جميع توليفات السجلات. تستخدم مقياس المسافة الإقليدية كمقياس للتشابه. يتم تحديد عدد المجموعات مسبقًا من قبل المستخدم.

* التجميع الهرمي (Hierarchical Clustering): هذه تقنية تجميع تهدف إلى إنشاء هيكل هرمي للمجموعات. تُصنف مناهج التجميع الهرمي عادةً إلى فئتين:

* التجميع التراكمي (Agglomerative): وهو نهج "من الأسفل إلى الأعلى" حيث تحتوي المجموعات على مجموعات فرعية، والتي بدورها تحتوي على مجموعات فرعية، ويتم دمج أزواج من المجموعات معاً كلما صعدنا في الهيكل الهرمي.

* التجميع الانقسامي (Divisive): وهو نهج "من الأعلى إلى الأسفل" حيث يتم تكرارًا اختيار المجموعة ذات القطر الأكبر في فضاء الميزات وتقسيمها إلى مجموعات فرعية ثنائية بمدى أقل.

لقد تم إنجاز الكثير من الأبحاث في مجال أنظمة التحكم السيبرانية-الفيزيائية (CPCS) فيما يتعلق بكشف الهجمات وتخفيفها باستخدام التعلم غير الخاضع للإشراف. على سبيل المثال، اقترح Alcaraz نهجًا يعتمد على التكرار لتحقيق المرونة. كما اقترح طبقة شبكة فرعية مخصصة لديها القدرة على التعامل مع السياق عن طريق جمع المعلومات بالإجماع

من عقد السائقين التي يتم التحكم فيها في شبكة التحكم نفسها، والتمييز بين وجهات النظر المختلفة من خلال تقنيات استخراج البيانات مثل k-means وk-nearest neighbor. اقترح Chao Shen وآخرون تقنية "بصمة الجهاز الهجينة المعززة" (Hybrid-Augmented device fingerprinting) لأنظمة كشف التطفل في شبكات التحكم الصناعية. وقد استخدموا تقنيات تعلم آلي مختلفة لتحليل حزم الشبكة لتصفية حركة المرور الشاذة لاكتشاف التطفلات في شبكات أنظمة التحكم الصناعية.

التعلم شبه الخاضع للإشراف في نظام كشف التطفل (IDS) :

يقع التعلم شبه الخاضع للإشراف (Semi-supervised learning) في منطقة وسطى بين التعلم شبه الخاضع للإشراف (الذي يستخدم بيانات تدريب مصنفة بالكامل) والتعلم غير الخاضع للإشراف (الذي لا يستخدم أي بيانات تدريب مصنفة).

لقد أظهر الباحثون أن التعلم شبه الخاضع للإشراف يمكن استخدامه مع كمية قليلة من البيانات المصنفة لتعزيز أداء المصنفات في أنظمة كشف التطفل، مع تقليل الوقت والتكاليف المطلوبة. هذه الميزة ذات قيمة كبيرة، لأن البيانات المصنفة لمشاكل كشف التطفل غالبًا ما تكون نادرة أو يصعب الحصول عليها.

تم اقتراح عدد من التقنيات المختلفة للتعلم شبه الخاضع للإشراف، مثل خوارزميات "توقع الحد الأقصى" (Expectation Maximization)، و "التدريب الذاتي" (self-training)، و"التدريب المشترك" (co-training) ، بالإضافة إلى آلات المتجهات الداعمة شبه تحت الإشراف (Semi-Supervised SVM)، والأساليب القائمة على الرسوم البيانية، وأساليب التعلم شبه تحت الإشراف القائمة على التعزيز (boosting).

يقترح "رانا وآخرون" منهجًا جديدًا للتعلم شبه الخاضع للإشراف يعتمد على المنطق الضبابي (fuzzy-based)، وذلك بتطبيق عينات غير مصنفة مدعومة بخوارزمية تعلم الخاضع للإشراف لتعزيز أداء المصنف في أنظمة كشف التطفل. يتم تدريب شبكة عصبية أمامية بطبقة مخفية واحدة لإخراج متجه عضوية ضبابي، ويتم تصنيف العينات غير المصنفة إلى فئات (ضبابية منخفضة، متوسطة، وعالية) باستخدام الكمية الضبابية. يتم إعادة تدريب المصنف بعد دمج كل فئة بشكل منفصل في مجموعة التدريب الأصلية.

أظهرت نتائجهم التجريبية، باستخدام هذا النهج شبه الخاضع للإشراف لكشف التطفل على مجموعة بيانات NSL-KDD، أن العينات غير المصنفة التي تنتمي إلى مجموعات الضبابية المنخفضة والعالية تساهم بشكل كبير في تعزيز دقة أنظمة كشف التطفل مقارنة بالأساليب التقليدية.

تقنيات قائمة على الهجين :

تواجه أنظمة كشف التطفل التقليدية (IDS) مجموعة من القيود: يصعب تعديلها بسهولة، وتفشل في التعرف على الهجمات الخبيثة الجديدة، كما أنها تعاني من انخفاض الدقة وارتفاع معدل الإنذارات الكاذبة. وفي المقابل، فإن أنظمة AIDS وحدها لديها قيود مثل ارتفاع معدل الإنذارات الإيجابية الكاذبة.

للتغلب على هذه المشكلات، ظهرت أنظمة كشف التطفل الهجينة (Hybrid IDS) التي تعتمد على دمج تقنيات SIDS, AIDS. يجمع النظام الهجين بين نقاط القوة في كلا المنهجين، مما يمكنه من تجاوز نقاط الضعف الخاصة بكل منهما على حدة.

على سبيل المثال، اقترح "فريد وآخرون" نظام IDS هجينًا يجمع بين خوارزميات نايف بايز وأشجار القرار، وقد حقق هذا النموذج معدل كشف بلغ 99.63% على مجموعة بيانات KDD'99.

مقاييس الأداء لأنظمة كشف التطفل (IDS) :

توجد العديد من مقاييس التصنيف لأنظمة كشف التطفل، وبعضها يُعرف بأسماء متعددة ، يتم عادةً تقييم أنظمة IDS بناءً على مقاييس الأداء القياسية التالية:

* معدل الإيجابية الحقيقية (True Positive Rate – TPR): يُحسب كنسبة عدد الهجمات التي تم التنبؤ بها بشكل صحيح إلى العدد الإجمالي للهجمات. إذا تم اكتشاف جميع التطفلات، فإن TPR يساوي 1، وهو أمر نادر للغاية بالنسبة لأي نظام IDS. يُعرف TPR أيضًا باسم "معدل الكشف" (Detection Rate – DR) أو "الحساسية" (Sensitivity).

* معدل الإيجابية الكاذبة (False Positive Rate – FPR): يُحسب كنسبة عدد الحالات الطبيعية التي تم تصنيفها بشكل خاطئ على أنها هجوم إلى العدد الإجمالي للحالات الطبيعية.

* معدل السلبية الكاذبة (False Negative Rate – FNR): تعني السلبية الكاذبة أن الكاشف فشل في تحديد شذوذ ما، وصنفه على أنه طبيعي.

* معدل التصنيف (Classification rate – CR) أو الدقة (Accuracy): يقيس CR مدى دقة نظام IDS في اكتشاف سلوك حركة المرور الطبيعية أو الشاذة. يُوصف بأنه النسبة المئوية لجميع الحالات التي تم التنبؤ بها بشكل صحيح إلى جميع الحالات.

* منحنى خاصية تشغيل المستقبِل (Receiver Operating Characteristic – ROC): يحتوي هذا المنحنى على محور x يمثل معدل الإيجابية الكاذبة (FPR) ومحور y يمثل معدل الإيجابية الحقيقية (TPR). في منحنى ROC، يتم رسم TPR كدالة لـ FPR لنقاط قطع مختلفة. تمثل كل نقطة على منحنى ROC زوجًا من

FPR و TPR يتوافق مع عتبة قرار معينة. عندما تتغير العتبة الخاصة بالتصنيف، يتم اختيار نقطة مختلفة على منحنى ROC بمعدل إنذار كاذب (FAR) و TPR مختلفين. أي اختبار يتميز بتمييز مثالي (لا يوجد تداخل بين التوزيعين) يمتلك منحنى ROC يمر عبر الزاوية العلوية اليسرى (حساسية 100%، خصوصية 100%).

الفصل الثاني :الدراسة النظرية المتقدمة :

الحساسات المستخدمة في انظمة المنازل الذكية :

تلعب الحساسات دورًا بالغ الأهمية في تطوير أنظمة المنازل الذكية (**Smart Home Systems – SHSs**) وقد تم تحديد تطبيق عدة أنواع من الحساسات خلال مرحلة مراجعة حلقات البحث السابقة.

يقدّم هذا القسم تفصيلًا لأنواع الحساسات المستخدمة في تصميم وتطوير وتنفيذ أنظمة المنازل الذكية.

1. حساس الأشعة تحت الحمراء (**Infrared Sensor – IR**)

من الناحية النظرية، فإن جميع الأجسام والكائنات الحية التي تمتلك حدًّا أدنى من درجة الحرارة تبعث إشعاعًا تحت أحمر وحساس الأشعة تحت الحمراء هو جهاز إلكتروني قادر على اكتشاف وقياس الإشعاع تحت الأحمر في البيئة المحيطة به.

السبب الرئيسي لاستخدام حساسات الأشعة تحت الحمراء هو كشف الحركة وقياس درجة الحرارة.

توجد فئتان من هذه الحساسات:

الحساس النشط (**Active IR Sensor**) و الحساس السلبي (**Passive Infrared Sensor – PIR**) ومن بينهما، يُعد **PIR** الأكثر استخدامًا في أنظمة المنازل الذكية.

يعمل حساس **PIR** على اكتشاف التغير في مستويات الإشعاع الكهرومغناطيسي في البيئة المحيطة به، وهو لا يصدر إشعاعًا بنفسه كما في النوع النشط.

يُستخدم هذا النوع أساسًا في كشف الحركة؛ فعندما يدخل جسم ضمن نطاق الحساس، يقيس الفرق في مستويات الأشعة تحت الحمراء ويحدد وجوده.

في أنظمة المنازل الذكية، يُستخدم حساس **PIR** في:

أنظمة الإنذار ضد التسلل.

الكشف عن نشاط الأشخاص داخل المنزل.

إنشاء أنظمة رعاية صحية للمسنين .

ومع ذلك، يُفضَّل استخدام حساسات **PIR** داخل المنازل لأنها تتأثر بالتغيرات البيئية مثل المطر أو الثلوج.

2.حساس الحرارة (**Temperature Sensor**)

يعمل حساس الحرارة على قياس درجة حرارة البيئة المحيطة لضمان راحة المعيشة وقد استُخدمَت عدة أنواع من هذه الحساسات في تطوير أنظمة المنازل الذكية تُستخدم حساسات الحرارة لقياس درجة حرارة الغرف، وبناءً على تلك القراءات تُتحكم أجهزة أخرى مثل المراوح والمكيفات والسخانات.

3.حساس الرطوبة (**Humidity Sensor**)

تقوم حساسات الرطوبة بكشف وقياس التغير في كمية بخار الماء أو الرطوبة في الهواء المحيط بها أشهر هذه الحساسات هو **DHT11**، الذي يمكنه أيضًا قياس درجة الحرارة في أنظمة المنازل الذكية، يُستخدم حساس الرطوبة عادةً في:

مراقبة مستوى الرطوبة في الغرف.

أنظمة التشغيل الآلي للمنزل (**Home Automation**).

أنظمة الإنذار المبكر.

4. حساس الغاز (**Gas Sensor**

تكشف حساسات الغاز وجود أنواع معينة من الغازات في الهواء ضمن نطاقها.تُستخدم عادة لاكتشاف الغازات الضارة أو الخطرة مثل غاز البترول المسال (**LPG**)، والبروبان، والميثان، وأول أكسيد الكربون، والبيوتان، والكحول تكتسب هذه الحساسات أهمية خاصة في تطوير أنظمة المنازل الذكية لأنها تقدّم إنذارًا مبكرًا بوجود غازات خطيرة داخل المنزل

5. حساس الدخان (**Smoke Sensor**)

هو جهاز إلكتروني يكتشف وجود الدخان في محيطه ويُفعّل إنذارًا عند اكتشافه تُستخدم حساسات الدخان كإجراء احترازي ضمن أنظمة الإنذار المبكر ضد الحرائق في أنظمة المنازل الذكية، تُبرمج هذه الحساسات عادةً لإطلاق إنذار أو إرسال إشارة تحذيرية إلى سكان المنزل عبر رسالة **GSM** أو تطبيق إلكتروني.

6. الحساس فوق الصوتي (**Ultrasonic Sensor**)

يقوم هذا الحساس بإصدار واستقبال الموجات الصوتية فوق السمعية لقياس المسافة إلى جسم معين.

تتم العملية من خلال إرسال موجات صوتية نحو الهدف، واستقبال الموجة المنعكسة منه، ثم تحويلها إلى إشارة إلكترونية

في أنظمة المنازل الذكية، يُستخدم الحساس فوق الصوتي في:

أنظمة الأبواب الأوتوماتيكية .

مراقبة مستوى المياه .

تطبيقات الأتمتة المنزلية الأساسية.

7. حساس اللهب (**Flame Sensor**)

هو جهاز إلكتروني صُمم خصيصًا للكشف عن وجود النار ضمن نطاق عمله، ويستجيب عادة بإطلاق إنذار أو تفعيل آلية تحذير تستخدم أنظمة المنازل الذكية التي تركز على الأمان هذه الحساسات للكشف المبكر عن الحرائق داخل المنزل وتحذير المستخدمين.

8. حساس الإضاءة (**Light Detection Sensor**)

يُستخدم هذا الحساس لقياس شدة الإضاءة في منطقة معينة وهو جهاز ضوئي كهربائي قادر على تحويل طاقة الضوء المحيطة إلى طاقة كهربائية توجد عدة أنواع من حساسات الإضاءة مثل المقاومات الضوئية (**Photoresistors**)، والثنائيات الضوئية (**Photodiodes**)، والترانزستورات الضوئية (**Phototransistors**).

في أنظمة المنازل الذكية، تُستخدم هذه الحساسات عادة في:

أتمتة نظام الإضاءة في المنزل.

في أحد الأنظمة الخاصة، استُخدم حساس الضوء لإعلام الشخص الكفيف بما إذا كان الوقت نهارًا أم ليلًا

10. مقياس التسارع (**Accelerometer**)

مقياس التسارع هو أداة إلكترونية تُستخدم لقياس قوى التسارع بدقة عالية في أنظمة المنازل الذكية (**SHSs**)، تُستخدم مقاييس التسارع لكشف تسارع الأشخاص سواء كانوا في حالة حركة أو سكون ، كما تُستخدم في التعرف على حالات التسلل، ورصد حركة المرضى وحالتهم الصحية داخل المنازل الذكية .

11. حساس الباب (**Door Sensor**)

حساس الباب هو جهاز يكتشف عملية فتح أو إغلاق الباب ويقوم بإشعار المستخدم بذلك.
يعتمد على زوج من الموصلات الكهربائية اللذين يكملان أو يفصلان الدائرة الكهربائية عند فتح أو إغلاق الباب.
تُستخدم هذه الحساسات بشكل متزايد في أنظمة المنازل الذكية للكشف عن حالة الأبواب (مفتوحة أو مغلقة)، خصوصًا ضمن أنظمة رعاية المسنين ، وكذلك في مراقبة النشاط العام للسكان داخل المنزل.

12.الجيروسكوب (**Gyroscope**)

الجيروسكوب، أو حساس السرعة الزاوية، هو جهاز يُستخدم لقياس الاتجاه والسرعة الزاوية لجسم معين والحفاظ على ثباته في أنظمة المنازل الذكية، يُستخدم الجيروسكوب من أجل تحديد وضعية الأشخاص ، وغالبًا ما يُستخدم مع مقياس التسارع كما يُستخدم أيضًا ضمن أنظمة التحكم بالإيماءات (**Gesture Control Systems**) لاكتشاف الإشارات أو الحركات.

13. حساس نبضات القلب (**Pulse Sensor**)

هو جهاز قادر على اكتشاف ومراقبة معدل ضربات القلب البشري بشكل مستمر.
في المنازل الذكية، يُستخدم هذا الحساس بشكل أساسي في أنظمة الرعاية الصحية الخاصة بكبار السن.

14. حساس السوائل أو الماء (**Fluid / Water Detection Sensor**)

ويُعرف أحيانًا باسم حساس قطرات المطر (**Raindrop Sensor**)، وهو جهاز إلكتروني يمكنه كشف وجود الماء عبر لوح معدني ممدود يستشعر الماء على سطحه.

يُستخدم عادة في الكشف عن تسرب المياه ومراقبة مستوى المياه في الخزانات.

15. الكاميرا (**Camera**)

أصبح استخدام الكاميرات، أو شبكات الكاميرات، شائعًا بشكل متزايد في تصميم أنظمة المنازل الذكية.

وقد استخدم الباحثون الكاميرات بالتكامل مع تقنيات حوسبية مختلفة مثل معالجة الصور، والتعلّم الآلي، والتعرّف على الإيماءات، والذكاء الاصطناعي لتحسين الأمان والمراقبة في المنازل الذكية.

تُستخدم الكاميرات أيضًا في:

الكشف عن الأجسام.

التعرف على الإيماءات .

المراقبة الحية بالفيديو (**Live Feed Monitoring**) .

تُعد الكاميرات وسيلة موثوقة لتأمين المنزل ومراقبته، إلا أن العيب الرئيسي لاستخدامها هو ارتفاع تكلفتها وصعوبة صيانتها.

16. حساس القوة (**Force-Sensing Resistor – FSR**)

هو جهاز إلكتروني قادر على قياس مقدار القوة أو الضغط أو الإجهاد الميكانيكي المطبق عليه تعتمد مقاومات **FSR** على مادة خاصة تتغيّر مقاومتها الكهربائية عند تطبيق قوة عليها تُعد من الحساسات المتخصصة المستخدمة في أنظمة المنازل الذكية لكشف نشاط السكان داخل المنزل ، وكذلك في أنظمة الرعاية الخاصة بكبار السن .

17 . حساس الانحناء (**Flex Sensor**)

يُستخدم هذا الحساس لقياس مقدار الانحناء أو الثني في الأجسام يعمل عن طريق تغيّر المقاومة الكهربائية عند انحنائه.

يُستخدم غالبًا في أنظمة التحكم بالإيماءات (**Gesture-Controlled Systems**) لاكتشاف الحركات.

أنواع أخرى من الحساسات (**Other Types of Sensors**)

إضافة إلى الأنواع السابقة، توجد أنواع أخرى من الحساسات المدمجة التي تجمع بين أكثر من نوع في جهاز واحد، مثل:حساسات السرير (**Bed Sensors**)

حساسات الكرسي (**Chair Sensors**)

حساسات الوضعية (**Posture Sensors**)

هذه الحساسات لا تُصنَّف كنوع واحد لأنها تحتوي عادة على عدة حساسات داخلية مثل حساسات الحركة، مقياس التسارع، والجيروسكوب.

أمن أجهزة إنترنت الأشياء (IoT) _ (نقاط الضعف الكامنة في أجهزة إنترنت الأشياء) :

تشير الدراسات الحديثة إلى أنه على الرغم من تزايد شعبية أجهزة إنترنت الأشياء بين العملاء، إلا أنها تفتقر بشكل عام إلى الأمان ، لكي يُعتبر الجهاز آمنًا في سياق أمن المعلومات والشبكات، يجب أن تتوفر فيه الخصائص التالية :

* التعريف (**Identification**): القدرة على تمييز جهاز أو مستخدم معين بناءً على سماته ومعلوماته الفريدة.

* السرية (**Confidentiality**): ضمان أن المعلومات لا يمكن الوصول إليها إلا للمصرح لهم، لحمايتها من وصول المستخدمين غير المصرح بهم أو الخبيثين.

* النزاهة/التكامل (**Integrality**): الحفاظ على دقة واكتمال البيانات، والتأكد من أنها غير مُعدّلة وجديرة بالثقة أثناء عمليات التخزين، النقل، والمعالجة.

* عدم الإنكار (**Undeniability**): عدم قدرة مرسل رسالة معينة أو مُصرح معاملة معينة على إنكار إرسال الرسالة أو التصريح بالمعاملة.

ومع ذلك، فإن تصميم أجهزة إنترنت الأشياء يحد من إمكانياتها، مما يؤدي إلى نقاط ضعف كامنة. أحد الأمثلة على هذا القيد هو محدودية موارد الحوسبة للأجهزة، مما يقيد قدرتها على تطبيق تدابير أمنية شاملة. غالبًا ما يؤدي هذا إلى استخدام غير كافٍ لتشفير البيانات، واستخدام خدمات شبكة غير آمنة، وكلمات مرور افتراضية، والتي تكون عرضة لهجمات (**Brute Force**)، على سبيل المثال من بين نقاط الضعف الكامنة هذه:

*كمية كبيرة من أجهزة إنترنت الأشياء لا تملك القدرة على إجراء تحديثات تلقائية، أو تتطلب من المستخدم تثبيت تصحيحات الأمان يدويًا، عندما يتوقف المصنعون عن تقديم الدعم للإصدارات الأقدم، تصبح الأجهزة معرضة باستمرار لنقاط الضعف الموجودة، كمية البيانات التي تجمعها أجهزة إنترنت الأشياء (مثل مراقبة الموقع المباشر) تشكل

أيضًا نقطة ضعف كامنة، حيث أن الوصول غير المصرح به إليها قد يؤدي إلى انتهاك الخصوصية ، قد يؤدي دمج أجهزة إنترنت الأشياء في أنظمة شبكات أكبر إلى خلق نقاط ضعف يمكن أن تهدد أمن الشبكات بأكملها، حيث أن اختراق جهاز إنترنت الأشياء قد يمنح الخصم إمكانية الوصول إلى معلومات قيمة أو أجزاء حرجة من الشبكة .

فئات الهجمات السيبرانية :

يمكن تقسيم الأنواع المختلفة للهجمات التي قد تُنفذ على أجهزة إنترنت الأشياء إلى أربعة مجالات :

هجمات المادية (**Physical attacks**)

هجمات الشبكة (**Network attacks**)

هجمات البرمجيات (**Software attacks**)

هجمات البيانات (**Data attacks**)

الهجمات المادية: تتطلب من المهاجم الوصول المادي إلى الشبكة أو الجهاز. تشمل هذه الهجمات التعديل المادي للجهاز، أو إدخال شيفرة خبيثة يمكن استخدامها لاحقًا لشن هجمات أخرى. من الأمثلة الإبداعية على ذلك اكتشاف "التحايل الصوتي" (**voice squatting**) في عام 2018، والذي سمح بشن هجمات على أجهزة المساعدات الافتراضية مثل **Amazon Echo** و **Google Home**، عن طريق إعداد أوامر صوتية إما أن تكون مطابقة للأوامر الموجودة صوتياً أو تستغل العامل البشري (مثل استخدام كلمة "من فضلك" بعد الأمر) .

هجمات الشبكة: هي هجمات لا تتطلب قربًا ماديًا ولكنها تستغل نقاط ضعف أنظمة الشبكة. تشمل ما يلي:

تحليل حركة المرور (**Traffic analysis**): للعثور على معلومات سرية قد لا تكون مشفرة أو مشفرة بشكل ضعيف.

إعداد عقدة خبيثة (**Malicious node**): لتغيير، إسقاط، أو إعادة توجيه بعض حزم البيانات بشكل انتقائي.

هجوم الوسيط (**Man in the Middle – MITM**):حيث يحصل المهاجم على معلومات سرية عن طريق التنصت على الاتصال بين جهازين .

هجوم حجب الخدمة (**Denial of Service – DoS**): حيث يقوم المهاجم بإبطاء النظام أو تعطيله عن طريق إغراقه بالرسائل، مثل هجوم حجب الخدمة الموزع (**DDoS**) الذي حدث في أكتوبر 2016 على مزود

خدمة **DNS** يدعى **Dyn**. استخدم الهجوم برمجية خبيثة تسمى **Mirai botnet**، والتي استغلت الأمان الضعيف لأجهزة إنترنت الأشياء (مثل الكاميرات الرقمية ومشغلات **DVR**) لبناء شبكة روبوتية ضخمة (**botnet**) قُدرت بنحو 100,000 نقطة نهاية، واستُخدمت لإحداث حركة مرور زائدة على خوادم **DNS**.

هجمات البرمجيات: ترتبط بأنواع مختلفة من البرامج. تشمل استخدام البرمجيات الخبيثة (**malwares**) لإصابة نظام ما للعبث بالبيانات، سرقة المعلومات، أو شن هجمات **DoS/DDoS**. مثال على ذلك هو **Mirai botnet** نفسه (لاحظ أن الهجوم قد يجمع بين أنواع مختلفة). مثال آخر هو سيطرة مجموعة من الباحثين في عام 2015 على مركبة **Jeep** والتحكم في سرعتها وتوجيهها .

هجمات البيانات: تستخدم أجهزة إنترنت الأشياء الحوسبة السحابية (**Cloud computing**) لتلبية الطلب الكبير على الاتصال وجمع البيانات، تشمل هذه الهجمات:

تضارب البيانات (**Data inconsistency**): أن تكون البيانات المستلمة مختلفة عن البيانات الفعلية.

الوصول غير المصرح به (**Unauthorized access**): حيث قد يحصل المهاجمون على بيانات حساسة لا ينبغي لهم الوصول إليها.

خرق البيانات (**Data breach**): تسريب بيانات شخصية، حساسة، أو سرية غالبًا ما تكمن نقاط الضعف في هذا النوع من الهجمات في وصول المهاجمين من الداخل (**inside access**) ، مما يمكنهم من تعريض المؤسسة لتهديدات الأمن السيبراني .

حجب الخدمة (**Denial of Service – DoS**) :

هجوم **DoS** يبطئ الآلة المستهدفة بشكل كبير أو يوقفها تمامًا عن طريق إغراقها ببيانات غير صالحة أو إرسال عدد كبير جدًا من الطلبات بحيث لا تستطيع معالجتها، مما يؤدي إلى زيادة تحميلها. في أجهزة إنترنت الأشياء، قد يصل هذا النوع من الهجمات إلى جعل الجهاز غير قابل للاستخدام إطلاقاً ويتطلب استبداله أو إعادة تثبيته.

حجب الخدمة الموزع (**Distributed Denial of Service – DDoS**) هو عندما تُستخدم نقاط نهاية متعددة لشن الهجوم، كما حدث في هجوم **Mirai botnet**. بما أن أجهزة إنترنت الأشياء غالبًا ما تكون غير آمنة، فهي هدف سهل للمهاجمين ، أحد الأخطاء الأمنية الكبيرة هو احتواءها على كلمات مرور افتراضية من

الشركة المصنعة. بهذه الطريقة، يمكن للمهاجمين "اختراق" الأجهزة بالقوة الغاشمة وإصابتها ببرامج ضارة يمكن إطلاقها في أي وقت، وهو ما حدث في الهجوم على **Dyn**.

هجوم الوسيط (**Man in the Middle – MITM**) :

هو نوع من الهجوم حيث يقوم الخصم بإعداد عقدة خبيثة في الشبكة لمراقبة والتحكم في الاتصال بين عقدتين شرعيتين. على سبيل المثال، عندما يرسل الجهاز "أ" طلبًا إلى الجهاز "ب"، قد تلتقط العقدة الخبيثة الطلب وتعالج بعض البيانات لمصلحتها قبل إعادة توجيهه إلى الجهاز "ب". إذا تم تنفيذ هذا الهجوم بنجاح، قد يتمكن المهاجم من التلاعب بتدفق حركة المرور، إعادة تكوين الشبكة، إنشاء هويات مزيفة، أو توليد معلومات خبيثة وكاذبة .

توحيد وتنظيم أجهزة إنترنت الأشياء

يعد الافتقار إلى إرشادات موحدة (**Standardized guidelines**) عند تطوير أجهزة إنترنت الأشياء أحد أسباب كونها غير آمنة. يناقش الاتحاد الأوروبي حاليًا تطوير الإطار الأوروبي لشهادة الأمن السيبراني (**ECSCF**) لمعالجة هذه المشكلات، بهدف إنشاء نظام بيئي يمنح شهادات لأجهزة إنترنت الأشياء .

ومع ذلك، هناك تحديات. فبينما توجد منظمات تضع معايير وتقدم شهادات أمنية، فإن عددًا كبيرًا منها لديه حوار نشط مع الحكومات والمصنعين ومقدمي الخدمات. قد يؤدي هذا إلى المساس بمصداقية المعايير والشهادات المقدمة، حيث قد تكون متحيزة بسبب التنافس بين هذه المنظمات .

الفصل الثالث:الخلفية النظرية لهجمات التشويش (**jamming attacks**) وهجمات الاغراق في الشبكات اللاسلكية (**probe flooding**)

3.1 - jamming attacks

تُعدّ هجمات التشويش (**Jamming Attacks**) من أخطر أنواع الهجمات التي تستهدف الشبكات اللاسلكية، حيث تعتمد هذه الهجمات على استغلال الطبيعة المفتوحة لوسط الإرسال اللاسلكي. بخلاف الهجمات

التقليدية التي تعتمد على اختراق البرمجيات أو استغلال الثغرات المنطقية، فإن هجمات التشويش تعمل على الطبقة الفيزيائية (**Physical Layer**) من خلال التأثير المباشر على الإشارة اللاسلكية نفسها.

الهدف الأساسي من التشويش هو منع العقد الشرعية من التواصل عبر تقليل جودة الإشارة أو زيادة مستوى الضجيج (**Noise**) في القناة اللاسلكية، مما يؤدي إلى فشل استقبال الحزم أو إعادة إرسالها عدة مرات، وبالتالي تدهور أداء الشبكة بشكل كبير .

آلية عمل هجمة التشويش :

تعتمد هجمة التشويش على إرسال إشارات راديوية ذات قدرة عالية أو إشارات مزيفة ضمن نفس نطاق التردد الذي تعمل عليه الشبكة المستهدفة. عند وجود المهاجم (**Jammer**)، فإن مستوى الضجيج في القناة يزداد، مما يؤدي إلى انخفاض نسبة الإشارة إلى الضجيج (**Signal–to–Noise Ratio – SNR**).

يمكن التعبير عن ذلك نظرياً كما يلي:

في الحالة الطبيعية تكون نسبة **SNR** كافية لضمان الاتصال.

عند وجود مشوش، تضاف قدرة التشويش إلى الضجيج، فتتحول **SNR** إلى ما يُعرف بنسبة **Jamming–to–Noise Ratio (JNR)**.

كلما زادت قدرة المشوش، انخفضت سعة القناة (**Channel Capacity**) حسب معادلة شانون، مما يؤدي إلى انخفاض معدل نقل البيانات .

أنواع هجمات التشويش :

تشير الدراسات إلى وجود عدة أنواع من هجمات التشويش، من أهمها:

1. التشويش المستمر (**Constant Jamming**):

يقوم المهاجم بإرسال إشارات ضوضائية بشكل مستمر، مما يؤدي إلى شلل شبه كامل في الاتصال.

2. التشويش التفاعلي (**Reactive Jamming**):

لا يقوم المهاجم بالإرسال إلا عند اكتشاف نشاط في القناة، مما يجعل اكتشافه أصعب.

3. التشويش العشوائي (**Random Jamming**):

يتم الإرسال على فترات متقطعة وبشكل غير منتظم.

4. التشويش الذكي (**Intelligent Jamming**):

يعتمد على تغيير التردد أو القدرة لتجنب آليات الكشف التقليدية.

هذه الأنواع تختلف في درجة تعقيدها وصعوبة اكتشافها، لكن جميعها تؤدي في النهاية إلى تدهور أداء الشبكة .

تأثير هجمات التشويش على أداء الشبكة :

أظهرت الأبحاث أن لهجمات التشويش تأثيرات واضحة يمكن ملاحظتها من خلال مؤشرات أداء الشبكة (**QoS**)، ومن أهم هذه التأثيرات:

4.1 معدل تسليم الحزم (**Packet Delivery Ratio – PDR**)

ينخفض **PDR** بشكل كبير أثناء التشويش نتيجة فقدان عدد كبير من الحزم أو تلفها قبل الوصول إلى المستقبل.

4.2 الإنتاجية (**Throughput**)

يؤدي التشويش إلى انخفاض الإنتاجية بسبب زيادة عدد الحزم المعاد إرسالها أو فشل الاتصال بالكامل.

4.3 التأخير الكلي (**End–to–End Delay**)

يزداد التأخير نتيجة إعادة الإرسال والانتظار الطويل للوصول إلى القناة.

4.4 قوة الإشارة المستقبلة (**RSSI**)

قد يظهر **RSSI** سلوكاً مضللاً، حيث يمكن أن تكون الإشارة قوية ولكن غير قابلة للاستخدام بسبب الضجيج العالي، مما يجعل الاعتماد على **RSSI** وحده غير كافٍ للكشف عن التشويش .

مبدأ الكشف عن هجمات التشويش

تعتمد آليات الكشف الحديثة على تحليل سلوك الشبكة بدلاً من تحليل الإشارة فقط. الفكرة الأساسية تقوم على:

1. إنشاء ملف تعريف طبيعي (**Baseline Profile**) للشبكة في حالة التشغيل العادي.
2. حساب القيم الإحصائية لمؤشرات الأداء مثل:

Delay, **RSSI** , **PDR** , **Throughput**

3. استخدام قواعد إحصائية (مثل قاعدة $\pm 3\sigma$) لتحديد القيم الشاذة (**Outliers**).
4. اعتبار وجود التشويش عند استمرار الانحراف عن القيم الطبيعية لفترة زمنية معينة (**Timeout**)، لتجنب الإنذارات الخاطئة الناتجة عن التغيرات المؤقتة في الشبكة .

أهمية استخدام أكثر من مؤشر أداء :

أثبتت الدراسات أن الاعتماد على مؤشر واحد فقط (مثل **PDR** أو **RSSI**) قد يؤدي إلى نتائج خاطئة، لأن مشاكل الشبكة الطبيعية (ازدحام، تداخل، ضعف إشارة) قد تُنتج أعراضاً مشابهة للتشويش. لذلك، فإن الجمع بين عدة مؤشرات أداء وتحليلها بشكل متزامن يعطي دقة أعلى في الكشف ويقلل من الإنذارات الكاذبة **[24]**.

3.2-probe flooding

وفقًا لما ورد في دراسة Ratnayake et al.، فإن بروتوكول IEEE 802.11 يحتوي على عدد من الإطارات الإدارية (Management Frames) غير المحمية، ومن أهمها Probe Request و Probe Response.

هذا الأمر يجعل مرحلة البحث عن الشبكات (Scanning Phase) عرضة للاستغلال من قبل المهاجمين لتنفيذ هجمات حجب خدمة تعتمد على السلوك وليس على كسر التشفير.

Probe Requests في معيار IEEE 802.11

تُستخدم Probe Requests من قبل الأجهزة اللاسلكية للبحث عن الشبكات المتاحة، سواء: بشكل نشط (Active Scanning) أو عند الانتقال بين نقاط الوصول

أن هذه الإطارات: تُبث بشكل واضح (Plaintext)

لا تتضمن آليات مصادقة أو تحقق يمكن لأي جهاز توليدها أو مراقبتها وهذا ما يشكل أساس الثغرة الأمنية التي تستغلها هجمة Probe Flooding.

مفهوم Probe Request Flooding Attack :

هجمة حجب خدمة تعتمد على الإرسال المفرط لإطارات Probe Request بهدف استنزاف موارد الشبكة اللاسلكية

في هذا النوع من الهجمات يقوم المهاجم بإرسال Probe Requests بكثافة عالية غالبًا مع انتحال أو تغيير عناوين MAC

دون نية فعلية للانضمام إلى الشبكة النتيجة هي إجبار نقطة الوصول على معالجة عدد هائل من الطلبات غير الضرورية.

تصنيف الهجمة :

تصنّف Probe Flooding ضمن:

Denial of Service Attacks

Management Frame Abuse Attacks

Resource Exhaustion Attacks

خصائص Probe Flooding Attack :

تُبرز الدراسة عدة خصائص أساسية للهجمة: تعتمد على سلوك مشروع في البروتوكول و لا تتطلب معدات خاصة اي لا تسبب انقطاعًا مباشرًا للشبكة وايضا تؤدي إلى تدهور تدريجي في الأداء كما انها تُعد صعبة الاكتشاف بالطرق التقليدية

ولهذا تتصف ضمن Stealthy Denial of Service Attack

تأثير الهجمة على أداء الشبكة :

تشير نتائج الورقة إلى أن Probe Flooding تؤدي إلى: زيادة استهلاك موارد نقطة الوصول ارتفاع زمن التأخير (Delay) انخفاض معدل النقل (Throughput)

تراجع موثوقية الاتصال للأجهزة وتوضح الدراسة أن هذه التأثيرات تظهر حتى قبل انهيار الشبكة بالكامل، ما يجعل الهجمة خطيرة في البيئات الحساسة.

أهمية الهجمة في بيئات Smart Home :

على الرغم من أن الورقة تدرس شبكات WLAN عامة، إلا أن نتائجها تنطبق بشكل مباشر على بيئات Smart Home، حيث: عدد الأجهزة محدود و أنماط الاتصال متوقعة أي تدهور في الأداء يؤثر على وظائف حرجة

وبالتالي، فإن Probe Flooding تمثل تهديدًا فعليًا لاستقرار الأنظمة الذكية.

سبب صعوبة الكشف :

تؤكد Ratnayake et al. أن سبب صعوبة كشف Probe Flooding يعود إلى:

استخدام إطارات سليمة تشابه السلوك الهجومي مع scanning الطبيعي و عدم وجود انقطاع واضح في الخدمة

لذلك تقترح الورقة البحثية الاعتماد على التحليل السلوكي و الخصائص الزمنية للإطارات وايضا مقارنة السلوك الحالي بالخط الأساسي (Baseline)

يمكن القول إن Probe Request Flooding Attack تمثل ثغرة جوهرية في تصميم شبكات IEEE 802.11، حيث تسمح بإحداث هجمات حجب خدمة فعالة من خلال إساءة استخدام آليات مشروعة في البروتوكول، دون الحاجة إلى كسر التشفير أو إرسال إشارات مشوشة.[25]

الفصل الثالث : تجهيز بيئة العمل :

لتجهيز بيئة العمل المناسبة للمشروع يجب علينا معرفة ماهي المحاكيات المتوفرة والمناسبة لتطبيقه بالشكل الأمثل والحصول على نتائج دقيقة تبين اهمية تحسين كشف التطفل ضمن المنازل الذكية لذلك نحتاج الى البحث عن محاكيات شبكات الانترنت واجهزة IoT تمت المقارنة بين عدة محاكيات مبينة في الجدول التالي :

المحاكي	NS-3 (Network Simulator 3)	OMNeT++ (Objective Modular Network Testbed in C++)	Cooja
الهدف الرئيسي	محاكاة دقيقة لبروتوكولات الإنترنت وأنظمة الشبكات على مستوى الحزم (packet-level).	بنية معيارية (modular) قابلة للتوسيع لمحاكاة أنظمة اتصالات متنوعة ومعقدة.	محاكي مخصص لشبكات الاستشعار اللاسلكية (WSNs) وContiki OS.
أداء المحاكاة	عالي: معروف بأدائه الممتاز وكفاءته العالية في محاكاة السيناريوهات الكبيرة.	جيد جدًا: يوفر أداءً ممتازًا، لكنه قد يكون أبطأ قليلاً من NS-3 في بعض الحالات.	جيد: مناسب لمحاكاة الأجهزة محدودة الموارد، ولكنه قد يواجه تحديات في قابلية التوسع (scalability) للشبكات الكبيرة.
نقاط القوة	دقة عالية: يوفر محاكاة واقعية جدًا للبروتوكولات. مجتمع نشط: يمتلك مجتمعًا بحثيًا كبيرًا ومجموعة واسعة من النماذج (modules) المتطورة. دعم لـ IoT: يحتوي على وحدات (modules) للعديد من بروتوكولات إنترنت الأشياء مثل LoRaWAN وZigbee.	بنية معيارية: يتيح بناء محاكاة معقدة من مكونات بسيطة وقابلة لإعادة الاستخدام. واجهة رسومية قوية: تساعد في تصور المحاكاة وتتبع تدفق البيانات. مرونة: يمكن استخدامه في مجالات أوسع من مجرد الشبكات.	محاكاة دقيقة للأجهزة: محاكاة سلوك الأجهزة الحقيقية (hardware-in-the-loop) بدقة عالية. مدمج مع نظام تشغيل: يعمل بشكل متكامل مع نظام التشغيل Contiki OS
نقاط الضعف	منحنى تعلم حاد: يتطلب وقتًا وجهدًا كبيرًا لإتقانه. غياب الواجهة الرسومية: لا يوفر واجهة رسومية مدمجة للتصميم	أقل انتشارًا من NS-3: على الرغم من قوته، إلا أن عدد النماذج المتوفرة قد يكون أقل مقارنة بـ NS-3.	متخصص جدًا: لا يناسب الأبحاث العامة في مجال الشبكات، ويقتصر استخدامه على بيئةContiki

وبناء على المقارنة السابقة تم اختيار المحاكي NS-3.45 بسبب ان المشروع يركز على تحسين كشف الهجمات على مستوى البروتوكولات الشبكية و المحاكي مناسب لتحليل اداء البروتوكولات الخاصة بأنترنت الاشياء المعقدة .

الفصل الرابع:التجربة العملية

يهدف هذا الفصل إلى عرض التصميم العملي للنظام المقترح لكشف هجمات التشويش في الشبكات اللاسلكية، وشرح آلية تنفيذ التجربة، وتوضيح كيفية توليد الهجوم، وجمع البيانات، وتحليل مؤشرات الأداء من أجل اكتشاف وجود التشويش بشكل آني (**Real-Time**).

يركّز هذا الفصل على كيفية تنفيذ الفكرة النظرية عملياً، بينما تم شرح الخلفية النظرية لهجمات التشويش وآليات كشفها في الفصل السابق.

تصميم سيناريو الشبكة :

تم تصميم سيناريو شبكة لاسلكية بسيطة تمثل بيئة واقعية، حيث تتكون الشبكة من:

نقطة وصول لاسلكية (Access Point) تعمل كمركز للشبكة.

مجموعة من العقد (Nodes) التي تمثل أجهزة مستخدمة بشكل طبيعي داخل الشبكة.

عقدة مهاجمة (Attacker Node) تهدف إلى تنفيذ هجمة تشويش.

جميع العقد اللاسلكية تعمل ضمن نفس نطاق التردد وتستخدم معيار Wi-Fi، بحيث تتشارك القناة اللاسلكية نفسها، مما يجعل الشبكة عرضة لهجمات التشويش المعتمدة على استهلاك القناة.

حركة البيانات الطبيعية (Normal Traffic) :

من أجل مراقبة حالة الشبكة بشكل مستمر، تم اعتماد حركة بيانات دورية ومنخفضة المعدل يتم إرسالها من العقد الشرعية إلى نقطة الوصول. تمثل هذه الحركة ما يُعرف بـ حركة المراقبة أو النبض (Monitoring / Probe Traffic)، وتهدف إلى:

التأكد من استمرارية الاتصال.

قياس أداء الشبكة في الظروف الطبيعية وتوفير مؤشر مبكر على أي تدهور في الاتصال.

```
hashem@hashem-vm:~/ns-3.45$ ./ns3 run smart-home

[0/2] Re-checking globbed directories...
[2/2] Linking CXX executable /home/has...uild/scratch/
ns3.45-smart-home-default
Sudo password:
5s | ProbesTx=1755 | ProbesRx=1754 | RSSI=-30.6522 dBm
 | PDR=99.943% | Thpt=0.258189 Mbps | Delay=3.6524 ms
6s | ProbesTx=588 | ProbesRx=585 | RSSI=-30.6571 dBm |
 PDR=99.4898% | Thpt=0.43056 Mbps | Delay=4.24904 ms
7s | ProbesTx=585 | ProbesRx=586 | RSSI=-30.6571 dBm |
 PDR=100.171% | Thpt=0.431296 Mbps | Delay=3.27397 ms
8s | ProbesTx=585 | ProbesRx=587 | RSSI=-30.6571 dBm |
 PDR=100.342% | Thpt=0.432032 Mbps | Delay=3.37473 ms
9s | ProbesTx=588 | ProbesRx=584 | RSSI=-30.6571 dBm |
 PDR=99.3197% | Thpt=0.429824 Mbps | Delay=3.46144 ms
10s | ProbesTx=585 | ProbesRx=586 | RSSI=-30.6571 dBm
| PDR=100.171% | Thpt=0.431296 Mbps | Delay=3.90031 ms
11s | ProbesTx=585 | ProbesRx=587 | RSSI=-30.6571 dBm
| PDR=100.342% | Thpt=0.432032 Mbps | Delay=3.785 ms
12s | ProbesTx=588 | ProbesRx=586 | RSSI=-30.6571 dBm
| PDR=99.6599% | Thpt=0.431296 Mbps | Delay=3.87259 ms
```

تتميز هذه الحركة بأنها:صغيرة الحجم و منتظمة و ثابتة المعدل. مما يجعلها مناسبة لرصد أي تغير غير طبيعي في سلوك الشبكة.

تنفيذ هجمة التشويش :

تم تنفيذ هجمة التشويش باستخدام أسلوب Flooding-based Jamming، حيث تقوم العقدة المهاجمة بإرسال عدد كبير من الحزم بسرعة عالية جداً مقارنة بالحركة الطبيعية.

تعتمد هذه الهجمة على مبدأ استهلاك القناة اللاسلكية بشكل شبه كامل، مما يؤدي إلى:

جعل القناة مشغولة معظم الوقت كما يؤدي الى زيادة التصادمات بين الحزم و زيادة أوقات الانتظار وإعادة الإرسال لدى العقد الشرعية و تدهور جودة الخدمة بشكل ملحوظ.

```
60s | ProbesTx=588 | ProbesRx=587 | RSSI=-30.6571 dBm
| PDR=99.8299% | Thpt=0.432032 Mbps | Delay=3.78987 ms
61s | ProbesTx=585 | ProbesRx=525 | RSSI=-26.9391 dBm
| PDR=0.498221% | Thpt=0.60288 Mbps | Delay=226.947 ms
 ⚠(1/5)
62s | ProbesTx=585 | ProbesRx=452 | RSSI=-27.244 dBm |
 PDR=0.333849% | Thpt=0.429632 Mbps | Delay=585.801 ms
 ⚠(2/5)
63s | ProbesTx=585 | ProbesRx=358 | RSSI=-26.9636 dBm
| PDR=0.276675% | Thpt=0.351808 Mbps | Delay=1123.96 m
s ⚠(3/5)
64s | ProbesTx=588 | ProbesRx=416 | RSSI=-27.4161 dBm
| PDR=0.29658% | Thpt=0.385376 Mbps | Delay=1353.51 ms
 ⚠(4/5)
65s | ProbesTx=585 | ProbesRx=459 | RSSI=-27.6559 dBm
| PDR=0.349672% | Thpt=0.446304 Mbps | Delay=1784.9 ms
 ⚠(5/5)
🚨 JAMMING DETECTED 🚨
```

يبدأ المهاجم بتنفيذ الهجمة بعد فترة زمنية محددة تم تحديدها بزمن بداية وهو 60s ، وذلك لإتاحة المجال لمراقبة الشبكة في الحالة الطبيعية أولاً، ثم مقارنة سلوكها بعد بدء الهجوم.

مؤشرات الأداء المستخدمة في المراقبة :

من أجل تقييم حالة الشبكة واكتشاف التشويش، تم الاعتماد على مجموعة من مؤشرات الأداء (Performance Metrics)، وهي:

عدد الحزم المستلمة من حركة المراقبة: يمثل عدد الحزم المستلمة مؤشراً مباشراً على صحة الاتصال. أي انخفاض مفاجئ أو مستمر في هذا العدد يدل على وجود مشكلة في القناة اللاسلكية.

نسبة تسليم الحزم (Packet Delivery Ratio – PDR) :تعكس هذه النسبة كفاءة الشبكة في إيصال الحزم المرسلة إلى وجهتها النهائية، حيث يؤدي التشويش إلى انخفاضها بشكل واضح نتيجة التصادمات وفقدان الحزم.

معدل الإرسال الفعلي (Throughput) :يمثل كمية البيانات التي تم استلامها بنجاح خلال وحدة الزمن. أثناء التشويش، ينخفض هذا المعدل بسبب ازدحام القناة وإعادة الإرسال المتكررة.

التأخير الكلي (End-to-End Delay) : يشير إلى الزمن الذي تستغرقه الحزمة منذ إرسالها وحتى وصولها. يؤدي التشويش إلى زيادة كبيرة في هذا المؤشر نتيجة آليات الانتظار (Backoff) وإعادة الإرسال.

قوة الإشارة المستقبلة (RSSI) : تم استخدام RSSI كمؤشر إضافي لرصد التغيرات في مستوى الطاقة على القناة، مع الأخذ بعين الاعتبار أن ارتفاع RSSI لا يعني بالضرورة تحسناً في جودة الاتصال.

بناء النموذج المرجعي (Baseline) :

قبل البدء بالكشف عن التشويش، تم تخصيص فترة زمنية يتم خلالها جمع قيم مؤشرات الأداء في الحالة الطبيعية للشبكة. تُستخدم هذه الفترة لبناء نموذج مرجعي (Baseline) يمثل السلوك الطبيعي للشبكة.

خلال هذه الفترة: يتم حساب المتوسط الحسابي لكل مؤشر و يتم حساب الانحراف المعياري لقياس مدى التذبذب الطبيعي اذ يشكل هذا النموذج المرجعي الأساس الذي يتم من خلاله مقارنة القيم المستقبلية لاكتشاف أي انحراف غير طبيعي.

```
===== BASELINE =====
Probe μ=585.96 σ=0.82365
RSSI  μ=-30.6571 σ=1e-06
Delay μ=0.00389313 σ=0.000488502
Thpt  μ=0.431267 σ=0.000606207
PDR   μ=1.00021 σ=0.00324438
====================
```

آلية الكشف عن التشويش

تعتمد آلية الكشف المقترحة على مبدأ الكشف الإحصائي عن الشذوذ (Statistical Anomaly Detection)، وذلك من خلال:

1. مقارنة القيم الحالية لمؤشرات الأداء مع القيم المرجعية.

2. اعتبار المؤشر شاذاً إذا تجاوز حد الانحراف المسموح به ($\pm 3\sigma$).

3. عدم إعلان وجود هجمة مباشرة عند أول انحراف، بل انتظار استمرار الحالة الشاذة لعدة فترات زمنية متتالية (Timeout).

تم تسجيل نتائج التجربة بشكل دوري، حيث يتم تخزين القيم المقاسة لكل مؤشر أداء مع الزمن.

أظهرت النتائج أن التشويش يؤدي إلى تدهور واضح في أداء الشبكة، ويمكن اكتشافه بشكل فعّال من خلال الجمع بين عدة مؤشرات أداء وتحليلها إحصائياً.

وتم تمثيل النتائج بواسطة مخططات بيانية على برنامج **Matlab** لاظهار التغيير الحاصل في المؤشرات في الحالة الطبيعية وبعد الهجوم

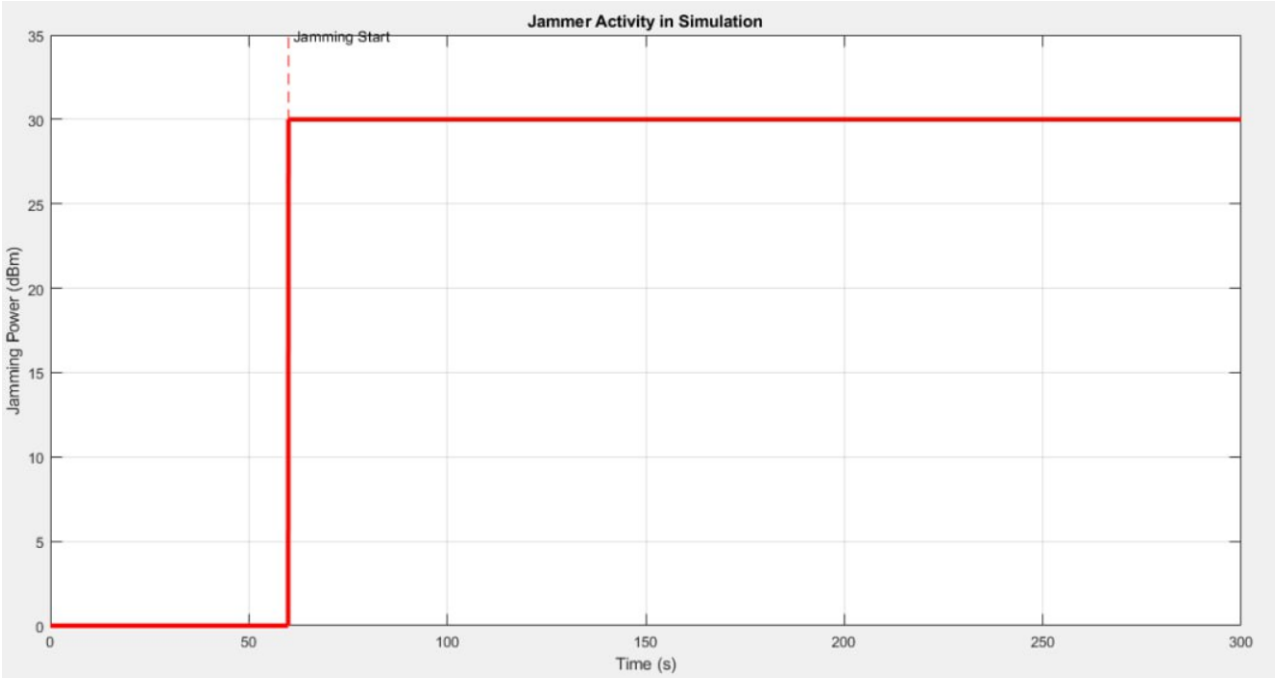

تصميم وتنفيذ سيناريو هجمة **Probe Flooding** وآلية كشفها :

يهدف هذا القسم إلى شرح كيفية تنفيذ هجمة **Probe Flooding** عملياً ضمن سيناريو شبكة لاسلكية، وبيان طريقة رصد الهجمة والكشف عنها بشكل شبه آني اعتماداً على سلوك التدفّق (**Traffic Behavior**) ومؤشرات إحصائية مبنية على الحالة الطبيعية للشبكة.

حركة البيانات الطبيعية (**Normal Probe–like Traffic**)

لأجل مراقبة الشبكة بشكل مستمر، تم توليد حركة "طبيعية" منخفضة المعدل من الأجهزة باتجاه الـ **AP** على منفذ ثابت (9999).

```
hashem@hashem-vm:~/ns-3.45$ ./ns3 run smart-home

[0/2] Re-checking globbed directories...
ninja: no work to do.
Sudo password:
5s | TxAll=876 | Rx9999=876 | Rx4444=0 | Worst9999=10.1.1.2 | Rate=29
2 pkts/s | dT=0.0101755 s | RSSImax(AP)=-16.6777 dBm | PDR=100% | Thp
t=0.644736 Mbps | Delay=4.66564 ms
6s | TxAll=294 | Rx9999=294 | Rx4444=0 | Worst9999=10.1.1.4 | Rate=98
 pkts/s | dT=0.0102243 s | RSSImax(AP)=-30.6571 dBm | PDR=100% | Thpt
=0.216384 Mbps | Delay=4.54367 ms
7s | TxAll=294 | Rx9999=292 | Rx4444=0 | Worst9999=10.1.1.3 | Rate=98
 pkts/s | dT=0.0102231 s | RSSImax(AP)=-30.6571 dBm | PDR=99.3197% |
Thpt=0.214912 Mbps | Delay=4.57751 ms
8s | TxAll=291 | Rx9999=293 | Rx4444=0 | Worst9999=10.1.1.2 | Rate=98
 pkts/s | dT=0.0101913 s | RSSImax(AP)=-30.6571 dBm | PDR=100.687% |
Thpt=0.215648 Mbps | Delay=4.55755 ms
9s | TxAll=294 | Rx9999=293 | Rx4444=0 | Worst9999=10.1.1.4 | Rate=98
 pkts/s | dT=0.0102221 s | RSSImax(AP)=-30.6571 dBm | PDR=99.6599% |
```

تمثل هذه الحركة قياس (**Probe–like**) هدفه:

توفير خط أساس لسلوك الشبكة الطبيعي , السماح بملاحظة أي تغيّر مفاجئ في معدل الاستلام أو نمط وصول الحزم

خصائص الحركة الطبيعية : معدل إرسال منخفض , أحجام حزم صغيرة , إرسال شبه مستمر (**On** دائم تقريباً).

تنفيذ هجمة (**Attack Generation**) **Probe Flooding** :

تم تنفيذ الهجمة عبر عقدة مهاجمة تقوم بإرسال عدد كبير جداً من الحزم إلى نفس المنفذ 9999 المستخدم من حركة المرور الطبيعية، لكن بمعدل أعلى بكثير (**Flood**).

يؤدي ذلك إلى استهلاك الموارد وزيادة الازدحام، وقد يسبب تدهوراً في أداء الشبكة وبالأخص بالنسبة للحزم الطبيعية.

تم ضبط الهجمة لتبدأ بعد الثانية 60 من بداية المحاكاة كي تتوفر فترة كافية لبناء **Baseline** للحالة الطبيعية أولاً، ثم مراقبة الانحراف بعد بدء الهجوم.

مؤشرات الرصد الخاصة بهجمة **Probe Flooding** :

بعكس هجمة التشويش التي تنعكس غالباً كـ "انهيار أداء عام"، هجمة **Probe Flooding** يمكن كشفها بدقة أعلى عبر مؤشرات تركيزها على مصدر واحد وسلوك الوصول للمنفذ المستهدف (9999). لذلك تم اعتماد

مؤشرين أساسيين للهجمة:

1– معدل الحزم من (**Worst Source Rate**)

ضمن نافذة زمنية مقدارها 1 ثانية:

يتم حساب عدد الحزم المستلمة على المنفذ 9999 لكل عنوان مصدر.

يتم اختيار المصدر الذي يرسل أكبر عدد حزم خلال تلك الثانية (**Worst sender**).

قيمة هذا المعدل (**packets/sec**) تعتبر مؤشراً مباشراً على الإغراق.

2– متوسط زمن الوصول بين الحزم للمصدر نفسه (**Average Delta Time**) :

يتم حساب متوسط الزمن بين وصول حزم متتالية من نفس المصدر خلال النافذة.

أثناء الهجوم ، يصبح **delta time** صغير جداً لأن الحزم تصل بسرعة عالية ومتقاربة.

الجمع بين (**Rate** مرتفع) و (**Delta Time** منخفض) يعطي كشفاً أدق ويقلل الإنذارات الخاطئة مقارنة بالاعتماد على مؤشر واحد فقط.

بناء النموذج المرجعي (**Baseline**)

قبل تشغيل آلية الكشف، يتم جمع عينات من المؤشرين خلال فترة طبيعية (قبل الهجوم):

تخزين قيم **Worst Rate** لكل ثانية , تخزين قيم **WorstDeltaTime** لكل ثانية , ثم يتم حساب المتوسط (**Mean**) لكل مؤشر , والانحراف المعياري (**Std**) لكل مؤشر.

```
===== BASELINE READY =====
FloodRate μ=98 pkts/s, σ=0
FlooddT   μ=0.0102325 s,      σ=2.24679e-05
PDR       μ=1.00017, σ=0.00701392
Thpt      μ=0.215619 Mbps, σ=0.000569343
Delay     μ=0.00455661 s, σ=2.68719e-05
RSSImax(AP) μ=-30.6571 dBm, σ=1.06581e-14
==========================
```

يمثل ذلك السلوك الطبيعي للشبكة عندما لا يوجد مهاجم .

آلية كشف (**Detection Logic**) **Probe Flooding** :

تعتمد آلية الكشف على كشف الشذوذ إحصائياً باستخدام قاعدة ($\pm 3\sigma$) مع شرط تلازم بين مؤشرين:

شرط (1): معدل الحزم المرسلة من المهاجم أعلى من الطبيعي بشكل كبير (**WorstRate > Mean Rate + 3×StdRate**)

شرط (2): متوسط **DeltaTime** للمصدر نفسه أقل من الطبيعي بشكل كبير

(**WorstDeltaTime < MeanDT − 3×StdDT**)

ثم يعتبر أن الهجمة في تلك الثانية فقط إذا تحقق الشرطان معاً:

FloodDetected = RateAnomaly AND DtAnomaly

تقليل الإنذارات الخاطئة عبر الاستمرارية (**Persistence / Timeout**)

حتى لا يتم إعلان الهجوم من أول ثانية شاذة (قد تكون **spike** طبيعية)، تم اعتماد عدّاد استمرارية :

إذا استمر الكشف لعدد ثوانٍ متتالية (مثلاً 5 ثوانٍ)، يتم إعلان الهجمة , إذا عادت القيم لطبيعتها يتم تصفير العداد

هذا يجعل القرار أكثر ثباتاً ويزيد موثوقية الكشف.

```
60s | TxAll=291 | Rx9999=293 | Rx4444=0 | Worst9999=10.1.1.4 | Rate=9
8 pkts/s | dT=0.0102468 s | RSSImax(AP)=-30.6571 dBm | PDR=100.687% |
 Thpt=0.215648 Mbps | Delay=4.07678 ms
61s | TxAll=78418 | Rx9999=2467 | Rx4444=0 | Worst9999=10.1.1.5 | Rat
e=2173 pkts/s | dT=0.000455765 s | RSSImax(AP)=-30.6571 dBm | PDR=3.1
4596% | Thpt=1.25942 Mbps | Delay=439.106 ms
62s | TxAll=78419 | Rx9999=2714 | Rx4444=0 | Worst9999=10.1.1.5 | Rat
e=2423 pkts/s | dT=0.000412253 s | RSSImax(AP)=-30.6571 dBm | PDR=3.4
609% | Thpt=1.37722 Mbps | Delay=1311.12 ms
63s | TxAll=78416 | Rx9999=2494 | Rx4444=0 | Worst9999=10.1.1.5 | Rat
e=2200 pkts/s | dT=0.000455104 s | RSSImax(AP)=-30.6571 dBm | PDR=3.1
8047% | Thpt=1.27238 Mbps | Delay=2135.7 ms
64s | TxAll=78419 | Rx9999=2790 | Rx4444=0 | Worst9999=10.1.1.5 | Rat
e=2496 pkts/s | dT=0.00040062 s | RSSImax(AP)=-30.6571 dBm | PDR=3.55
781% | Thpt=1.41446 Mbps | Delay=3034.83 ms

🚨 PROBE FLOODING DETECTED 🚨 src=10.1.1.5 at t=65s
```

تسجيل النتائج وعرضها :

يتم طباعة سطر قياس كل ثانية يتضمن عدد الحزم المرسلة إجمالاً , عدد الحزم المستلمة على 9999 (للخدمة الطبيعية + الهجوم) في تلك الثانية **WorstRate** و **WorstDeltaTime**

تم تنفيذ هجمة **Probe Flooding** عملياً عبر إغراق المنفذ المستهدف بحزم عالية المعدل من مصدر واحد، ثم كشفها باستخدام نهج مبني على:

استخراج كل ثانية **worst source**، قياس معدل الإرسال منه , وقياس متوسط زمن الوصول بين حزمه،

ومقارنة ذلك بخط أساس طبيعي عبر عتبات إحصائية ، مع اعتماد شرط الاستمرارية لتقليل الإنذارات الخاطئة.

الفصل الخامس : النتائج و الافاق المستقبلية

تم في هذا المشروع مايلي :

نتائج هجمة التشويش (Jamming) :

أظهرت نتائج التجربة أن هجمة التشويش أدت إلى تدهور واضح في أداء الشبكة، حيث انخفضت نسبة تسليم الحزم (**PDR**) والإنتاجية (**Throughput**)، مقابل ارتفاع ملحوظ في زمن التأخير (**Delay**). كما لوحظ ارتفاع في قيمة **RSSI** المقاسة عند نقطة الوصول نتيجة زيادة مستوى الطاقة على القناة، رغم تدهور جودة الاتصال الفعلية.

تمكنت آلية الكشف المقترحة من رصد الهجمة بعد فترة قصيرة من بدئها اعتماداً على الانحراف المتزامن في عدة مؤشرات أداء، مع تقليل الإنذارات الخاطئة بفضل شرط الاستمرارية الزمنية.

نتائج هجمة Probe Flooding :

بيّنت النتائج أن هجمة **Probe Flooding** أدت إلى ظهور مصدر واحد مهيمن يرسل حزمًا بمعدل مرتفع جداً وبفواصل زمنية قصيرة. وعلى عكس التشويش، لم تؤدِّ هذه الهجمة إلى انهيار فوري في الأداء العام للشبكة، بل كان تأثيرها الأساسي متركزاً على استهلاك موارد نقطة الوصول.

اعتمد كشف الهجمة على الجمع بين ارتفاع معدل الإرسال من المهاجم وانخفاض متوسط الزمن بين الحزم، مما أتاح اكتشاف الهجمة بدقة عالية مع تجنب الخلط بينها وبين الازدحام الطبيعي.

تُظهر النتائج أن هجمة التشويش تؤثر على الأداء العام للشبكة، بينما تبرز هجمة **Probe Flooding** كسلوك غير طبيعي لمصدر محدد. وقد أثبتت آلية الكشف المقترحة فعاليتها في التمييز بين الهجمتين باستخدام مؤشرات مختلفة لكل منهما .

الافاق المستقبلية :

بالاعتماد على نتائج هذا العمل، وبالاستناد إلى الدراسات السابقة المتعلقة بهجمات التشويش (**Jamming**) وهجمات الإغراق من نوع **Probe Flooding**، يمكن اقتراح عدد من الآفاق المستقبلية التي تساهم في تطوير النظام المقترح وزيادة فعاليته في بيئات أكثر واقعية وتعقيداً .

- دعم أنواع أكثر تقدماً من هجمات التشويش :

ركّز العمل الحالي، بما يتوافق مع البيبر الأول، على هجمات التشويش المعتمدة على استهلاك القناة والإغراق. إلا أن الدراسات تشير إلى وجود أنواع أكثر تقدماً مثل:

التشويش التفاعلي (**Reactive Jamming**) الذي يهاجم فقط عند وجود إرسال.

التشويش المتقطع (**Intermittent Jamming**) الذي يعمل على فترات زمنية قصيرة لتفادي الكشف.

التشويش الذكي (**Adaptive or Intelligent Jamming**).

- الانتقال من الكشف إلى الاستجابة (**Mitigation**) :

إضافة آليات استجابة تلقائية بعد الكشف.

عزل العقد المهاجمة أو تقليل أولوية حزمها.

تغيير القناة اللاسلكية أو تعديل إعدادات **MAC** ديناميكياً.

دراسة تأثير هذه الاستجابات على أداء الشبكة الكلي.

فهرس المراجع :

[1] AL-TAAI, Suaad Hadi Hassan; KANBER, Huda Abbas; AL

DULAIMI, Waleed Abood Mohammed. The importance of using the internet of things in education. Int. J. Emerg. Technol. Learn., 2023, 18.1: 19 .

[2] ASIF, Muhammad K., et al. Network intrusion detection and its strategic importance. In: 2013 IEEE Business Engineering and Industrial Applications Colloquium (BEIAC). IEEE, 2013. p. 140-144 .

[3] BACE, Rebecca Gurley, et al. Intrusion detection systems 2001 .

[4] AMRU, Malothu, et al. Network intrusion detection system by applying ensemble model for smart home. International Journal of Electrical and Computer Engineering, 2024, 14.3: 3485-3494 .

[5] J., Asharf, N., et all. A review of intrusion detection systems using machine and deep learning in Internet of things: Challenges, solutions and future directions, Electronics, vol. 9 no. 7, pp. 11-77, 2020 .

[6] N., Chaabouni, M., Mosbah, A., Zemmari, C., Sauvignac, and P. Faruki, Network intrusion detection for IoT security based on learning techniques. IEEE Communications Surveys & Tutorials, vol. 21. no. 3, pp. 2671-2701. 2019 .

[7] G. Altan, SecureDeepNet-IoT: A deep learning application for invasion detection in industrial Internet of things sensing systems. Transactions on Emerging Telecommunications Technologies, vol.32, no 4, pp. 42- 28.2021 .

[8] H. Sallay, An integrated multilayered framework for IoT security intrusion decisions. Intelligent Automation & Soft Computing, vol 36. no 1.pp. 429-444.2023 .

[9] X., An, X., Zhou, X., Lü, F., Lin, and L. Yang. Sample selected extreme learning machine based intrusion detection in fog computing and MEC. Wireless Communications and Mobile Computing, pp.1-10.2018 .

[10] R., Heartfield, G., Loukas, A., Bezemskij, and E. Panaousis, Selfconfigurable cyber-physical intrusion detection for smart homes using reinforcement learning. IEEE Transactions on Information Forensics and Security, vol. 16, pp. 1720-1735. 2020 .

[11] E. D. Alalade. Intrusion detection system in smart home network using artificial immune system and extreme learning machine hybrid approach. In 2020 IEEE 6th World Forum on Internet of Things (WFIoT). pp. 1-2. 2020 .

[12] M., Noman S., Rosli A.H., Mohammad and, Z. Muhammad. SDN based intrusion detection and prevention systems using manufacturer usage description: a survey. (IJACSA) International Journal of Advanced Computer Science and Applications, vol 11, no 12, 2020 .

[13] A. S., Ibrahim, K. Y., Youssef, H., Kamel, and M. Abouelatta. Traffic modelling of smart city internet of things architecture. IET Communications, vol 4, no 8, pp.1275-1284.2020 .

[14] S., Kumar, et all. Characterizing IoT traffic in smart home and campus environments. Proceedings IEEE INFOCOM pp.2706-2715.2020 .

[15] JAMSHIDI, Saeid, et al. Application of deep reinforcement learning for intrusion detection in Internet of Things: A systematic review. Internet of Things, 2025, 101531 .

[16] D.E. Denning, An intrusion-detection model, IEEE Trans. Softw. Eng. SE-13 (1987), 222–232 .

[17] A. R. Bauer, K. T. Burns, M. V. Esposito, P. L. O'malley, B. J. Olexa, and R. Mcmillan , "Monitoring system for determining and communicating a cost of insurance," ed: Google Patents ., (2013 (

[18] H.J. Liao, C.-H. R. Lin, Y.C. Lin, K.Y. Tung, Intrusion detection system: a comprehensive review, J. Netw. Comput. Appl. 36 (2013), 16–24 .

[19] J.M. Fossaceca, T.A. Mazzuchi, S. Sarkani, MARK-ELM: application of a novel multiple kernel learning framework for improving the robustness of network intrusion detection, Expert Syst. Appl. 42 (2015), 4062–4080 .

[20] M. Tavallaee, E. Bagheri, W. Lu, A.A. Ghorbani, A detailed analysis of the KDD CUP 99 data set, in 2009 IEEE Symposium on Computational Intelligence for Security and Defense Applications, Ottawa, Canada, 2009 .

[21] M. Moradi, M. Zulkernine, A neural network based system for intrusion detection and classification of attacks, in IEEE .

International Conference on Advances in Intelligent Systems-Theory and Applications, Luxembourg, 2004 .

[22] T. Pietraszek, "Using adaptive alert classification to reduce false positives in intrusion detection," in International Workshop on Recent Advances in Intrusion Detection, Springer, 2004. pp. 102– 124 .

[23] S. Elhag, A. Fernández, A. Bawakid, S. Alshomrani, F. Herrera, On the combination of genetic fuzzy systems and pairwise learning for improving detection rates on intrusion detection systems, Expert Syst. Appl. 42 (2015), 193–202 .

[24] ZAHRA, Fatima Tu; BOSTANCI, Yavuz Selim; SOYTURK, Mujdat. Real-time jamming detection in wireless IoT networks. *IEEE Access*, 2023, 11: 70425-70442.

[25] RATNAYAKE, Deepthi N.; KAZEMIAN, Hassan B.; YUSUF, Syed A. Identification of probe request attacks in WLANs using neural networks. *Neural Computing and Applications*, 2014, 25.1: 1-14.